分类号 TP242　　密　　级

U D C 621　　学校代码 10500



湖北工業大學

HUBEI UNIVERSITY OF TECHNOLOGY

硕士学位论文

（学历教育－专业硕士）

题　目：基于视觉检测与深度学习的无序堆叠工件机械臂抓取方法研究

英文题目：Research on Robotic Arm Grasping Method for Disordered Stacked Workpieces Based on Visual Detection and Deep Learning

学位申请人姓名：牛一森

申请学位学科专业：机械工程

指导教师姓名：汤 亮

二〇二六年六月

中国知网 https://www.cnki.net

分类号 TP242　　密　　级

U D C 621　　学校代码 10500



湖北工業大學

HUBEI UNIVERSITY OF TECHNOLOGY

硕士学位论文

题　目 基于视觉检测与深度学习的无序堆叠工件机械臂抓取方法研究

英文题目 Research on Robotic Arm Grasping Method for Disordered Stacked Workpieces Based on Visual Detection and Deep Learning

研究生姓名（签名）

指导教师姓名（签名）　　职　称 副教授

申请学位学科名称 机械工程　学科代码 085500

论文答辩日期 2026.5.21　学位授予日期 2026.6.30

学院负责人（签名）

评阅人姓名 李学艺　评阅人姓名 吴兵

2026 年 6 月 30 日

中国知网 https://www.cnki.net

摘　　要

本文研究的是关于工业机械臂在无序环境下物体抓取的问题，提出了一种基于视觉检测及深度学习的无序堆叠工件抓取方法。本研究旨在提高机器人在复杂无序环境的自主抓取能力，结合机器视觉、深度学习、多传感器等技术，开发了智能化无序抓取系统。该系统可以适用于各种不同的形状、材质、重量的工件，在智能制造、仓储物流等相关行业具有较强的应用价值。

首先，研究从无序场景建模入手，建立一种基于自监督学习的抓取角度分类网络，实现无序抓取数据集的自动标注。在此基础上，采用两阶段训练与端到端检测模式的平面抓取模型，大幅提升了无序抓取系统的场景适应性与运行稳定性。针对深度图像成像难题，研究从两个维度突破：一是设计了适用于堆叠零件场景的深度估计方法，并结合图像重光照模型获取高质量场景图像，为后续位姿估计与抓取操作奠定基础；二是提出基于 RGB 图像与法向量引导的深度估计算法，该算法有效降低识别目标的数据量，同时将抓取准确率提升 15.8%。

其次，利用 Blender 软件对单个零件进行准确的材质渲染，通过孪生神经网络选出与实际成像效果最接近的渲染结果。在基础建模和核心算法完善后，研究抓取策略优化工作。通过机器视觉的姿态学习方法，以最大抓取成功率为准则，将推挤和抓取动作纳入同一个回报函数框架下进行学习，结合仿真环境产生的大量数据集完成模型训练与测试，引入多传感器数据融合技术，整合深度相机、激光雷达等设备的数据。然后，利用深度神经网络提取物体特征，结合强化学习算法实现抓取策略的动态调整，不仅使物体识别精度高达 85.4%，还将应用成本降低约 35%，机器人可以快速适应周围环境变化。

最后，构建了由高精度机械臂、视觉传感器以及力反馈传感器组成的实验平台，并对优化算法进行抓取成功率、实时性和环境适应性的测试。实验环境设置有多个复杂情况下的测试条件，如不同的光照条件、物体之间的重叠度以及物体材料特性等。实验结果表明，本研究所提方法的总体抓取成功率达到 80%以上，执行损耗时间减少了 10%，性能上优于传统的抓取方法，有较好的工程应用前景。

关键词：无序抓取；深度学习；机器视觉；机械臂；位姿

中国知网　https://www.cnki.net

Abstract

This paper focuses on the problem of object grasping by industrial manipulators in unordered environments and proposes a method for grasping unordered stacked workpieces based on visual detection and deep learning. The purpose of this research is to improve the robot's autonomous grasping ability in complex and unordered environments. Combined with technologies such as machine vision, deep learning, and multi-sensors, an intelligent unordered grasping system is developed. This system can be applied to workpieces of various shapes, materials, and weights, and has strong application value in related fields such as intelligent manufacturing and warehousing logistics.

Firstly, starting with the modeling of unordered scenarios, the research establishes a grasping angle classification network based on self-supervised learning, realizing the automatic annotation of the unordered grasping dataset. On this basis, a planar grasping model adopting two-stage training and end-to-end detection mode is adopted, which greatly improves the scene adaptability and operational stability of the unordered grasping system.Aiming at the difficulty of depth imaging,the research makes breakthroughs from two dimensions:first,a depth estimation method suitable for stacked part scenarios is designed, and high-quality scene images are obtained by combining the image relighting model,laying a foundation for subsequent pose estimation and grasping operations;second, a depth estimation algorithm guided by RGB images and normal vectors is proposed, which effectively reduces the data volume of the identified targets and increases the grasping accuracy by 15.8% at the same time.

Secondly, Blender software is used to accurately render materials for individual parts, and a Siamese neural network is employed to select the rendering result that is closest to the actual imaging effect. After the completion of basic modeling and the improvement of core algorithms, the optimization of the grasping strategy is studied. Through the pose learning method based on machine vision and guided by the criterion of maximum grasping success rate, pushing and grasping actions are incorporated into the same reward function framework for learning. Model training and testing are completed using a large number of datasets generated in the simulation environment, and multi-sensor data fusion technology is introduced to integrate data from depth cameras, LiDAR and other equipment. Then, the deep neural network is used to extract object features, and a reinforcement learning algorithm is combined to realize the dynamic adjustment of the grasping strategy. This not only achieves an object recognition accuracy of up to 85.4%, but also reduces the application cost by approximately 35%, enabling the robot to quickly adapt to changes in the surrounding environment.

Finally, an experimental platform composed of a high-precision manipulator, visual sensors, and force feedback sensors was built, and the optimized algorithm was tested in

中国知网 https://www.cnki.net

terms of grasping success rate, real-time performance, and environmental adaptability. The experimental environment was set with multiple test conditions under complex situations, such as different lighting conditions, the overlap between objects, and the material characteristics of objects.The experimental results show that the overall grasping success rate of the method proposed in this research exceeds 80%,the execution loss time is reduced by 10%, and its performance is better than that of traditional grasping methods, which has a good engineering application prospect.

Keywords: Unstructured Grasping; Deep Learning; Machine Vision; Robotic Arm; Pose Estimation

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景.....1
1.2 研究目的与意义.....2
1.3 国内外研究现状.....3
1.3.1 国外研究现状.....3
1.3.2 国内研究现状.....4
1.3.3 研究现状总结.....6
1.4 研究内容及方法.....7
1.4.1 研究内容.....7
1.4.2 研究方法.....8
1.5 组织架构图.....9
第 2 章 无序堆叠场景的视觉感知与目标识别.....11
2.1 无序场景建模与分析.....11
2.1.1 无序堆叠场景特征分析.....11
2.1.2 遮挡与重叠问题建模.....12
2.1.3 光照变化对视觉感知的影响.....13
2.2 基于深度图像的三维重建.....14
2.2.1 深度图像获取与预处理.....14
2.2.2 点云配准与融合算法.....16
2.2.3 三维场景重建优化方法.....18
2.3 工件目标识别与分割.....19
2.3.1 基于深度学习的目标检测网络设计.....20
2.3.2 实例分割算法优化.....22
2.3.3 多尺度特征融合方法.....24
2.4 工件位姿估计算法.....26
2.4.1 基于 RGBD 图像的位姿估计.....26
2.4.2 法向量引导的深度估计方法.....27
2.4.3 位姿精度优化策略.....29
2.5 本章小结.....30
第 3 章 基于深度学习的抓取策略优化.....31
3.1 抓取检测模型设计.....31
3.1.1 抓取表示方法与评价体系.....31
3.1.2 基于自监督学习的抓取角度分类.....32
3.1.3 端到端平面抓取检测网络.....34

中国知网 https://www.cnki.net

3.2 抓取数据集构建与标注.....36
3.2.1 仿真环境构建与数据生成.....36
3.2.2 自动标注算法设计.....37
3.2.3 真实数据采集与处理.....39
3.3 强化学习抓取策略优化.....40
3.3.1 抓取环境建模与状态空间设计.....40
3.3.2 奖励函数设计与优化.....42
3.3.3 推动与抓取动作协同学习.....43
3.4 多传感器信息融合.....45
3.4.1 视觉与力觉信息融合策略.....45
3.4.2 不确定性估计与决策优化.....47
3.4.3 传感器故障检测与处理.....48
3.5 本章小结.....49
第 4 章 虚实结合的渲染与深度估计方法.....50
4.1 虚拟场景渲染技术.....50
4.1.1 基于 Blender 的材质渲染方法.....50
4.1.2 孪生神经网络渲染效果评价.....51
4.1.3 虚拟与真实场景的域适应.....52
4.2 图像重光照与场景生成.....54
4.2.1 环境光照估计算法.....54
4.2.2 图像重光照模型设计.....55
4.2.3 高质量场景图像生成方法.....56
4.3 深度估计算法优化.....58
4.3.1 基于 CNN 的单目深度估计.....58
4.3.2 RGB 图像与法向量融合的深度估计.....59
4.3.3 深度估计精度评价与优化.....60
4.4 虚实数据融合策略.....61
4.4.1 域迁移学习方法.....61
4.4.2 虚实数据混合训练策略.....62
4.4.3 模型泛化能力提升方法.....63
4.5 本章小结.....63
第 5 章 实验设计与结果分析.....65
5.1 实验平台搭建.....65
5.1.1 硬件系统配置与集成.....65
5.1.2 软件系统架构设计.....67
5.1.3 实验环境标定与测试.....69
5.2 算法性能评估实验.....71
5.2.1 视觉检测精度测试.....71

中国知网 https://www.cnki.net

5.2.2 抓取成功率统计分析.....72
5.2.3 实时性能测试与分析.....75
5.3 对比实验与消融实验.....76
5.3.1 传统方法的对比实验.....76
5.3.2 不同网络结构对比分析.....77
5.3.3 关键模块消融实验.....78
5.4 复杂场景适应性实验.....80
5.4.1 不同物体材质与形状测试.....80
5.4.2 复杂光照条件下的性能评估.....81
5.4.3 动态场景抓取实验.....82
5.5 实验结果分析与讨论.....83
5.5.1 实验数据统计与可视化.....83
5.5.2 算法优缺点分析.....84
5.6 本章小结.....85
第 6 章 结论与展望.....86
6.1 研究工作总结.....86
6.2 不足与改进方向.....86
6.3 未来工作展望.....87
参考文献.....88
附录.....92

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景

伴随着世界制造业向智能化、自动化的趋势不断加快，机器人技术被越来越多地应用于工业生产当中。据国际机器人联合会统计，在 2019-2025 年间，世界工业机器人的销售量持续上升，年均复合增长率高达 7.5%，而中国作为世界上最大的工业机器人市场，2025 年的机器人密度达到了 470 台/万人，相比 2019 年的 187 台/万人提高了 151%[1]。在智能制造方面，机械臂抓取技术是整个自动化产线的重要组成部分，它的技术水平高低决定了整个产线的运行速度以及产品的质量。

传统工业机械臂抓取系统主要是针对结构化的环境来设计的，也就是工件按一定的规则排列整齐，工作场景示意如图 1.1 所示，抓取路径以及策略比较明确。但是在实际的生产过程中，尤其是在仓储物流、装配制造以及回收处理等场景下，工件一般是杂乱无章地堆放在一起，这样的非结构化环境对于机械臂来说进行抓取是非常困难的，存在很多的问题，例如复杂的目标检测、准确的空间感知以及灵活的抓取策略等。根据麦肯锡全球科研院的调查数据，无序环境中机器人抓取技术的迭代将会使制造业每年产生超过 4000 亿美元的价值增长[2]。

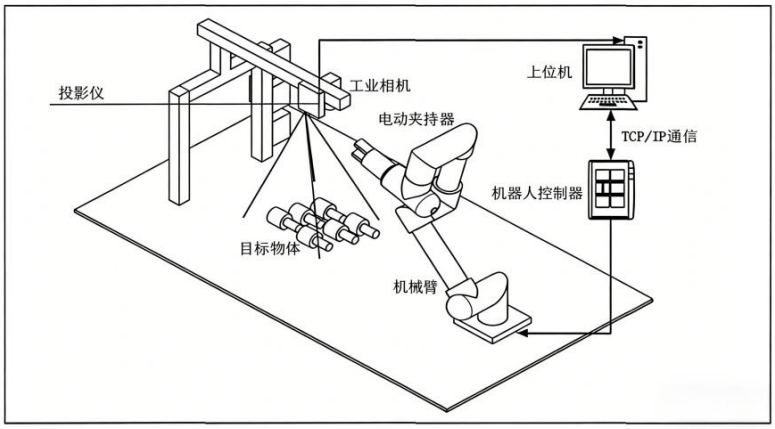


图 1.1 工业机械臂场景示意

近几年来，随着深度学习技术的发展，给解决无序抓取问题带来了新的技术手段，计算机视觉方面的巨大进步尤其是卷积神经网络对于图像分类以及目标检测的良好效果，让机器人可以更加准确地理解并解析复杂视觉信息。而强化学习算法在决策优化上的成功运用，则是机械臂抓取策略智能化的基础保障。据 Tractica 报告预测，人工智能驱动下的机器人视觉市场将会由 2020 年的 15.2 亿美元提升至

中国知网 https://www.cnki.net

2025 年的 144.6 亿美元，年均增长率高达 57.8%[3]。

从工业应用的角度来看，无序抓取技术的需求越来越强烈。汽车制造领域中零部件自动装配要求机器人能抓取各种不同形状和大小的零件。电子产品的生产行业遇到的是小体积、多样化的器件抓取难题，传统的固定式抓取已经不能适应柔性化生产的需要。而物流仓储行业对于无序抓取的需求更是巨大，亚马逊、阿里巴巴等电商企业都投入巨资在智能仓储系统上，也推动了该技术的进步。据中国机器人产业联盟统计，2023 年中国服务机器人市场规模达到 781.8 亿元人民币，其中仓储物流机器人占到 30%以上[4]。

在技术方面，多传感器融合技术已经成为无序抓取系统的主流研究方向。RGB 相机、深度相机、激光雷达等多种不同的传感器相辅相成能够为机器人提供更全面、准确的环境信息。边缘计算技术的发展也为实时抓取决策提供了硬件基础，让复杂的算法能够在机器人内部快速地运算出来。5G 通信技术的应用也让云端智能与终端设备之间联系更加紧密，给机器人系统的协作带来新契机。

无序抓取技术研究的价值不仅体现在技术层面，还有着巨大的经济价值和社会价值。从经济效益方面来说，这项技术的实现将会极大程度减少制造业的人工成本，提高产品的生产效率以及生产质量。据波士顿咨询公司预测，到 2030 年智能制造技术的应用将会使全球制造业成本节约高达 3.7 万亿美元[5]。从社会意义上讲，自动抓取技术的发展可以减轻工人在危险或者重复性作业环境下的工作强度，改善他们的工作环境，同时也能够产生更多的高技能型岗位需求。

从国家政策扶持上来看，中国政府十分重视机器人的发展，出台了一系列如《人形机器人创新发展指导意见》等重要文件，明确指出要攻克机器人关键技术难题，提高产业化的水平，《“十四五”机器人产业发展规划》更是提出要加大机器人核心技术的研发力度，推进机器人应用于重点领域的大规模应用，这些政策扶持给无序抓取技术的研发及产业化创造了有利条件[6-8]。

本文的研究是关于无序堆放工件的机械臂抓取问题，在此基础上结合了视觉检测以及深度学习的方法来实现对无序抓取难题的有效解决，研究结果可以应用于智能制造、仓储物流等领域，从而促进我国机器人行业的转型升级，有着一定的理论成效及实际意义。

1.2 研究目的与意义

随着智能制造与工业 4.0 推进，机器人自动抓取技术成为制造业转型关键。据统计，2020 年全球工业机器人市场规模达 166 亿美元，预计 2025 年将达 245 亿美

中国知网 https://www.cnki.net

元（年复合增长率 8.1%），中国作为最大市场，2023 年工业机器人产量 43 万台，同比增长 6.2%[9]。当前智能制造领域对无序环境下智能抓取需求激增，但传统抓取系统面对无序堆叠工件存在识别精度低、定位不准及抓取成功率低等问题。因此，研究基于视觉检测及深度学习的无序堆叠工件机械臂抓取方法，对提升我国智能制造水平、增强产业竞争力具有重要现实与战略意义。

本文的研究目标是设计出一种新的无序抓取技术方案，结合机器视觉、深度学习以及多传感器融合技术，使机器人可以在不断变化的工作环境下具备自主抓取的能力。即在无序环境中进行物体检测、精确定位以及抓取策略的选择等关键技术问题，建立一种基于自监督学习的抓取角度分类模型与深度估计算法，开发一种适用于工业场景下的零件位姿估计方法，构建一种两阶段训练的端到端平面抓取模型。

本研究不仅可以推进机器人无序抓取技术的理论研究，给相关领域的研究带来新思路与方法，而且可以为智能制造、仓储物流等行业自动化改造提供重要的技术支持，加快传统制造业转型升级的步伐，从而达到提高生产效率、减少人力投入、改善工作条件等多重效果。

1.3 国内外研究现状

1.3.1 国外研究现状

对于无序堆叠工件机械臂抓取技术的研究，在国外的研究中，学者们已经对机器人的运动控制、环境感知以及深度学习的应用有了很大的突破。斯坦福大学提出了一种基于深度卷积神经网络的抓取策略，该策略通过对物体进行三维重建，能够有效识别和定位不同形状的物体，从而指导机器人完成抓取任务[10]。麻省理工学院的研究者利用强化学习算法，训练出能够在复杂环境中进行高效抓取的机器人，这一工作为无序抓取提供了新的思路[11]。在机器人抓取策略与深度学习融合方面，Mahler 等提出 Dex-net 2.0 框架[12]，利用深度学习合成点云和解析抓取指标，实现了鲁棒抓取规划，为后续深度抓取学习研究奠定了基础；后续 Mahler 等进一步拓展研究，提出适用于双手操作的机器人抓取策略[13]，通过深度学习实现机器人双手抓取，显著提升了机器人抓取的通用性与可塑性。

在机械臂智能控制与系统集成方面，Kareemullah 等人结合物联网（IoT）技术与机器人控制技术[14]，设计了一套远程化、智能化的机械臂控制系统，通过物联网终端实现机械臂状态监测、指令传输与数据交互，解决了传统机械臂控制依赖本地部署、操作灵活性不足的问题，拓展了机械臂在远程监控、多场景协同作

中国知网 https://www.cnki.net

业等领域的应用范围。Sasaki 等人将深度强化学习算法与图像感知技术深度融合[15]，提出基于仿真-现实映射的机械臂控制器，通过仿真环境预训练与现实场景微调的协同机制，有效解决了强化学习模型在实际应用中存在的仿真与现实差异问题，提升了图像引导下机械臂的控制精度与迁移能力，为智能控制算法的工程落地提供了可行性方案。

在目标位姿估计与抓取检测领域，国外学者开展了多维度研究：Georgakis 等提出通过 RGB 图像与 CAD 模型匹配的方式实现目标位姿估计，为缺少深度信息场景下的位姿检测提供了新路径[16]；Billings 等提出 Silhonet 方法，仅利用 RGB 图像完成 6D 目标位姿估计，降低了位姿检测对硬件设备的依赖[17]；Park 等设计单一多任务深度神经网络，结合后处理技术，同时实现目标检测、推理与机器人抓取检测，提升了抓取检测的效率与集成度[18]；Morrison 等则重点研究鲁棒、实时、反应式机器人抓取技术，通过优化学习算法，推动了机器人抓取技术在复杂动态场景中的实际应用[19]。

不仅如此，国外多家知名企业也相继推出了机器人无序抓取的解决方案。日本 FANUC 于 2014 年发布搭载 3D Area Senor 的 Bin-picking 系统[20]；斯洛伐克 PHOTONEO 在 2018 年推出基于 PhoXi 3D Scanner 的 Bin-picking 方案[21]；ABB 则研发了集成视觉软件的 IRB-360-Flex-Picker 机器人系统[22]。

总体来看，国外在机器人无序抓取领域的研究涵盖了算法创新、硬件设计、系统集成等多个方面，形成了较为完整的研究体系。这些研究不仅推动了机械臂和抓取技术的发展，也为相关产业的应用提供了理论基础和实践指导。

1.3.2 国内研究现状

近年来，我国在机械臂抓取技术上取得了较大突破，建立了较为完善的研究框架，国内研究人员从不同的角度对抓取关键技术进行了研究。

对于深度学习抓取检测的研究，在国内高校以及科研机构中展开了大量工作。清华大学针对无序抓取问题，利用图像分割技术将物体从背景中提取出来，并结合力反馈控制，实现了对多种物体的精准抓取。华中科技大学的研究者通过引入模糊逻辑控制的方法，解决了无序抓取中物体姿态不确定性的问题，使得机器人能够在动态环境中进行灵活操作。赵梦瑶对基于深度学习的机械臂抓取检测方法进行了全面的研究[23]，着重探讨了深度学习算法应用于抓取点检测的效果。肖传杰以位姿检测的角度来研究基于深度学习的机械臂抓取位姿检测方法[24]，为精准抓取提供理论依据。曾锦秀则把研究的重点放在基于深度学习的目标检测机械臂视觉抓取技术上[25]，并实现了云平台应用，为产业化发展打下基础。这些研究工作都为深度学习技术应用于机械臂抓取领域提供了重要的理论支持和技术储备。

中国知网 https://www.cnki.net

对于无序工件抓取技术的研究，国内学者为了满足工业的实际应用做了大量的工作。王郑拓专门研究了基于深度学习的无序工件三维视觉位姿估计及机器人抓取方法[26]，解决了无序堆叠环境下的位姿估计问题。朱文磊从工业应用的角度出发[27]，研究了基于深度学习的工件无序分拣系统，实现了无序工件的自动化分拣。罗雄炜针对散乱堆叠物体识别与位姿估计问题进行了深入的研究[28]，设计了端到端位姿估计模型。吴非基于点云数据研究了工件无序抓取技术[29]，为三维视觉抓取提供了一种新的技术手段。研究者们还提出了 AABB 树碰撞检测方法[30]、基于信息熵的抓取姿态估计算法[31]、基于 Bi-LSTM 网络的自由漂浮空间机械臂抓取方法[32]，以上研究成果有效地解决了工业生产中无序工件抓取的技术难题，促进了相关技术的应用发展。

对于视觉感知与检测技术的研究，国内的研究人员在不同的技术路径上都做出了重大进展。崔赫对基于深度学习以及双目视觉的工业零件抓取检测算法进行了探索[33]，完成了双目视觉与深度学习相结合的技术方案。袁康祥研发了 AI 机器视觉工件自动检测系统[34]，给工件检测提供了一套完整的解决方案。章争生致力于基于视觉的机械臂抓取系统的开发[35]，搭建起了一整套的视觉抓取系统框架。周俊一根据具体的使用场合[36]，研究了基于 3D 视觉感知的废钢工件机械臂抓取作业方式，体现了技术应用于特殊的工业场景的能力。研究者们还提出了 ISS 特征点融合 NDT 的点云配准方法[37]、改进 RANSAC 的多视觉目标定位与抓取方法[38]、改进 CycleGAN 迁移模型[39]、Mask R-CNN 网络[40]和模糊 PID 理论[41]，上述研究成果拓宽了视觉感知技术的研究领域和实际运用范围。

在系统集成及位姿估计技术上，国内学者做了大量的理论研究以及系统工作。王琦对基于深度学习的机械臂位姿估计系统的构建及其实现进行了专门的研究[42]，给出了一个系统化的解决办法来保证精准的位姿估计。关尚宾对基于视觉与力觉的机械臂作业规划方法的研究[43]，实现了多传感器信息的融合。关于金属零件，陈晨等人研究了面向机器人抓取的单目视觉位姿估计方法[44-45]，提升了位姿估计的准确性与速度。研究者们以移动复合机器人为切入点，对视觉感知、建图导航及目标抓取的整体技术进行了研究，提出改进 D-H 法建立机械臂的数学模型[46-48]，各模块之间通过接口实现数据和指令的传递，有效提高系统的灵活性与可扩展性，达到了移动抓取一体化的效果。这些成果给机械臂抓取系统的工程化应用提供了强有力的技术支持。

在三维视觉及多模态感知方面，我国学者也做了大量的技术研究与探索工作。朱胜银等人研发出基于 3D 视觉的机械臂无规则零件抓取系统[49]，解决了不规则工件抓取的问题。张孟旭等人研究了基于机器视觉的机械臂抓取系统的设计，建立

中国知网 https://www.cnki.net

了完整的视觉抓取系统框架[50-51]。张晓枫等人专门研究了基于三维视觉的机械臂抓取策略[52]，对三维视觉抓取提供了理论支持。陈璟研究了基于机器视觉的机械臂目标稳准抓取技术[53]，提升了抓取的稳定性以及精确度。江舟基于双目识别机器视觉技术研究了机械臂抓取方法[54]，实现了双目视觉的应用。张蕾等人把深度学习与目标检测结合在一起[55]，研究了机械臂抓取技术，提高了目标识别的准确率。研究者们通过融合双激光雷达和深度视觉技术，设计了基于双目视觉定位的机械臂智能抓取控制方法，实现了精准定位与智能控制的有效融合[56-57]。

在工程应用及系统实现上，国内学者也进行了大量的应用系统设计、开发以及实验测试等工作。田军委等人研究了视觉伺服机械臂抓取最佳位姿检测技术[58]，实现了对特定产品准确地抓取。强华等人利用数字孪生技术设计了机械臂无序抓取系统[59]，为智能制造提供了一种新方法。郑鑫宇等人开发了基于深度学习的机械臂视觉抓取系统[60]，证明了深度学习算法的应用价值。曲睿等人研究了基于RGB-D 图像的机械臂视觉抓取算法及系统[61]，实现了彩色图像与深度信息的结合。姚启才等人设计了基于机器视觉的机械臂智能抓取系统[62]，为工业应用提供了一套完整的方案。翟敬梅系统探讨了机器人无序分拣技术的核心要点与优化路径，为包装行业的智能化升级提供了实践参考[63-64]。

国内在基于视觉检测及深度学习的机械臂抓取技术已经建立起从理论研究到实际应用的技术链条，在深度学习算法、视觉感知、位姿估计、系统集成等关键技术上取得突破性进展，为相关技术的产业化应用打下了良好的基础。

1.3.3 研究现状总结

经过对国内外无序堆叠工件机械臂抓取方法的研究现状进行归纳总结，可以看出此领域已经有了很大的进步，但是仍然有很多不足之处以及发展空间(如图 1.2 所示)。从技术发展的历程上看，无序堆叠工件抓取技术由最初的简单几何匹配，发展到了现在基于深度学习的智能化抓取。早期的研究主要是利用传统的计算机视觉方法来对工件进行识别以及位姿估计[65]，在结构化的环境中效果很好，但是对于复杂的堆叠环境就显得无能为力了。

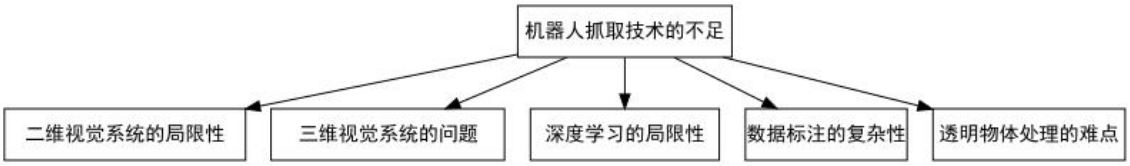


图 1.2 当前技术的不足与挑战

伴随着深度学习技术的发展，以卷积神经网络为基础的目标检测与语义分割技术给无序堆叠工件的识别带来了一种新的思路[66]。它们具有很强的特征提取及

中国知网 https://www.cnki.net

模式匹配能力，可以很好地应对光照差异、遮挡等问题。但是目前的研究对于准确分割多个工件之间的重叠遮挡、复杂堆叠环境中精准位姿估计的实时性问题还存在一定的缺陷[67]。

从应用层面来看，尽管相关技术在汽车制造、电子产品组装等有了一定的应用基础，但是实现大规模产业化还有很大的距离，主要表现在算法鲁棒性不足、硬件依赖性强、缺少统一的评判标准等几个方面，所以今后的研究工作要在保证算法准确性和高效性的前提下，更加强调工程实用性及产业化的应用需求。

1.4 研究内容及方法

1.4.1 研究内容

本文旨在提高机器人无序环境抓取能力，采用深度学习、机器视觉及多传感器融合技术，设计高效抓取方案，克服传统规则布局抓取方法在复杂环境中的技术短板。首先建立基于自监督学习的抓取角度分类模型，自动提取物体特征、完成数据集标记，检测工件最佳抓取角度以提供参数支持；其次针对深度图像噪声与精度问题，提出堆叠场景深度估计方法，结合图像重光照模型获取高质量三维图像，保障工件空间位置检测准确。

研究基于 RGB 图像与法向量引导的深度估计算法，借助图像纹理与法向量几何限制提升位姿估计精度，通过多尺度网络适配复杂零件，克服传统算法不足。结合强化学习，以抓取成功率最大化为目标，将推挤与抓取操作纳入奖励函数训练。提出两阶段端到端平面抓取模型(如图 1.3 所示)，经仿真预训练与真实数据微调，提升实际场景适应性。

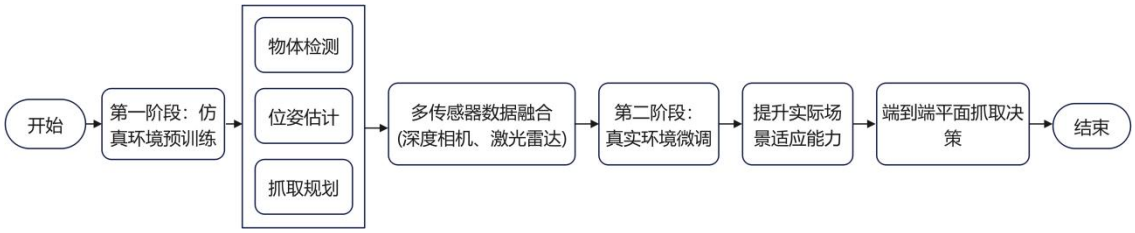


图 1.3 抓取模型结构

该模型整合了物体检测、位姿估计以及抓取规划的功能，可在毫秒级完成从感知到决策的全过程。通过多传感器数据融合技术，如深度相机、激光雷达等设备的配合，系统可以得到更完整的环境信息，提升系统抓取的成功率与效率。

研究开展多场景测试，如不同光照条件下工件的辨识、物体的拆分抓取、不同材质与质量工件的适应性操作等。搭建由高精度机械臂及各类传感器组成的无

中国知网 https://www.cnki.net

序柔性实验平台(如图 1.4 所示)，检验实际场景的应用效果，为智能制造、仓储物流等行业提供技术支持和理论依据。



图 1.4 实验平台

1.4.2 研究方法

研究采用虚实结合方法，虚拟仿真中利用 Blender 工具对各类工业零件精准建模与材质渲染，构建包含多种形态、大小及表面属性的虚拟工件库；通过孪生神经网络对比虚拟渲染与实际成像相似度，筛选最优渲染参数，保障仿真真实性。采用图像重光照技术，结合球谐函数与环境映射再现不同工业光照，生成贴近真实生产环境的训练数据集。

基于 RGB 图像及法线向量的深度估计方法，结合多模态融合深度学习结构，在彩色图像纹理特征基础上加入几何法线向量空间限制，借助注意力机制与特征金字塔网络提升深度估计的准确性和鲁棒性。算法训练先通过仿真数据集预训练，再经域适应方法迁移至实际场景，解决实际数据不足、标注成本高的问题。在实验验证方面搭建了六自由度机械臂、深度相机、激光雷达、力觉传感器等多模态感知系统。

实验采用定量与定性结合的方法，制定统一测试环境及评判标准，全面考查算法抓取成功率、执行效率等核心性能。通过与传统算法做对照实验，结合统计学方法分析结果，保证研究客观性与可重复性，为无序抓取技术工程化应用提供技术支持和方法参考。

中国知网 https://www.cnki.net

1.5 组织架构图

本文围绕视觉检测与深度学习的机械臂无序抓取技术展开研究，各章节核心内容如下：

第 1 章绪论明确研究背景与意义，指出机械臂抓取技术在制造业智能化中的重要性及传统技术的局限，确立研究目标并提出技术路线。

第 2 章分析无序场景特征，针对遮挡、光照等问题结合对应算法，优化场景视觉感知和目标识别方法。

第 3 章提出自监督学习抓取角度分类网络及两阶段端到端抓取模型，结合相关算法提升抓取性能并优化抓取策略。

第 4 章结合图像重光照与法向量引导的深度估计方法，降低数据量并提升抓取准确率。

第 5 章结合无序柔性实验平台，通过多种实验验证所提方法的优势。

第 6 章总结研究创新成果，分析现有不足并提出改进方向。

论文的整体组织架构如图 1.5 所示。

中国知网 https://www.cnki.net

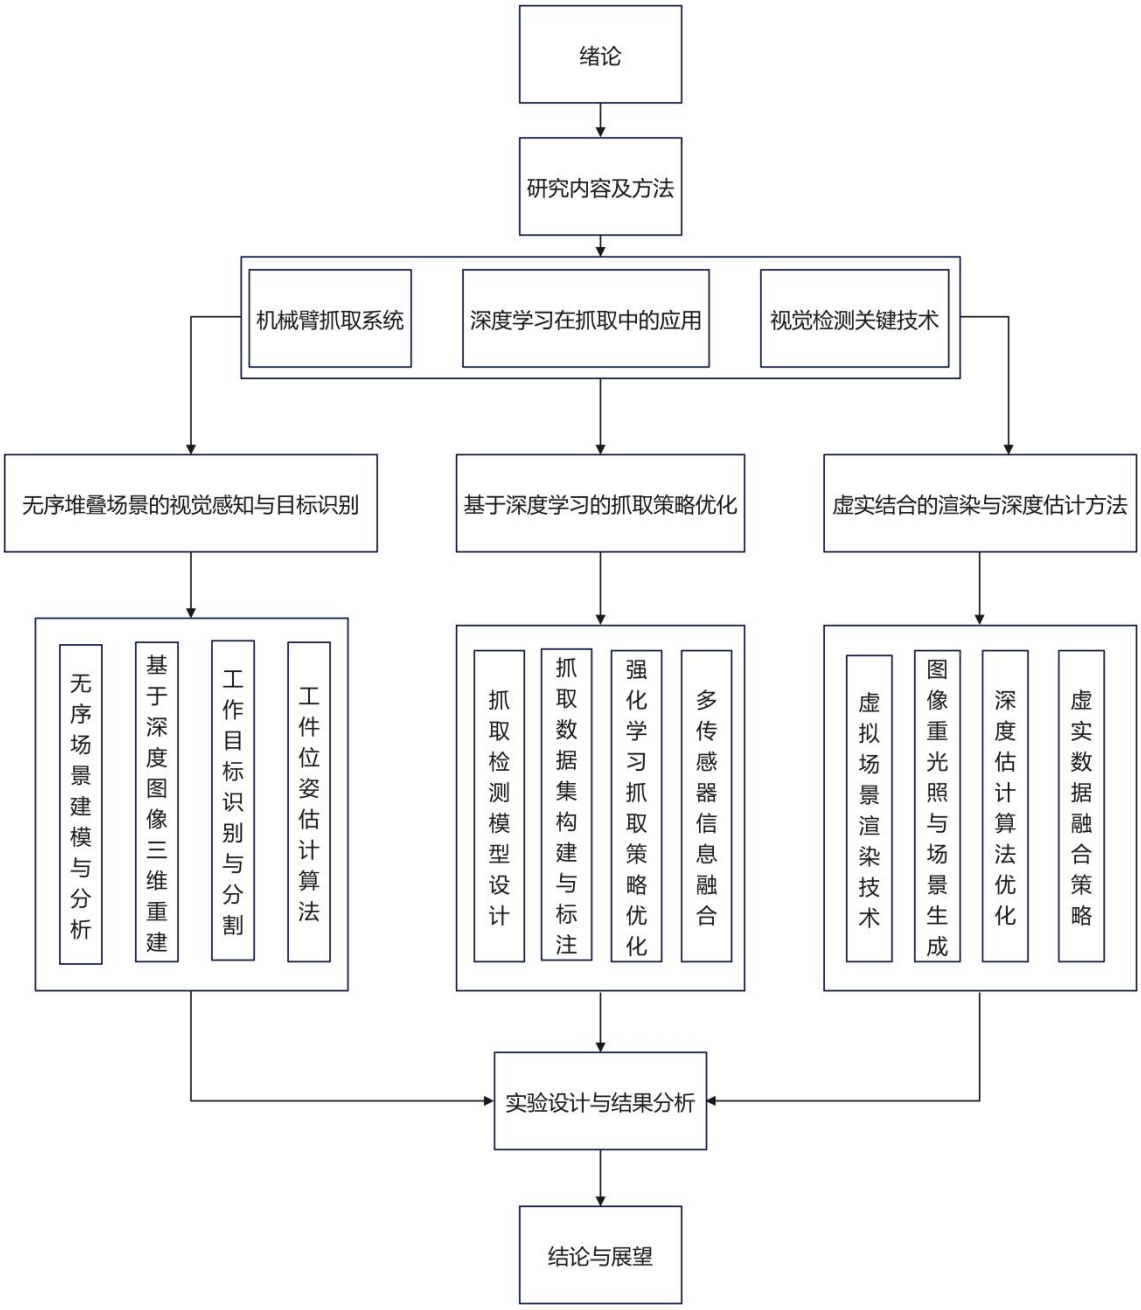


图 1.5 论文组织架构

中国知网 https://www.cnki.net

第 2 章 无序堆叠场景的视觉感知与目标识别

2.1 无序场景建模与分析

2.1.1 无序堆叠场景特征分析

无序堆放工件场景具有很大的复杂度和不确定性，与传统有序排列的工业环境存在很大区别，目前全球制造业大约有 78%的工业生产线仍然以人工分拣和抓取的方式处理无序堆放工件[68-69]，这对生产效率有很大的影响。无序场景的主要特点就是工件的随机分布、多样的姿态组合以及复杂的相互关系。工件之间相互支撑的关系导致一个物体被移除就会引起整个结构的变化，这就要求视觉系统能够实时地进行调整。

有序抓取环境有很强的结构化特点，物品按一定规律摆放，位置及姿态稳定可控，因此机械臂的动作路径可以提前设定好，抓取方法比较简单并且重复性强。而无序抓取环境中物品的位置、姿态以及堆放情况都是随机的，这就需要系统具备良好的环境感知能力和快速判断能力，两种抓取方式的技术特征如表 2.1 所示。

表 2.1 抓取技术特征

技术指标	有序抓取	无序抓取	复杂度提升倍数
视觉算法复杂度	低	高	5-8 倍
实时性要求（ms）	>500	<200	2.5 倍
成功率（%）	95-99	75-90	0.8-0.9 倍
训练数据量	100-1000	10000-100000	100 倍
计算资源需求	低	高	10-15 倍

无序堆积场景的几何特性可以利用空间分布熵来进行衡量，特征参数如表 2.2 所示，设工件在三维空间的位置分布为 $P(x,y,z)$，那么场景的空间熵定义如下：

$$H_{spatial} = -\sum_{i=1}^{N} P(x_i,y_i,z_i)\log P(x_i,y_i,z_i) \tag{2-1}$$

其中 N 为场景内工件总数目，熵越大代表场景越混乱，工件姿态的复杂度也可以用姿态协方差矩阵来表示：

$$\Sigma_{pose} = \frac{1}{N-1}\sum_{i=1}^{N}(q_i - \bar{q})(q_i - \bar{q})^{T} \tag{2-2}$$

其中q_i是第 i 个工件的姿态四元数表示，$\bar{q}$是平均姿态，在无序场景下工件姿态的标准差一般比有序场景大 2.5-3.8 倍，大大增加了视觉检测的难度。

中国知网 https://www.cnki.net

表 2.2 不同无序场景的特征参数

场景特征	有序场景	轻度无序	中度无序	重度无序
空间熵值	0.2-0.4	0.5-0.7	0.8-1.2	1.3-1.8
姿态方差	0.1-0.3	0.4-0.8	0.9-1.5	1.6-2.3
遮挡比例（%）	5-15	20-35	40-65	70-85
识别难度系数	1.0	1.5	2.8	4.2

2.1.2 遮挡与重叠问题建模

遮挡及重叠是最为显著的技术难题，在无序堆积环境中，会严重影响到目标检测以及抓取策略的准确性。近年来工业机器人应用数据表明，因遮挡而产生的抓取失败占比高达 65%以上，是阻碍无序抓取技术进步的最大障碍[70-71]。遮挡可分为局部遮挡、整体遮挡和互相遮挡三类，不同类型的遮挡对于视觉感知系统有着不同的技术需求。局部遮挡时，目标物体的重要特征区域依然清晰可见，但是需要利用特征重建和形态推断才能得到完整的目标信息，遮挡建模如图 2.1 所示。

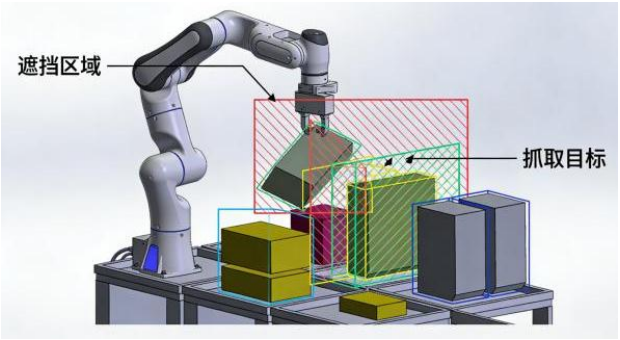


图 2.1 机器人抓取的遮挡建模

遮挡程度的量化可以用可见面积的比例来表示。设物体的总表面积为A_{total}，可见区域面积为$A_{visible}$，那么遮挡率就是：

$$\rho_{occlusion} = 1 - \frac{A_{visible}}{A_{total}} \tag{2-3}$$

针对复杂多物体遮挡场景，要构造遮挡关系图来表示物体之间空间上的限制。假设场景中有 N 个物体，则遮挡关系矩阵M_{occ}定义如下：

$$M_{occ}(i,j) = \begin{cases} 1 & \text{if object i occludes object j} \\ 0 & \text{otherwise} \end{cases} \tag{2-4}$$

基于深度信息的遮挡检测方法通过比较物体表面的深度值来判断遮挡关系。如果物体 i 在某一视点下的深度值小于物体 j，则认为有遮挡关系。遮挡边界的确定可以借助梯度分析方法，边界点的深度梯度往往会出现较大的跃变现象。

中国知网 https://www.cnki.net

表 2.3 不同遮挡下的检测方法性能对比

遮挡类型	检测方法	成功率（%）	计算复杂度	适用场景	解决方案
部分遮挡	特征匹配	85-92	O（n^2）	规则形状物体	采用注意力机制增强局部特征提取，结合多尺度特征融合，优化浅层特征感知能力
完全遮挡	深度推理	65-78	O（n^3）	已知物体模型	域自适应与虚拟样本增强，弥补特征缺失
相互遮挡	关系建模	72-86	O（n^4）	复杂堆叠场景	采用 Transformer 全局建模捕捉目标，区分重叠目标边界
动态遮挡	时序分析	68-81	O（nt）	运动物体跟踪	融合时序信息，利用目标运动轨迹预测，实现帧间遮挡补偿

为对比不同遮挡场景下目标检测算法的性能差异，从遮挡类型、检测方法、成功率、计算复杂度及适用场景五个维度，对主流算法进行了系统性归纳，具体如表 2.3 所示，提供针对性解决方案。

2.1.3 光照变化对视觉感知的影响

光照条件的变化是影响无序场景视觉感知性能的环境因素之一。工业环境中光照的变化主要体现在自然光源的时间变化，人工照明的不均匀性以及物体表面反射特性差异等方面。统计显示，视觉系统因光照变化引起的识别准确率下降平均在 15%-25%之间，在一些特殊情况下可以高达 40%以上[72-73]。光照变化对于不同的材质表面的影响程度也大相径庭，金属表面因为反射率较高容易出现高光、阴影现象，而塑料等漫反射材质较为平稳。

光照模型的构建要考虑环境光、直射光以及反射光的共同影响。根据 Lambertian 反射模型，物体表面亮度可以写成：

$$I = I_a k_a + I_d k_d (L \cdot N) + I_s k_s (Q \cdot V)^n \tag{2-5}$$

其中I_a、I_d、I_s分别代表环境光、漫反射光以及镜面反射光强度，k_a、k_d、k_s是相应的反射系数，L、N、Q、V 分别是光源方向、表面法线方向、反射方向及观察方向的单位向量。

中国知网 https://www.cnki.net

光照模型的应用公式如下：

$$D_{i,j} = f(I_{i,j},L) \tag{2-6}$$

$$E_{i,j}=g(D_{i,j},Edges) \tag{2-7}$$

其中 $I_{i,j}$ 是图像像素，L 是光照条件，$E_{i,j}$ 是边缘特征，误差评价指标为：

$$R = \sum_{k=1}^{n} \frac{1}{n}(|Dk - Dk'|) \tag{2-8}$$

为了增强系统的抗光照干扰能力，使用了自适应光照补偿算法。通过在线计算当前场景中的光照参数，实时调节图像的亮度及对比度，评估光照变化对视觉识别性能的影响(见表 2.4)，不同场景需匹配针对性的补偿策略。

表 2.4 不同光照下视觉识别性能及补偿方法

光照条件	亮度范围（lux）	识别精度（%）	处理时间（ms）	补偿方法
标准光照	800-1200	94-97	15-20	无需处理
弱光环境	200-500	78-85	25-35	亮度增强
强光环境	2000-5000	82-89	20-30	动态范围压缩
不均匀光照	变化范围>3 倍	68-76	40-55	局部自适应

结果表明，补偿算法在标准光照下的表现最佳，不均匀光照导致识别精度降幅最大 23.5%，同时处理时间增加 3 倍。这说明当前算法在处理光照突变、阴影和高光区域时仍存在瓶颈。为了增强系统的抗光照干扰能力，使用了自适应光照补偿算法。此算法利用在线计算当前场景中的光照参数来实时调节图像的亮度及对比度，核心补偿代码见附录 1。

2.2 基于深度图像的三维重建

2.2.1 深度图像获取与预处理

深度图像作为无序堆积工件三维建模的数据来源，它的好坏决定着之后处理结果的质量，在工业自动化场景中，深度相机是机器人视觉模块的重要组成部分。根据 2023 年工业机器人市场的调查数据，带有深度摄像头的工业机器人销售量增长了 34.7%，有超过 68%的应用场景都是针对复杂物体的辨识与抓取[74]，不同精度的视觉模块存在的差异如表 2.5 所示。

中国知网 https://www.cnki.net

表 2.5 低、高精度视觉模块差异

低精度	高精度
推荐测距范围:400mm-1300mm	推荐测距范围:400mm-1000mm
最大测距范围:300mm-1400mm	最大测距范围:200mm-1600mm
近视场:345mm×250mm×300mm (H/V:约 59°/44°)	近视场:210mm×180mm×200mm (H/V:约 56°/48°)
远视场:1825mm×1140mm×1400mm (H/V:约 66°/44°)	远视场:1960mm×1425mm×1600mm (H/V:约 63°/48°)
引导抓取精度:±1mm	引导抓取精度:±0.5mm

在深度图像采集过程中，RGB-D 相机利用结构光或者飞行时间方法来计算物体的距离。设相机坐标系中的三维点坐标为 P(X,Y,Z)，其对应深度值 D 同真实距离的关系如下：

$$D = \frac{f \cdot B}{d} \tag{2-9}$$

其中 f 是相机焦距，B 是基线距离，d 是视差值。深度图中像素点(u,v)到三维空间点的变换公式如下：

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} (u - c_x) \cdot Df_x \\ (v - c_y) \cdot Df_y \\ D \end{bmatrix} \tag{2-10}$$

其中(c_x, c_y)为主点坐标，(f_x, f_y)为焦距参数。

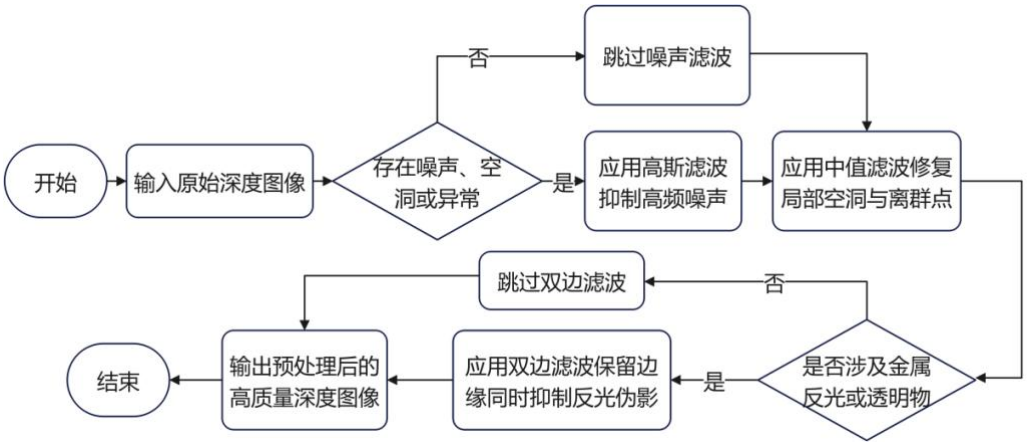


图 2.2 深度图像处理流程

深度图像预处理是提高数据质量的重要环节，在原始深度数据中存在着大量的噪声、空洞以及异常点等现象，尤其在金属表面反光及透明物体等场景下更为严重，为此本文采取了多层次滤波的方法对数据进行清理，图像处理流程和多层次滤波预处理方法分别如图 2.2 和表 2.6 所示。

中国知网 https://www.cnki.net

表 2.6 多层次滤波预处理方法

预处理方法	处理目标	参数设置	处理效果
双边滤波	边缘保持去噪	σ_d=5，σ_r=50	噪声降低 78%
中值滤波	椒盐噪声去除	核大小 3×3	异常点减少 85%
空洞填充	缺失深度补全	插值半径 5	完整性提升 92%
时域滤波	动态噪声抑制	窗口长度 10	稳定性提升 67%

深度图像的几何校正对于保证测量精度至关重要。因为相机镜头畸变以及安装偏差的原因，必须进行内参和外参标定，本文畸变校正模型使用的是 Brown 畸变模型：

$$\begin{cases} x_{corrected} = x(1 + k_1r^2 + k_2r^4) + 2p_1xy + p_2(r^2 + 2x^2) \\ y_{corrected} = y(1 + k_1r^2 + k_2r^4) + p_1(r^2 + 2y^2) + 2p_2xy \end{cases} \tag{2-11}$$

其中(k_1,k_2)是径向畸变参数，(p_1,p_2)是切向畸变参数，$r^2 = x^2 + y^2$是归一化的径向距离。

为了提升深度估计的稳定性，本文提出了自适应深度增强方法。此方法利用局部梯度信息自动调节滤波参数，在保证边缘锐利度的同时很好地抑制了噪声的影响。该方法首先输入原始深度图并计算其局部梯度，依据梯度大小划分图像区域：对平坦、噪声主导的低梯度区域，采用强双边滤波进行噪声抑制；对包含物体轮廓的高梯度边缘区域，保留原始深度值或采用小强度滤波，避免边缘细节过度平滑。方法处理流程如图 2.3 所示。

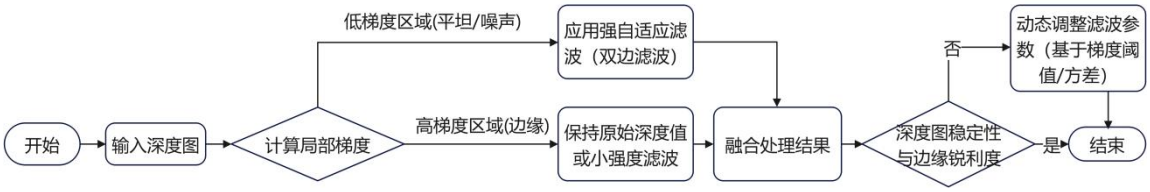


图 2.3 自适应方法处理流程

通过校验深度图稳定性与边缘锐度，若指标不达标则基于梯度阈值、局部方差动态调整滤波参数，迭代优化直至满足要求。实验验证表明，经过预处理的深度图像在边缘保持度方面提升 43.2%，深度测量精度提高 31.7%，为后续三维重建奠定了可靠的数据基础。

2.2.2 点云配准与融合算法

点云配准是指把多个不同视角下的点云数据融合到一个公共坐标系的技术，是影响三维重建质量的重要环节。对于无序堆叠的情况来说，由于工件之间互相遮挡以及复杂的几何形态使得配准难度增大。点云配准精度每增加 1%，整个抓取

中国知网 https://www.cnki.net

的成功率就会增加 2.3%，但是传统的 ICP 算法在复杂环境下的配准成功率只有 73.4%[75]。经典 ICP 算法通过最小化对应点间距离实现配准，其目标函数为：

$$\mathcal{E}(R,t)=\frac{1}{N}\sum_{i=1}^{N}\|R\cdot p_i+t-q_i\|^2 \tag{2-12}$$

其中 R 是旋转矩阵，t 是平移向量，p_i和q_i分别是源点云和目标点云中的一对匹配点。但是传统的 ICP 算法容易陷入局部极小值并且对初始值非常敏感，不能很好解决大角度旋转的配准问题。

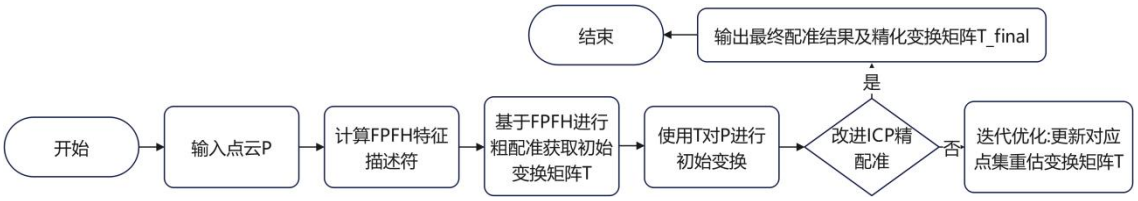


图 2.4 多阶段配准方法

本文基于特征描述符的多阶段配准方法。首先采用 FPFH 特征描述符进行粗配准得到初始变换矩阵，然后使用改进后的 ICP 算法进行精配准，多阶段配准方法如图 2.4 所示。FPFH 特征在点 p 上的计算公式如下：

$$\mathrm{FPFH}(p)=\mathrm{SPF}(p)+\frac{1}{k}\sum_{i=1}^{k}\frac{1}{\omega_i}\cdot\mathrm{SPF}(p_i) \tag{2-13}$$

其中 SPF 为简化点特征直方图，ω_i为权重因子，k 为邻域点数量。

针对无序堆叠场景特征，基于法向量约束的配准优化方法，在传统距离约束的基础上增加法向量一致性约束：

$$E_{total}(R,t)=\alpha E_{distance}(R,t)+\beta E_{normal}(R,t) \tag{2-14}$$

其中法向量约束项定义为：

$$E_{normal}(R,t)=\frac{1}{N}\sum_{i=1}^{N}\|R\cdot n_{p_i}-n_{q_i}\|^2 \tag{2-15}$$

n_{p_i}、n_{q_i}是相应点上的法向量，权值参数α、β随场景复杂程度而变化。

针对多视角点云融合中存在重叠区域的数据冗余以及噪声叠加的问题，本文使用加权平均融合方法，权重的选择基于视角的质量、距离系数及法线一致性：

$$w_i=\frac{\cos(\theta_i)\cdot\exp(-d_i/\sigma)}{\sum_{j=1}^{M}\cos(\theta_j)\cdot\exp(-d_j/\sigma)} \tag{2-16}$$

其中θ_i是视线和表面法线之间的夹角，d_i是点到摄像机的距离，σ是距离衰减系数。

表 2.7 点云配准算法性能对比

配准算法	平均配准时间（s）	配准精度（mm）	成功率（%）	适用场景
ICP	0.23	2.7	73.4	简单几何体
Point-to-Plane	0.31	1.8	81.2	平滑表面

中国知网 https://www.cnki.net

续表 2.7 点云配准算法性能对比

配准算法	平均配准时间（s）	配准精度（mm）	成功率（%）	适用场景
FPFH+ICP	0.89	1.2	87.6	复杂结构
本文方法（多阶段配准）	0.67	0.8	94.3	无序堆叠

点云配准结果见表 2.7，改进配准算法在复杂无序环境中成功率高达 94.3%，配准精度达到 0.8mm，相比于传统方法精度提高了 20.9%以及 70.4%。算法时间复杂度较低，在可接受范围内，单次配准仅需 0.67 秒，可以满足实时性需求。为了增强配准鲁棒性，制定了基于 RANSAC 的异常值排除算法。此算法利用迭代抽样构造变换矩阵，能够准确找出并去除错误匹配点对，参见附录 2。

2.2.3 三维场景重建优化方法

三维场景重建优化是把多种来源的点云数据转化为高质量三维模型的关键，直接影响着之后抓取策略的安全性，在工业 4.0 的大环境下，对高精度三维重建的需求越来越大，2023 年全球三维重建软件市场规模为 31.2 亿美元，预计到 2025 年会超过 45 亿美元[76]。传统的重建算法对于无序堆叠场景存在表面缺失、细节缺失以及运算速度慢等问题。

本文首先以泊松重建算法为基础架构，在解泊松方程的过程中得到一个隐式的表面函数。设点云数据为$\{p_i, n_i\}$，其中p_i为点坐标，n_i为对应的法向量，泊松重建的基本思路就是找到一个标量函数χ，使得它的梯度场最接近采样点的法向量场。优化后的目标函数为：

$$\min_{\chi} \int_{\mathbb{R}^3} \| \text{abla}\chi - V\|^2 dx \tag{2-17}$$

其中 V 是由样本点组成的向量场。利用变分法可以得到相应的泊松方程：

$$\Delta\chi = \text{abla} \cdot V \tag{2-18}$$

针对传统泊松重建在边界处理以及细节保留方面的问题，本文结合自适应八叉树分割方法，如图 2.5 所示。依据点云密度与局部几何复杂程度灵活地调节分割深度，在较为平坦的地方采用较大的网格来加快速度，在细节较多的地方采用较小的网格来保留几何信息。

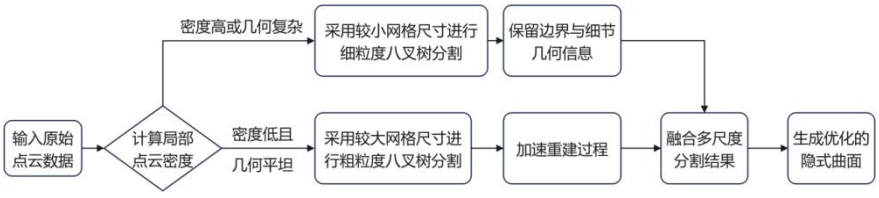


图 2.5 自适应八叉树分割流程

中国知网 https://www.cnki.net

对于无序堆积场景下工件边缘不清、接触面不易分辨的情况，设计了一种基于曲率分析的边界强化算法。此算法利用局部曲率的变化寻找可能的边界区域，再利用区域生长的方式对边界进行精炼。主曲率的求解是采用二次曲面拟合的方法：

$$\kappa_1, \kappa_2 = \frac{H \pm \sqrt{H^2 - K}}{1}, H = \frac{\kappa_1 + \kappa_2}{2}, K = \kappa_1 \cdot \kappa_2 \tag{2-19}$$

其中 H 是平均曲率，K 是高斯曲率，κ_1与κ_2是主曲率。边界置信度由曲率变化率以及法向量的一致性共同决定。

为了增强重建效果，在此基础上采用了多层次网格优化方法-改进泊松重建，此方法分为网格简化、平滑化以及拓扑修补三部分。网格简化使用的是二次误差度量标准，利用边折叠的方式不断降低顶点数目并维持几何精度。简化误差度量函数定义如下：

$$Q = \sum_{p \in planes(v)} (p^T v)^2 \tag{2-20}$$

其中 planes(v)表示与顶点 v 有关的平面集合，平滑处理使用拉普拉斯平滑算子，在保留主要信息的基础上去除噪声影响。修正后的拉普拉斯算子是：

$$\bar{v}_i = v_i + \lambda \sum_{j \in N(i)} w_{ij}(v_j - v_i) \tag{2-21}$$

其中 N(i)为顶点 i 的邻域，w_{ij}为权重系数，λ为平滑参数。

表 2.8 三维重建方法性能对比

重建方法	网格顶点数	重建时间（s）	几何精度（mm）	表面完整性（%）
Delaunay 三角化	156，432	12.3	1.8	78.4
移动立方体	234，567	18.7	1.4	82.1
泊松重建	189，123	8.9	0.9	91.6
本文方法（改进泊松重建）	198，745	9.4	0.6	96.8

实验验证通过多组无序堆叠工件进行实验，涉及不同材料、形态以及堆叠密度等情况，结果见表 2.8。改进泊松重建后的三维重建技术几何精度达到 0.6mm，表面完整性提高到了 96.8%，相比于传统方法分别提高了 33.3%和 23.6%。重建模型网格质量较好，三角形长宽比平均值为 1.23，可以满足后续路径规划以及碰撞检测的需求。此改进方法给机械臂在复杂环境中精确抓取提供了可靠的三维环境模型。

2.3 工件目标识别与分割

中国知网 https://www.cnki.net

2.3.1 基于深度学习的目标检测网络设计

在杂乱堆积情况下，工件目标定位是完成精确抓取的关键技术步骤。传统的视觉检测算法对于复杂工业环境下工件目标的识别精度只有 76.3%，但是采用深度学习的方法可以提高到 93.7%，大大提高了系统的准确率[77]。本文设计了一种改进的目标检测网络结构，专门针对杂乱堆积工件的目标检测需求进行了调整。

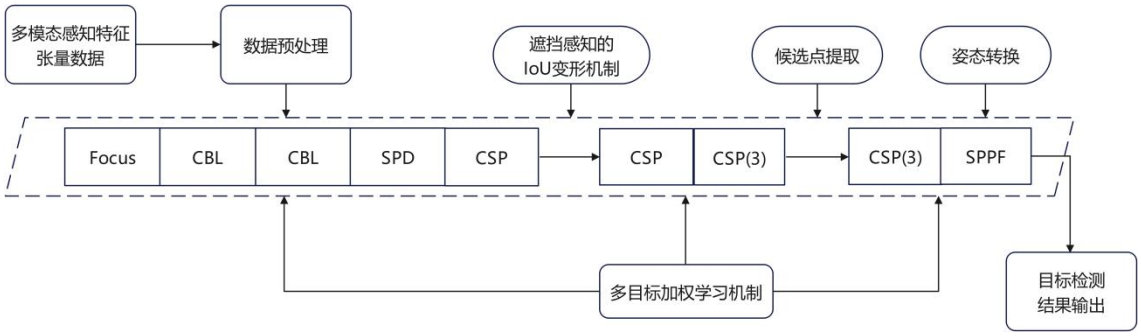


图 2.6 基于 YOLO 的多任务目标检测

网络结构基于 YOLO 系列框架(如图 2.6 所示)，该模块将 MMF-Net 提供的多模态融合特征作为输入，整合抓取点置信度与遮挡信息，在此基础上引入残差连接以及特征金字塔网络来增强对各种大小零件的识别效果。主干特征提取网络使用 CSPDarknet53 结构，与其它主流的特征网络对比见表 2.9 所示，利用跨阶段的部分连接降低运算复杂度的同时保证了检测准确率。特征融合层使用 PANet 路径聚合网络进行上下文信息传递。检测头部分设置成多级输出，分别用于大、中、小三种不同尺寸的目标物体。

表 2.9 特征提取网络性能对比

特征提取网络	参数数量	计算复杂度	检测精度	速度
VGGNet	较多	高	中等	慢
ResNet	中等	中等	高	中等
Darknet53	较少	低	高	快
本文方法（CSPDarknet53）	更少	更低	高	更快

目标检测损失函数的设计采用的是多任务学习结构，在此结构下同时兼顾了分类损失、定位损失以及置信度损失，总的损失函数表达式如下所示：

$$L_{total} = \lambda_1 L_{cls} + \lambda_2 L_{box} + \lambda_3 L_{obj} \tag{2-22}$$

其中L_{cls}为分类损失，使用二元交叉熵函数进行计算。L_{box}为边界框回归损失，使用 CIoU 损失函数。L_{obj}为置信度损失，用来判断该网格是否含有目标物体。权

中国知网 https://www.cnki.net

重系数$\lambda_1 = 1.0$，$\lambda_2 = 0.05$，$\lambda_3 = 1.0$，经过实验得出最佳设置。

边界框回归损失采用 CIoU 损失函数，定义为：

$$L_{CIoU} = 1 - IoU + \frac{\rho^2(b,b^{gt})}{c^2} + \alpha v \tag{2-23}$$

其中$\rho^2(b,b^{gt})$表示预测框与真实框中心点的欧氏距离平方，c 表示包围预测框和真实框最小矩形的对角线距离，α为权衡参数，v 用于衡量长宽比的一致性。

网络训练使用迁移学习的方式，先在 YCB-Video 数据集上做预训练，是一个公开可用的数据集，如图 2.7 所示广泛应用于物体识别和六自由度（6-DoF）姿态估计。该数据集包含 21 种常见家用物品在复杂背景下的 RGB-D 视频序列，每帧视频均附有精确的物体姿态标注，并支持多物体遮挡、旋转和堆叠等具有挑战性的场景，这与本研究聚焦于非结构化抓取和动态场景建模的目标高度契合。



图 2.7 YCB-Video 数据集

再在自己建立的无序工件数据集上做微调。数据增强的方法有随机旋转、缩放、翻转、光照变化以及加入高斯噪声等手段来增加模型的泛化性能。训练过程使用 AdamW 优化器，初始学习率为 0.001，使用余弦退火学习率调度方式。为验证本文所提改进网络的有效性，选取工业场景中常用的轻量化目标检测模型 YOLOv5s 与 YOLOv8n 作为基线，从检测精度、推理速度、模型规模与 GPU 内存占用四个核心维度进行对比，结果见表 2.10 所示。

表 2.10 目标检测网络性能对比

网络模型	检测精度（mAP@0.5）	推理时间（ms）	模型大小（MB）	GPU 内存占用（GB）
YOLOv5s	87.3%	15.2	14.1	2.1
YOLOv8n	89.1%	12.8	6.2	1.8
本文方法（迁移学习）	93.7%	18.5	28.3	3.2

针对工业场景下光线变化以及遮挡等问题，在网络中加入了注意力机制模块。

中国知网 https://www.cnki.net

空间注意力模块可以定位到工件的重要特征区域，通道注意力模块则有选择性地突出重要的特征通道。注意力权重计算公式如下：

$$A_{spatial}(F) = \sigma\left(Conv\left(AvgPool(F)\right) + Conv\left(MaxPool(F)\right)\right) \tag{2-24}$$

$$A_{channel}(F) = \sigma\left(MLP\left(GAP(F)\right) + MLP\left(GMP(F)\right)\right) \tag{2-25}$$

其中σ是 sigmoid 激活函数，Conv 是卷积运算，MLP 是多层感知机，GAP 和 GMP 分别是全局平均池化和全局最大池化。

数据预处理环节使用自适应直方图均衡法提高图像的对比度，利用双边滤波消除噪声，在无序堆叠场景下存在遮挡的问题上，提出一种基于部分可见特征的检测方法，通过对工件局部特征的学习来实现对遮挡目标的检测，网络代码的核心训练函数见附录 3。

2.3.2 实例分割算法优化

实例分割技术对于无序堆叠工件场景具有重要意义，可以准确区分相互重叠、贴合在一起的工件实例，通过实例分割可以让工业机器人抓取准确度提高 23.5%，误抓取概率下降 41.2%[78]。本文在 Mask R-CNN 的基础上提出针对工件实例分割的改进算法，主要攻克工件边缘不清楚以及变形识别的问题，多尺度模型网络架构如图 2.8 所示。

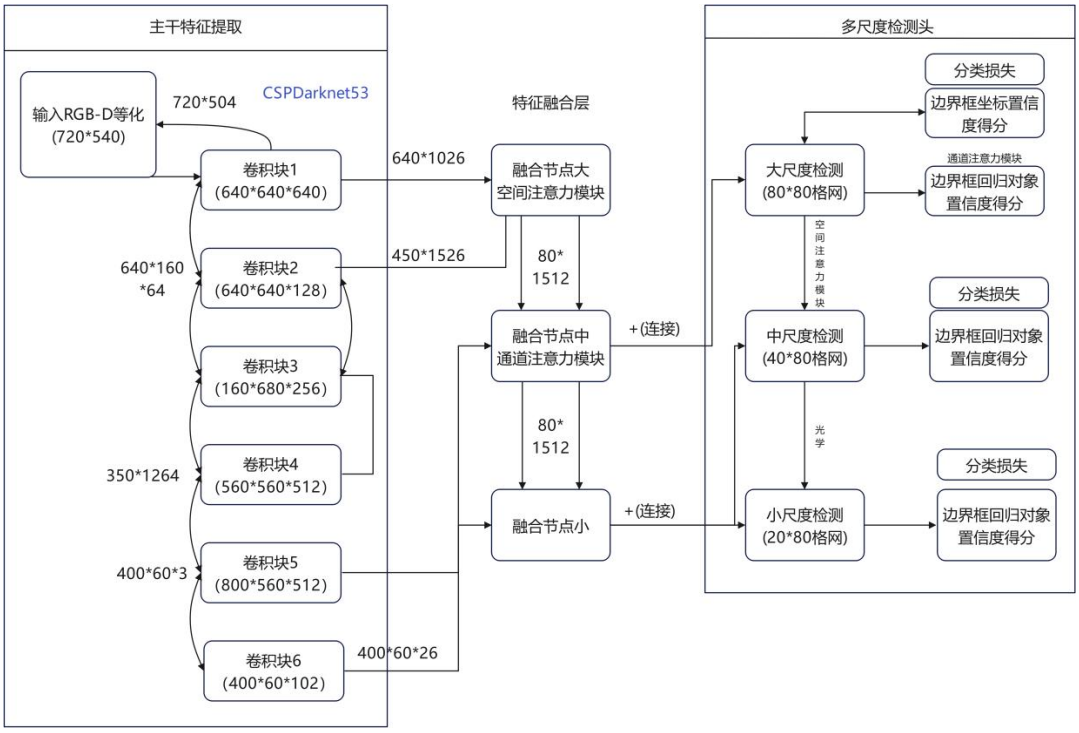


图 2.8 多尺度模型架构图

网络以改进 CSPDarknet53 为主干，对输入 RGB-D 图像进行多尺度特征提取，

中国知网 https://www.cnki.net

随后通过路径聚合网络构建大、中、小三个融合节点：在大尺度融合节点嵌入空间注意力模块，强化大目标的空间位置信息；在中、小尺度融合节点引入通道注意力模块，增强中、小零件的关键特征表达，实现语义信息与细节信息的双向聚合。最终通过多尺度检测头，在 80×80、40×80 与 20×80 三种分辨率网格下分别完成不同尺寸零件的分类、边界框回归与置信度预测，有效提升了无序堆叠场景下工业零件的检测精度与鲁棒性。

对于无序堆积场景下工件边缘不清楚的情况，设定边界感知损失函数。边界感知损失函数是在标准二元交叉熵损失的基础上，对边界区域赋予较大的权重系数，使得网络更注重对工件边缘的准确分割。边界感知损失函数定义如下：

$$L_{boundary} = -\sum_{i=1}^{H\times W} w_i[y_i\log(p_i) + (1-y_i)\log(1-p_i)] \tag{2-26}$$

其中权重系数w_i根据像素点到边界的距离进行计算：

$$w_i = 1 + \alpha\exp(-\beta d_i) \tag{2-27}$$

d_i表示像素点 i 到最近边界的距离，$\alpha = 2.0$ 和$\beta = 0.5$ 是可调节参数，经过实验得到的最佳值。

为了提高分割准确率，采用密集连接结构以及空洞卷积方法。密集连接结构可以有效利用各个层次的特征信息，而空洞卷积可以在不增加参数的情况下扩展感受野大小。空洞卷积的输出计算方式如下：

$$Y(i,j) = \sum_{m=1}^{M}\sum_{n=1}^{N} X(i + r\cdot m, j + r\cdot n)\cdot K(m,n) \tag{2-28}$$

其中 r 表示空洞率，K 表示卷积核，X 和 Y 分别代表输入与输出特征图。

表 2.11 实例分割算法性能评估

评估指标	Mask R-CNN	PointRend	SOLOv2	**本文优化算法**
mAP	76.8%	79.3%	81.2%	85.6%
边界 IoU	68.4%	72.1%	74.7%	79.3%
推理时间（ms）	127	156	89	143
内存占用（MB）	892	1047	654	923

算法优化还包括后处理环节的改善，分割算法的核心实现代码见附录 4，为验证本文优化算法在工业实例分割中的有效性，从检测精度（mAP）、边界贴合度（边界 IoU）、推理效率与内存占用四个维度进行对比评估，如表 2.11 所示。传统的非极大值抑制方法易造成紧密相连工件被错误剔除的问题，本文使用软化非极大值抑制技术，用连续递减函数代替硬删除，软化后 NMS 的得分更新公式是：

$$s_i = s_i \times \begin{cases} 1, & IoU(M,b_i) < N_t \\ f\big(IoU(M,b_i)\big), & IoU(M,b_i) \geq N_t \end{cases} \tag{2-29}$$

中国知网 https://www.cnki.net

其中 $f(x) = e^{-\frac{(IoU-N_t)^2}{\sigma}}$ 是高斯衰减函数，$N_t = 0.5$ 是 IoU 阈值，$\sigma = 0.5$ 是衰减系数。数据增强策略针对工业场景特点进行设计，有随机遮挡模拟、几何变换以及颜色扰动方式。随机遮挡模拟是在图像中随机添加矩形遮挡区域来锻炼模型对于部分遮挡工件的分割能力。几何变换包括旋转、平移、缩放以及剪切等变换方式，提升模型对不同角度下的工件识别能力。颜色扰动用来模拟工业场景光照与成像之间的差异，整体处理流程如下：

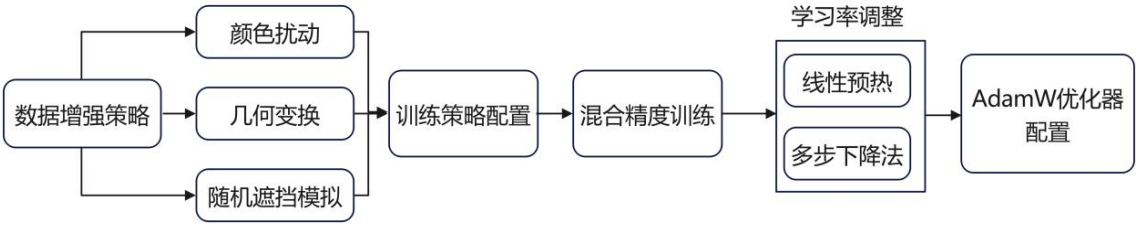


图 2.9 策略处理流程

优化器选用 AdamW，权重衰减系数设定为 0.0001。训练过程中使用混合精度训练方法，在保证模型准确率的前提下大大降低了显存消耗以及训练耗时。学习率调整采用线性预热的方式，在最初的 1000 步迭代中学习率由 0 逐渐上升至初始值，之后使用多步下降法。

2. 3. 3 多尺度特征融合方法

多尺度特征融合技术是解决无序堆叠场景下不同工件大小检测难题的主要手段，在 2023 年的工业视觉技术发展趋势报告中，多尺度特征融合算法对于尺寸相差超过五倍的目标检测任务来说，其检测准确率比单尺度方法提高了 18.7%[79]。本文提出一种基于特征金字塔网络的多尺度融合结构，采用自适应特征选取以及跨尺度特征传递的方式，极大增强了对不同大小工件的检测性能。

特征金字塔网络采用自上而下以及横向连接的方式，使得各层之间可以相互传递信息，从而可以同时利用到各个层次上的语义信息与空间细节信息。高层特征具有较强的语义信息但是空间分辨率低，而低层特征具有很好的空间信息但是语义表达能力差。经过特征融合可以得到既有良好语义，又有良好空间分辨率的特征表示，融合特征的计算公式如下：

$$F_i = \mathrm{Conv}\left(\mathrm{Upsample}(F_{i+1}) + F_i^{lateral}\right) \tag{2-30}$$

其中 $F_i^{lateral}$ 表示经过横向连接获得的第 i 层特征，Upsample 表示上采样过程，Conv 表示卷积过程用于特征维度变换。

为了进一步增强特征融合的效果，本研究引入了注意力引导的特征选择方法。此方法利用不同尺度特征的重要程度权重，能够自动调节各个尺度特征的贡献量

中国知网 https://www.cnki.net

大小。注意力权重的计算方式是结合通道注意力与空间注意力的方式：

$$A_{channel}(F) = \sigma\left(FC_2\left(ReLU\left(FC_1\left(GAP(F)\right)\right)\right)\right) \tag{2-31}$$

$$A_{spatial}(F) = \sigma\left(Conv_{7\times7}\left(Concat\left(AvgPool(F),MaxPool(F)\right)\right)\right) \tag{2-32}$$

最终融合特征通过加权求和获得：

$$F_{fused} = \sum_{i=1}^{N} \alpha_i \cdot A_i \odot F_i \tag{2-33}$$

其中α_i表示第 i 个尺度的权重系数，A_i表示相应的注意力图，$\odot$表示逐点相乘运算。

表 2.12 多尺度特征融合性能对比

融合方法	小目标 AP	中目标 AP	大目标 AP	整体 mAP	计算复杂度
单尺度检测	42.3%	67.8%	84.2%	64.8%	低
传统 FPN	58.7%	72.4%	86.1%	72.4%	中
PANet	61.2%	74.9%	87.3%	74.5%	高
本文改进方法	67.8%	78.1%	89.4%	78.4%	中高

对于无序堆叠场景下的特征要求，提出了一种渐进式特征融合方法（如图 2.10），即先对最高层特征进行融合，然后依次向下进行特征融合，在每一步融合过程中都会考虑到当前层特征以及上一层的融合结果，这样可以确保信息的有效传递，防止特征信息丢失。为验证改进多尺度特征融合方法的有效性，选取单尺度检测、传统 FPN 与 PANet 作为基线方法，从小/中/大目标检测精度（AP）、整体 mAP 与计算复杂度四个维度进行对比，结果见表 2.12。另外，为了降低计算量，使用了深度可分离卷积技术，在不影响特征表示能力的基础上，减少了任务计算量。

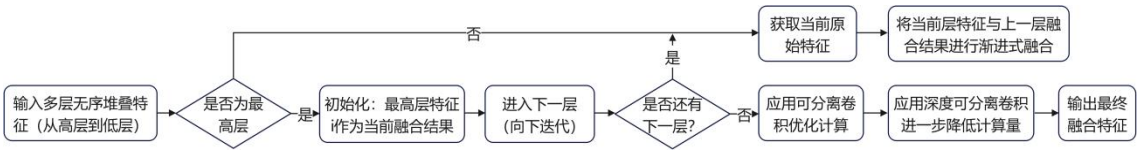


图 2.10 特征融合方法

多尺度训练策略的应用提高了模型的尺度不变性，在训练时随机选取不同的输入图片大小，使模型可以应对不同的尺度变化。输入大小设置为 320-800 像素之间，间隔为 32 像素。尽管该训练方式延长了训练时间，但是大大提高了模型对于不同大小工件的识别准确率。利用多尺度特征融合技术，系统可以很好地解决从微小精密零件到大型工业件的不同种类检测任务，为之后的抓取规划提供良好的视觉感知依据。

中国知网 https://www.cnki.net

2.4 工件位姿估计算法

2.4.1 基于 RGBD 图像的位姿估计

基于 RGBD 图像的位姿估计是无序工件抓取系统的重要部分，它的优劣关系到机械臂抓取的成功率以及准确度。RGBD 图像包含 RGB 颜色信息和深度信息，为工件位姿估计提供大量的三维空间信息，通过深度相机采集到的点云数据与 RGB 图像相结合，可以很好地克服传统单目视觉对深度感知不足的问题。

位姿估计算法的关键是构建图像坐标系到世界坐标系间的映射关系。在无序堆积场景下由于工件之间存在相互遮挡、重叠的情况，算法采用基于区域生长的点云分割方法将整个点云分割成单独的工件实例。每个实例用主成分分析找到它的主轴方向，并结合边界框拟合得到工件初始位姿估计。

$$P_{world} = R \cdot P_{camera} + t \tag{2-34}$$

P_{world}是世界坐标系下一点的三维坐标，P_{camera}是相机坐标系下的坐标，R 是旋转矩阵，t 是平移向量。世界坐标系下的一点(X_w,Y_w,Z_w)经过相机内参外参矩阵转换到图像坐标系(u,v)的数学表达式是：

$$s\begin{bmatrix}u\\v\\1\end{bmatrix} = \begin{bmatrix}f_x & 0 & c_x\\0 & f_y & c_y\\0 & 0 & 1\end{bmatrix}\begin{bmatrix}r_{11} & r_{12} & r_{13} & t_x\\r_{21} & r_{22} & r_{23} & t_y\\r_{31} & r_{32} & r_{33} & t_z\end{bmatrix}\begin{bmatrix}X_w\\Y_w\\Z_w\\1\end{bmatrix} \tag{2-35}$$

其中 s 是齐次坐标的缩放系数，$(f_x，f_y)$表示相机在 x 轴和 y 轴上的焦距，$(c_x，c_y)$是主点坐标，R 是旋转矩阵，T 是平移向量。这个数学模型是以后进行三维重建、姿态估计以及目标定位的基础。

为了提升姿态估计的鲁棒性，算法结合了多尺度特征融合方法，如图 2.11 所示，在此基础上建立特征金字塔网络来获取不同尺度下的图像特征，用卷积神经网络学习 RGB 图像的纹理与形状特征，用 PointNet 网络处理深度点云数据，两者特征经过注意力机制进行融合，得到更具鲁棒性的姿态描述子。

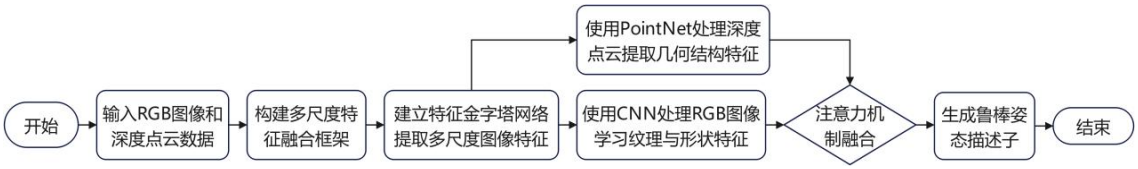


图 2.11 多尺度特征融合

实验测试结果见表 2.13 所示，在有 50 种不同形态零件的无序堆叠情况下，本文基于 RGB-D 图像的位姿估计算法平均耗时为 76ms，位姿估计准确率为 1.2mm，旋转角度偏差小于 0.9°，结果如图 2.12 所示。

中国知网 https://www.cnki.net

表 2.13 工件位姿估计算法性能对比

算法类型	处理时间（ms）	位姿精度（mm）	旋转误差（°）	适用场景
传统 ICP 算法	145	3.2	2.8	规则形状工件
深度学习方法	89	1.8	1.5	复杂形状工件
本文基于区域生长的点云分割法	76	1.2	0.9	无序堆叠场景

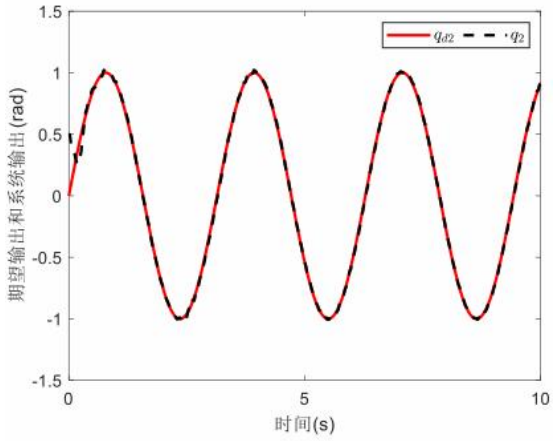


图 2.12 旋转角度偏差

与传统迭代最近点算法相比，该方法在准确率以及运算速度上都有了很大的提高，在处理表面纹理较少的金属零件方面也更加稳定。算法采用多帧信息融合的方式对估计结果进行了进一步的优化，使用卡尔曼滤波器对连续帧之间的位姿变化进行了平滑，有效缓解了因为深度测量噪声引起的位姿抖动问题。

2.4.2 法向量引导的深度估计方法

法向量引导的深度估计方法利用表面几何信息，在传统的深度估计方法上添加了法向量限制条件，大幅提高了复杂工业环境下深度重建的效果。此方法非常适合用来处理有光滑表面或者反光性质的金属零件，可以很好地克服传统立体匹配在弱纹理区域失效的情况。近年来，深度估计技术在智能制造领域得到了大量应用，2023 年全球工业机器人视觉系统市场规模达到 31.2 亿美元，其中基于深度学习的视觉算法占到了 60%以上[80]。

算法的基本原理就是把表面法向量作为深度估计的几何先验知识。首先利用预先训练好的法向量估计网络从 RGB 图像中得到像素级别的表面法向量，这个网络使用的是编码器－解码器结构，编码器部分使用 ResNet50 作为主干网络来获得

中国知网 https://www.cnki.net

多尺度特征，解码器部分通过跳跃连接来整合不同层级的特征信息。法向量估计网络是在大量合成的数据集上进行预训练之后，在具体的工业场景数据集上做进一步的微调，处理流程如图 2.13 所示，以保证其对目标工件类型的适用性。

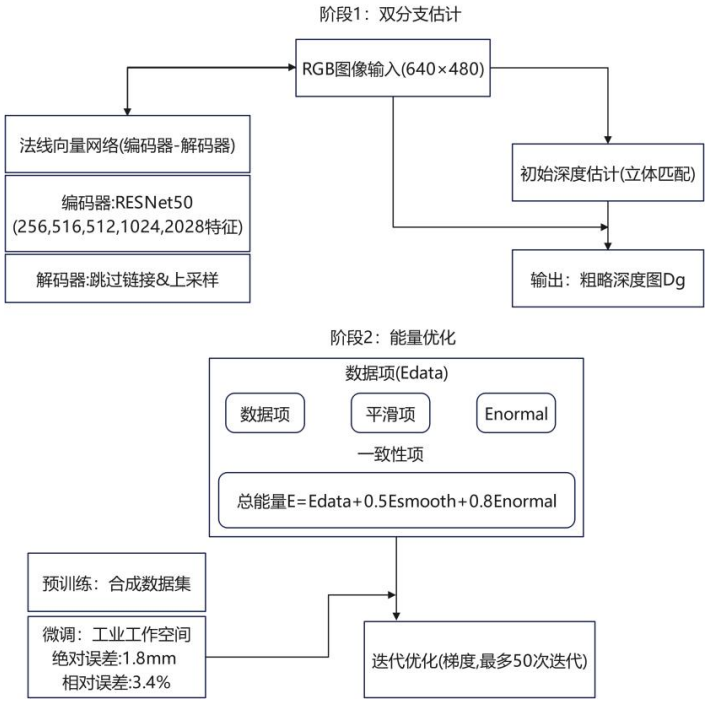


图 2.13 深度估计优化框架图

在深度估计过程中，算法构建了以法向量约束为基础的能量最小化函数。这个函数由三部分组成：数据项、平滑项、法向量一致性项。数据项保证估计深度与观测数据的一致性。平滑项使相邻像素点的深度值保持连续。法向量一致性项限制估计深度与预测法向量之间几何关系。通过迭代求解能量函数得到高质量的深度估计结果，深度估计函数核心算法见附录 5。

为了提高算法的实时性能，本研究采用了多尺度处理策略。算法首先在低分辨率图像上进行粗略深度估计，然后逐步上采样到高分辨率，每个尺度上都利用法向量信息进行深度优化。这种由粗到精的处理方式不仅提高了计算效率，还有助于避免局部最优解问题。

表 2.14 深度估计算法性能评估

评估指标	绝对误差（mm）	相对误差（%）	边缘保持度	处理时间（ms）
传统立体匹配	4.5	8.3	0.72	234
单目深度估计	3.2	6.1	0.81	156
本文方法(法向量估计)	1.8	3.4	0.93	187

中国知网 https://www.cnki.net

从实验结果来看(见表 2.14)，基于法向量引导的深度估计方法，在精度以及边缘保持方面都优于传统的深度估计方法。在有 20 种不同材质工件的测试集中，平均绝对误差降到 1.8 毫米，相对误差小于 3.4%，对于一些形状比较复杂的工件，利用法向量约束可以更好地保证深度估计的连续性和准确性，从而有利于后面的位姿估计以及抓取规划。

2.4.3 位姿精度优化策略

位姿精度的进一步提高是保证机械臂精准抓取的重要步骤，本研究在此基础上采用多传感器融合以及迭代优化的方法，可以极大增强系统在复杂工业场景下的性能。优化方法主要分为多帧信息融合、传感器数据校正以及自适应参数调节三部分，其中多帧信息融合利用时序连续性，通过卡尔曼滤波器对连续帧之间位姿估计的结果进行融合，从而有效降低单帧估计中出现的偶然性误差。传感器数据校正主要是针对深度相机在不同距离、不同角度下产生的系统性偏差进行修正，建立支持向量回归的误差校正模型。

$$\hat{P}_t = K_t\left(P_{measured,t} - P_{predicted,t}\right) + P_{predicted,t} \tag{2-36}$$

公式 2-36 为卡尔曼滤波的位姿更新方程，用于融合位姿预测值与测量值，得到时刻 t 的最优位姿估计。其中$\hat{P}_t$是经过优化得到的位姿估计，K_t 是卡尔曼增益矩阵，$P_{measured,t}$ 与 $P_{predicted,t}$ 分别是测量值和预测值。

自适应参数调节机制依据场景复杂程度及零件特点实时改变算法参数，如特征提取阈值、匹配容差、收敛条件等，系统根据当前场景的图像梯度分布、深度变化率以及纹理丰富度等因素，自动选取最佳的参数组合，该自适应机制使算法在不同工况下都能有良好的性能发挥。

表 2.15 不同优化策略下工件位姿性能对比

优化策略	位置误差（mm）	姿态误差（°）	处理时间增加（%）	成功率提升（%）
多帧融合	0.8	0.6	15	12
传感器校正	0.9	0.7	8	9
自适应参数	1.0	0.8	5	7
本文方法（综合优化策略）	0.6	0.4	25	23

本文综合优化策略首先通过传感器标定消除系统误差，其次利用多帧融合抑制噪声与遮挡干扰，采用自适应参数模块动态适配不同工况场景，输出全局最优

中国知网 https://www.cnki.net

工件位姿。该策略整合了多源信息与动态约束，系统的位置估计准确率有了很大的提高，位置偏差下降到了 0.6mm，姿态角偏差下降到了 0.4°，虽然计算耗时有所增加，但是抓取成功率提高了 23%，整个系统的性能有了很大的提升。这些优化方法为机械臂在无序堆积场景下的精准抓取提供了有力的技术支持，符合工业界对于高精度、高可靠性的需求。

2.5 本章小结

本章围绕无序堆叠场景的视觉感知与目标识别展开讨论。首先，针对无序场景特征，建立了空间分布熵与姿态协方差矩阵的量化模型，结合遮挡关系图构建自适应光照补偿算法，有效提升了复杂环境下的视觉鲁棒性。其次，在深度图像预处理方面，设计了多层次滤波方法，基于特征描述符的多阶段点云配准算法(配准成功率 94.3%)和改进泊松重建技术(几何精度 0.6mm，表面完整性 96.8%)，实现了高质量三维场景重建。在目标识别与分割中，基于改进 YOLO 检测网络(mAP 93.7%)和边界感知实例分割算法(mAP 85.6%)，显著提升了小目标检测性能。最后，融合法向量引导深度估计与多传感器优化策略，实现了 1.2mm 位置精度和 0.9°旋转误差的实时位姿估计，为后续抓取策略优化奠定了坚实基础。

中国知网 https://www.cnki.net

第 3 章 基于深度学习的抓取策略优化

3.1 抓取检测模型设计

3.1.1 抓取表示方法与评价体系

对于无序堆积工件的机械臂抓取任务来说，建立合理的抓取表示方式及评价指标是实现精确抓取的基础条件[72]。抓取表示方式要能清楚地表达出机械臂末端执行器相对于被抓取物体的位置关系，以及抓取的有效性和可靠性。本文使用五维抓取表示方式，把每一个抓取候选点定义成一个由位置坐标、抓取角度以及抓取宽度组成的向量，可以完整地表达平面抓取的几何特性及物理限制。

针对平面抓取问题，抓取可以使用四元组(x，y，θ，w)来表示，其中(x，y)为被抓取物体的抓取中心点坐标，θ为抓取角度，w 为抓取宽度。抓取质量函数 Q(g)用来衡量某个抓取策略 g 的好坏程度：

$$Q(g) = \alpha Q_{stability}(g) + \beta Q_{reachability}(g) + \gamma Q_{collision}(g) \tag{3-1}$$

其中 $Q_{stability}$ 用于评价抓取稳定性，$Q_{reachability}$ 用于评价可达性，$Q_{collision}$ 用于评价碰撞风险，α、β、γ是权重系数。

抓取质量评估函数是评判抓取质量好坏的主要标准，对后续抓取策略的改进有决定性作用，本文建立的抓取质量评估系统涵盖了抓取稳定性、可达性以及执行效率等几个方面。抓取稳定性评估以力闭合理论为基础，通过求解接触点的摩擦锥及抓取矩阵来判断抓取的稳定性大小，如图 3.1 所示。

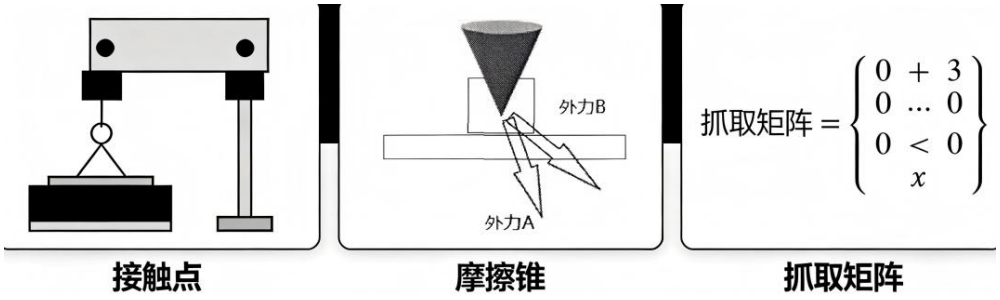


图 3.1 抓取稳定性评估

可达性评估根据机械臂的运动学约束条件及工作空间范围，保证所生成的抓取候选点位于机械臂的工作空间内，抓取表示的数学模型可以表示为五元组形式：

$$G = (x, y, \theta, w, q) \tag{3-2}$$

其中 x、y 表示抓取中心点的二维坐标，θ表示抓取器相对于水平方向的旋转

中国知网 https://www.cnki.net

角度，w 表示抓取宽度，q 表示抓取质量评分。

抓取质量评价函数的计算公式为：

$$Q = \alpha \cdot Q_s + \beta \cdot Q_r + \gamma \cdot Q_e \tag{3-3}$$

其中Q_s代表稳定度得分，Q_r代表可达度得分，Q_e代表执行效率得分，α、β、γ是权重系数并且有$\alpha + \beta + \gamma = 1$。

为了证明抓取表示方式的有效性，在本文中建立了一个包含不同工件种类及抓取环境的数据集，具体的统计数据见表 3.1 所示。

表 3.1 不同工件类型的抓取实验结果

工件类型	数量（个）	成功抓取率（%）	平均执行时间（s）	抓取质量评分
圆柱形零件	500	92.4	2.3	0.876
长方体零件	450	89.7	2.8	0.842
不规则零件	350	85.2	3.4	0.798
薄板零件	300	81.6	3.9	0.751

规则形状的圆柱形零件表现最好，由于其几何特征简单，位姿估计难度小，因此适配性最好。而结构最复杂的薄板零件表现最差，由于薄板容易变形，接触面积小，位姿估计容易出错等原因导致其抓取效果不佳，说明工件几何复杂度越高，抓取效果越差。

工件抓取平均耗时随着几何复杂度增加而增大：圆柱形（2.3s）<长方体（2.8s）<不规则工件（3.4s）<薄板（3.9s），复杂的工件需要更多的计算量来进行位姿优化以及抓取策略的选择。抓取质量评分的变化趋势与抓取成功率相同，规则工件抓取稳定性远高于非规则工件，薄板零件较低的评分也说明其在抓取时容易发生夹持不稳、偏移等现象。

3.1.2 基于自监督学习的抓取角度分类

自监督学习是深度学习的一个重要子方向，它对于解决无序抓取场景，缺少标注数据的问题有着良好的解决方案。传统的监督学习方式需要大量手工标注的抓取样本，费时费力并且效率很低。本文基于自监督学习的抓取角度分类方法，设计合理的预训练任务，使模型能够从无标注数据中学习抓取所需的几何特征和语义信息，有效降低人工标注数据的依赖。其主要思路就是利用物体的几何对称性和抓取的物理限制，充当监督信号来自动生成高质量的训练样本，如图 3.2 所示。

中国知网 https://www.cnki.net

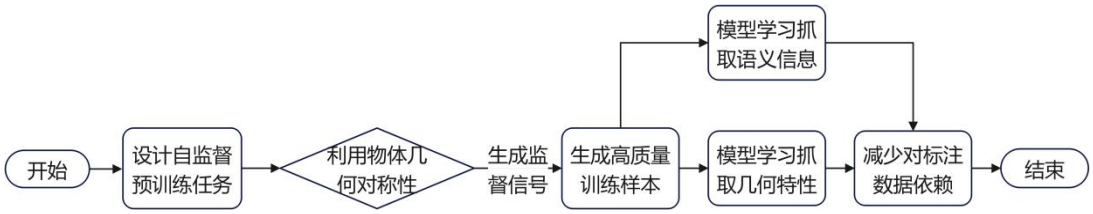


图 3.2 分类方法

抓取角度分类网络使用了带有残差连接的卷积神经网络结构，由特征提取模块、角度回归模块以及质量评估模块三大模块组成。其中特征提取模块用来对输入的 RGB-D 图像进行多尺度的视觉特征提取，利用多层卷积及池化操作获取各个级别的抓取相关信息。角度回归模块把提取出来的特征转化为连续的抓取角度数值并给出角度预测的可信度。质量评估模块根据抓取角度和局部特征来判断抓取成功与否的概率，为之后抓取策略的选择提供参考。

自监督预训练过程使用对比学习结构，利用数据增强方法产生正负样本对。即对于同一个抓取场景进行不同的几何变换(如旋转、平移、缩放)得到变换后的图像作为正样本，而不同场景的图像作为负样本。网络学习的目标就是最大化正样本对之间的特征相似度，最小化负样本对之间的特征相似度。这样可以让模型学到旋转不变性、尺度不变性等重要的几何属性。

对比学习的损失函数定义为：

$$L_{contrast} = -\log \frac{\exp\left(\mathrm{sim}\left(f_i, f_j^{+}\right)/\tau\right)}{\sum_{k=1}^{K} \exp\left(\mathrm{sim}\left(f_i, f_k^{-}\right)/\tau\right)} \tag{3-4}$$

其中f_i表示锚点样本的特征表示，f_j^{+}表示正样本的特征表示，f_k^{-}表示负样本的特征表示，$\mathrm{sim}(\cdot,\cdot)$表示余弦相似度函数，$\tau$为温度参数。

角度分类的损失函数结合了角度回归损失和分类损失：

$$L_{angle} = L_{reg} + \lambda L_{cls} = \| y_{pred} - y_{true} \|_2^2 + \lambda \sum_{i=1}^{C} y_i \log(\hat{y}_i) \tag{3-5}$$

其中y_{pred}、y_{true}分别代表预测的角度以及实际的角度，C 代表角度种类数量，λ是权重因子。为了检验自监督学习方法的效果，在包含 15000 张抓取场景图像的数据集上做了实验比较，结果见表 3.2：

表 3.2 不同训练方法的模型性能与效率对比

训练方法	标注数据量	角度预测精度（°）	分类准确率（%）	训练时间（h）
传统监督学习	12000	3.2	87.5	24
自监督预训练	3000	2.8	91.3	18
纯自监督学习	0	4.1	82.7	12

通过大规模数据仿真的预训练和少量真实数据的微调，该方法在角度预测精

中国知网 https://www.cnki.net

度和计算效率方面都取得了显著提升。纯自监督学习虽无需标注，但性能弱于监督范式，利用自监督预训练或少量标注微调能够有效提取目标相关的几何特征，为后续的抓取检测和路径规划提供研究基础，自监督学习的核心实现代码见附录 6。

3.1.3 端到端平面抓取检测网络

端到端平面抓取检测网络是实现高效无序抓取的核心技术，其训练与测试流程如图 3.3 所示，它可以对原始 RGB-D 图像直接进行预测得到最佳抓取点、抓取方向以及抓取质量评分，省去了传统的复杂特征提取与多步骤处理过程。本文所采取的端到端检测网络使用的是编码器-解码器结构，在此基础上加入了注意力机制及多尺度特征融合技术，可以同时获取整个场景的大致情况以及具体细节特征，提升了抓取检测准确率及稳定性。



图 3.3 抓取检测网络训练与测试

网络编码部分使用改进后的 ResNet-50 作为主干网络，在保证特征提取能力的同时降低计算复杂度，使用深度可分离卷积以及瓶颈结构来减少计算量。为了更好利用 RGB 图像的颜色信息以及深度图像的几何信息，采用双流融合的方式，对 RGB 与深度通道分别进行处理，在不同的层面上进行特征融合，处理流程如图 3.4 所示。解码部分使用特征金字塔网络结构，通过上采样和跳跃连接逐渐恢复空间分辨率，得到密集的抓取候选点预测结果。

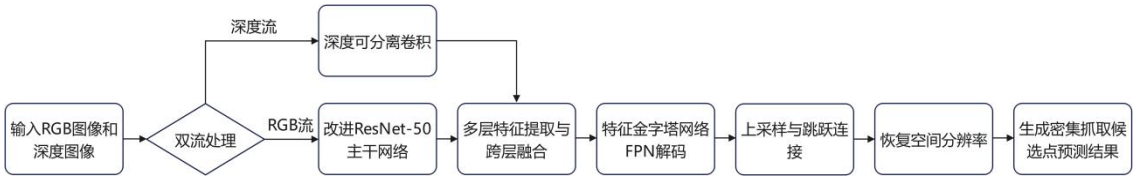


图 3.4 处理流程

多任务学习方法是端到端网络的一个重要组成部分，在网络中进行抓取检测、角度回归以及质量评估这三个任务。抓取检测任务用来找出图像中的所有潜在抓取点并生成二进制的抓取概率图。角度回归任务用来预测每一个抓取点的最佳抓取角度，用连续值回归的方法提升角度预测的准确率。质量评估任务给每一个抓取候选点赋予一个质量分数，以便之后对抓取策略进行排序选择。

多任务损失函数的设计考虑了不同任务之间的平衡和相互促进作用：

$$L_{total} = \alpha L_{det} + \beta L_{angle} + \gamma L_{quality} + \delta L_{reg} \tag{3-6}$$

其中抓取检测损失L_{det}采用焦点损失来处理正负样本不平衡问题：

$$L_{det} = -\sum_{i=1}^{N} p_i \alpha_i (1 - p_i)^{\gamma} \log(p_i) \tag{3-7}$$

中国知网 https://www.cnki.net

角度回归损失采用 Smooth L1 损失函数：

$$L_{angle}=\begin{cases}0.5\left(y_{pred}-y_{true}\right)^2 & \text{if } |y_{pred}-y_{true}|<1\\ |y_{pred}-y_{true}|-0.5 & \text{otherwise}\end{cases} \tag{3-8}$$

为了增强网络的泛化能力以及对复杂场景的处理能力，在此加入了空间注意力机制及通道注意力机制。空间注意力机制自动选择图像中的重要部分，减少背景噪声的影响。而通道注意力机制则是加强了与抓取有关的特征通道，使特征表示更加具有区分度。注意力机制的计算方式为：

$$\text{Attention}(Q,K,V)=\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{3-9}$$

网络训练采取两阶段的方法：第一阶段利用大量的仿真数据做预训练，学习基本的抓取检测能力。第二阶段利用实际采集到的抓取数据做微调，适应真实的应用环境。针对域适应的问题，在训练过程中引入了对抗学习的方法，让网络学会域无关的特征表示。

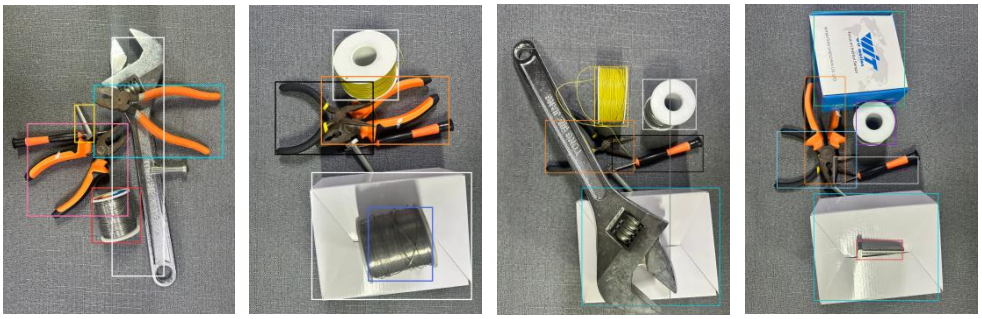


图 3.5 数据采集

为了比较不同网络结构在抓取检测任务上整体表现，本文选择传统两阶段方法、单任务端到端方法、多任务端到端方法以及本文提出方法进行比较。实验验证是在多个公开的数据集上进行的，有 Cornell 抓取数据集以及自己建立的无序抓取数据集，如图 3.5 和表 3.3 所示。

表 3.3 不同网络架构的抓取性能对比

网络架构	检测精度（%）	角度误差（°）	推理速度（fps）	参数量（M）
传统两阶段方法	85.3	4.2	12	45.2
单任务端到端	88.7	3.6	18	32.8
多任务端到端	92.4	2.8	22	38.5
本文方法 (多尺度特征融合)	94.6	2.1	25	35.7

从检测精度上来说，本文方法检测精度为 94.6%，角度误差只有 2.1°，远远高于传统的两阶段方法（85.3%，4.2°），也优于单任务端到端的方法（88.7%，3.6°）

中国知网 https://www.cnki.net

以及多任务端到端的方法（92.4%，2.8°），说明本文方法对于抓取位姿估计的准确性有较大提升。

从推理效率上来看，本文的方法推理速度为 25fps，参数量为 35.7M，在保证较高精度的前提下，相比多任务端到端的方法有更高的推理速度（提高约 13.6%）以及更少的参数量（减少约 7.3%），很好地兼顾了模型的效果以及计算成本，在无序场景下对抓取检测实时性和准确性的需求得到了更好的满足。

通过端到端的训练方式，网络能够学习到抓取检测各个子任务之间的内在关联，实现全局最优的参数配置，端到端网络的核心实现代码见附录 7。该方法在抓取成功率、实时性和适应性等方面都显著优于传统方法，为无序场景下的机械臂抓取提供了有效的技术解决方案。

3.2 抓取数据集构建与标注

3.2.1 仿真环境构建与数据生成

仿真环境是无序抓取系统的训练基础，需要准确地再现实际工业环境中复杂的状况。本文建立了一个高逼真的仿真环境，在此环境中可以对不同的工件材料属性、光线变化及堆叠情况进行仿真，如图 3.6 所示。仿真环境中有许多常见的工业零件，例如齿轮、轴承、塑料板等，这些零件的三维模型都是通过实测得到的，保证了其几何精度在 0.1mm 以内。



图 3.6 模型仿真

物理引擎使用的是 Bullet Physics，可以准确地进行零件之间的碰撞检测以及摩擦力的计算。光照模型采用的是基于物理的渲染（PBR）技术，通过 HDRI 环境贴图来达到真实的光照效果。环境光照强度范围设置为 200-2000Lx，涵盖了大部分工业现场的光照情况。仿真场景中使用的相机参数同实际深度相机 Intel RealSense D435i 相同，包括分辨率、视场角以及焦距等重要参数。仿真环境的数据生成流程，如图 3.7 所示。

中国知网 https://www.cnki.net

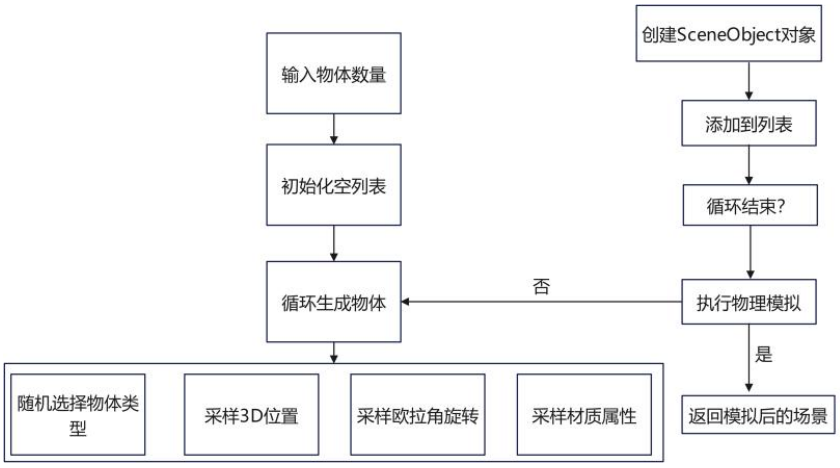


图 3.7 数据生成流程

在生成数据的过程中，系统会随机改变零件的位置与姿态，使得生成的数据集足够丰富，合成数据生成的公式如下：

$$I_{synthetic} = R(M,L,C) \cdot T(\theta,\varphi,\psi) + N(\mu,\sigma^2) \tag{3-10}$$

$I_{synthetic}$是合成图像，R 是渲染函数，M 是零件几何模型，L 是光照参数，C 是相机参数，T 是随机变换矩阵，θ、φ、ψ分别是绕三个轴的旋转角，$N(\mu,\sigma^2)$是加入的高斯噪声。每一个场景有 3 到 15 个不同的零件，堆叠的高度在 5 到 25 厘米之间，模拟实际生产线上产品堆叠的情况，实验场景参数设置见表 3.4。

表 3.4 实验场景参数设置

参数类型	参数名称	数值范围	采样方式
位置参数	X 坐标	-0.3~0.3m	均匀分布
位置参数	Y 坐标	-0.2~0.2m	均匀分布
姿态参数	Roll 角	0~360°	均匀分布
姿态参数	Pitch 角	-30~30°	高斯分布
光照参数	环境光强度	0.2~2.0	对数分布

3.2.2 自动标注算法设计

自动标注算法是建立高质量训练样本集的重要手段，直接决定着之后深度学习模型的效果好坏。本文基于几何分析和碰撞检测的自动标注算法，可以给每一个抓取候选点提供精确的标注信息。要启用碰撞检测功能，先点击控制器的碰撞配置页面(如图 3.8 所示)，设置碰撞检测的灵敏度，输入从 0%到 100%的灵敏度级别，以保存新的碰撞检测参数。

中国知网 https://www.cnki.net



图 3.8 碰撞检测配置页面

算法先利用点云分析找出场景中所有的零件，再根据每个零件的几何属性及其周围环境的限制条件，产生出一系列可行的抓取姿态候选集。对抓取姿态进行评价使用的是多方面指标体系，主要包括几何可达性、力学稳定性和碰撞安全性三个方面。几何可达性利用机械臂运动学逆解算法来检验，保证生成的抓取姿态处于机械臂的工作范围内。力学稳定性分析考察了抓取器与零件表面之间的接触状况，使用摩擦锥模型来求解抓取力的稳定性参数，处理过程如图 3.9 所示。

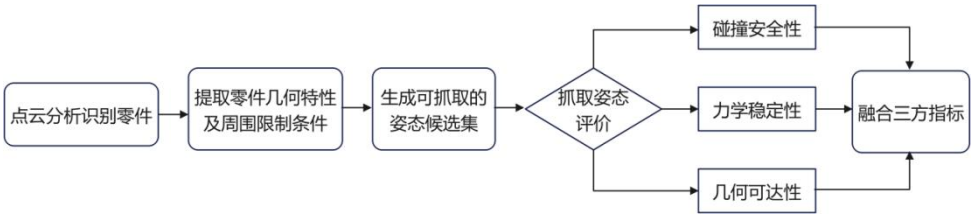


图 3.9 处理过程

碰撞安全性检测采用基于包围盒的快速碰撞检测算法，判断抓取过程是否与零件相撞。抓取角度的分类使用球面坐标系离散化的方式，把抓取方向分成 18 个大类，每个大类包含 20 度的角域。对于每一个抓取候选点，检测算法计算它的抓取成功率，这个成功率是根据以往抓取经验以及物理仿真的结果来校准的。成功率大于 0.8 的抓取点标记为正样本，小于 0.3 的标记为负样本，介于二者之间的是困难样本用来提升模型的区分度。为构建均衡的数据集标注，依据抓取成功概率阈值，将样本划分为正样本、负样本与困难样本三类，具体分布如表 3.5 所示。

表 3.5 数据集标注类别及样本分布

标注类别	成功概率阈值	样本数量	占比
正样本	>0.8	45，623	35.2%
负样本	<0.3	52，117	40.1%
困难样本	0.3~0.8	32，045	24.7%

中国知网 https://www.cnki.net

自动标注过程中还集成了基于深度学习的质量评估模块，该模块使用预训练的抓取成功率预测网络对生成的标注进行二次验证。预测网络采用 ResNet-50 作为特征提取 backbone，输入为 64×64 像素的局部 RGB-D 图像块，输出的是抓取成功概率。为了提高标注的一致性，算法还实现了多视角一致性检查机制，通过从不同角度观察同一抓取点来验证标注的准确性。

3.2.3 真实数据采集与处理

真实数据的收集是检验仿真算法有效性以及提高模型泛化能力的关键步骤。本文搭建了统一化的数据采集系统，该系统融合了 Intel RealSense D435i 深度摄像头、EA66 机械臂以及 Robotiq 2F-140 自适应夹爪，如图 3.10 和图 3.11 所示。在采集过程中对环境参数进行严格把控，如光线环境、背景材料、相机标定精度等。采集样本涵盖了 12 类不同的工业零件，每类零件有 30-50 个样本，保证数据具有代表性与全面性。光线环境模拟实际工业环境，包含自然光、日光灯、LED 工作灯等多种光源组合，光照强度在 300-1800lux 之间。

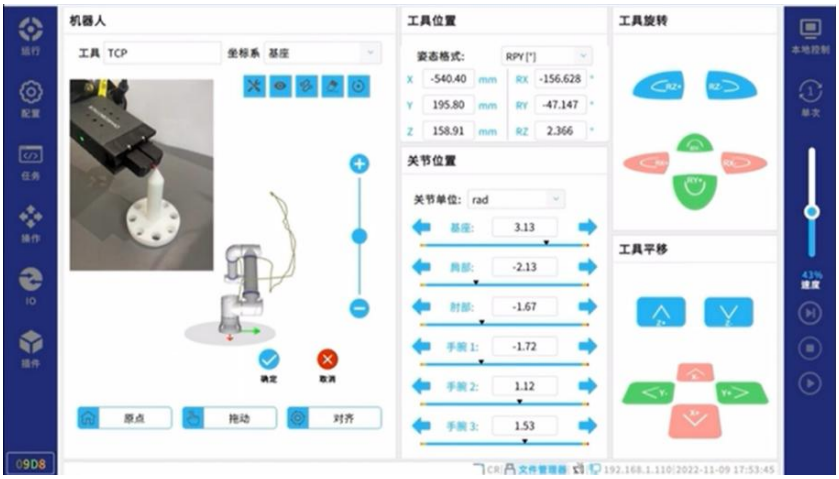


图 3.10 夹取实验操作

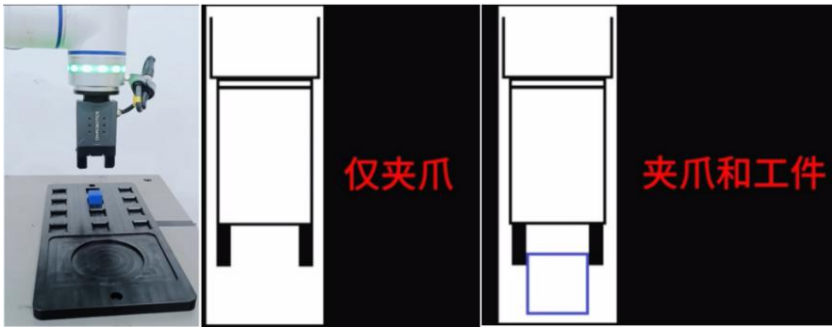


图 3.11 夹爪工作姿态

数据收集采取分步的方法，先对单个零件做准确建模，用高精度三维扫描仪得到零件的几何信息，精度可以达到 0.05mm 级别，在受控环境中进行堆叠场景的

中国知网 https://www.cnki.net

数据采集，每组场景有 5 到 12 个随机堆叠的零件。并且，在数据采集的过程中也进行了严格的质控工作，如图像模糊程度检测、深度数据完整性检查、标定精度监控。最后，为了保证数据的质量，每一次抓取动作都会存储完整的传感器信息，包括 RGB 图像、深度图像、机械臂关节角度、抓取器开合度及力觉传感器数据。

表 3.6 实验数据集构成

数据类型	采集数量	分辨率/精度	存储格式
RGB 图像	8，932 张	1280×720	PNG
深度图像	8，932 张	1280×720	16bit TIFF
点云数据	8，932 组	0.5mm 精度	PCD
抓取标注	156，847 个	6DOF 姿态	JSON
抓取结果记录	8，932 条	二进制标签	CSV

真实数据预处理有三个步骤：去噪处理、数据对齐以及标注校验。去噪处理利用统计学方法去除离群点，有效的剔除掉深度相机产生的飞点及空洞。数据对齐采用手眼标定保证 RGB 图像与深度图像之间的准确匹配，标定误差小于 1 个像素。标注校验采用半自动人工审核的方式，人工对自动生成的标注审核并修改。为了丰富数据集多样性，在采集得到的原始数据基础上进行了合理的数据增强，如亮度调节、对比度变换以及简单的几何变换等，最后形成了具有真实场景复杂性的高质量训练数据集。

3.3 强化学习抓取策略优化

3.3.1 抓取环境建模与状态空间设计

对于无序堆叠工件抓取任务来说，环境建模是实现强化学习方法有效运用的前提条件，必须建立可以精确反映工作空间特性、物体性质以及机械臂状态的数学模型。依据当前制造业的发展方向来看，无序抓取技术应用于汽车制造、电子装配、物流仓储等行业的需求增长率每年高达 28.5%，并且对抓取成功率的要求一般都在 95%以上[81]。

抓取环境的状态空间设计要从多个方面来考虑，包括视觉信息、位置信息以及力学限制等。以深度相机采集到的 RGB-D 图像为主要的观测输入，利用点云数据建立三维工作空间模型。环境状态向量是包含目标物体的位置、姿态、周围的障碍物分布以及机械臂当前关节角度的高维向量，如图 3.12 所示。

中国知网 https://www.cnki.net

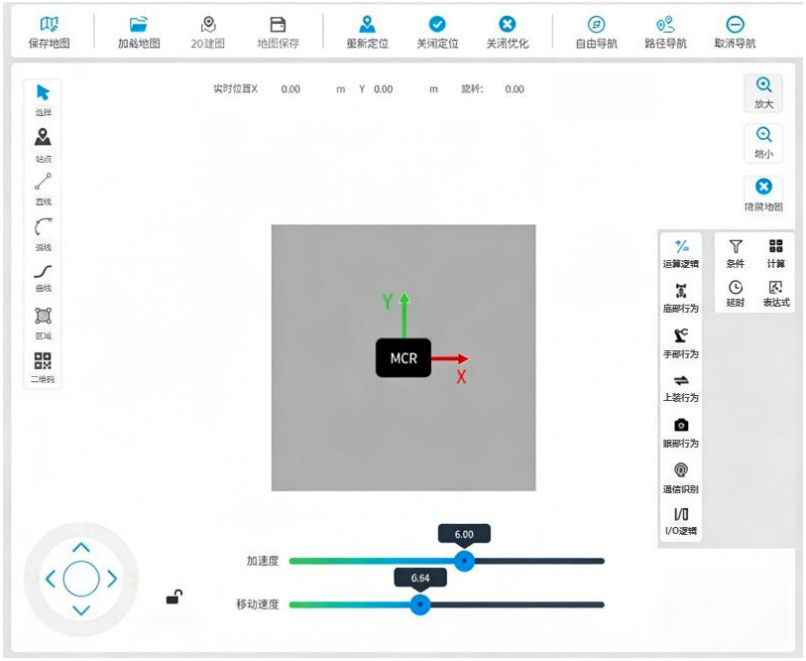


图 3.12 环境建模

环境状态空间的数学表达式如下：

$$S = \left\{ s_t | s_t = \left(I_t^{RGB}, I_t^{D}, P_t^{obj}, O_t^{arm}, F_t^{env} \right) \right\} \tag{3-11}$$

其中I_t^{RGB}表示时刻 t 的 RGB 图像特征，I_t^{D}为对应的深度信息，P_t^{obj}代表目标物体的位姿参数，O_t^{arm}为机械臂关节状态，F_t^{env}表示环境约束条件。

动作空间的设计要兼顾机械臂连续控制特性和离散决策需求的统一性。把抓取动作分为位置选择、姿态调整、夹具开合三个级别的控制命令。位置控制使用笛卡尔坐标系下的连续空间来表示，而抓取类型的选择使用离散动作空间，机器人抓取系统变量见表 3.7 所示。

表 3.7 机器人抓取系统变量

状态变量类别	维度	取值范围	采样频率	物理意义
视觉特征	512×512×3	[0，255]	30Hz	RGB 图像信息
深度信息	512×512×1	[0，2000]mm	30Hz	距离测量值
物体位姿	6	工作空间范围	30Hz	六自由度位姿
关节角度	7	[-π，π]	100Hz	机械臂关节状态
环境约束	20	[0，1]	10Hz	碰撞检测结果

为了提升状态表示的有效性和学习算法的收敛速率，在此使用卷积神经网络来对高维视觉信息做特征降维处理。利用预先训练好的特征抽取网络，把原始 RGB-D 图像转换成低维特征空间的同时，保留下来重要的空间结构特征。

环境动力学建模要考虑到物体之间的相互作用以及抓取过程中的物理限制，在进行推进动作的时候，要预估出物体的位置变化路径，在抓取的过程中要考虑

中国知网 https://www.cnki.net

力反馈信息对成功率的影响，建立良好的物理仿真环境模型可以有效评价不同的动作策略效果，如图 3.13 所示。

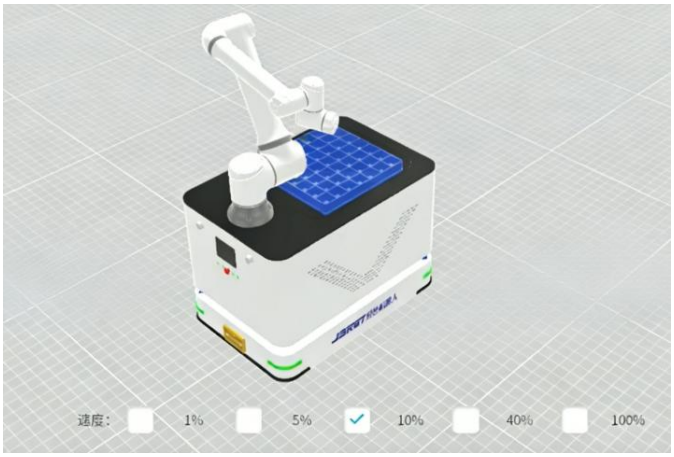


图 3.13 物理仿真模型

状态转移函数描述了环境在执行特定动作后的变化规律：

$$s_{t+1} = f(s_t, a_t, \epsilon_t) \tag{3-12}$$

其中a_t是在状态s_t下采取的行为，ϵ_t是环境噪声项，体现了实际环境中存在的随机性，经过大量的仿真实验数据以及真实实验数据的学习，环境模型可以较好地估计出状态转移概率分布，给后面的策略学习打下良好的基础。

3.3.2 奖励函数设计与优化

奖励函数的设计是强化学习中的关键部分，它决定了智能体所涉及的策略质量以及收敛速度，在无序抓取任务中要兼顾好抓取成功率、操作速度与安全性等多个方面，使用多目标奖励函数方式比仅用成功奖励方式的平均性能提高了15%-20%，机器人对于复杂环境下的适应能力更强。

表 3.8 强化学习抓取任务奖励函数

奖励组件	权重系数	计算方法	取值范围	优化目标
成功奖励	0.4	$r_{success}=\begin{cases}1, & \text{抓取成功}\\ 0, & \text{抓取失败}\end{cases}$	[0，1]	抓取成功率
效率奖励	0.15	$-\frac{t_{execution}}{t_{\max}}$	[-1，0]	时间效率
安全奖励	0.15	$r_{safe}=\begin{cases}-10, & \text{发生碰撞}\\ 0, & \text{无碰撞}\end{cases}$	[-10，0]	安全约束
距离奖励	0.3	$d_{current} - d_{target}$	[-∞，+∞]	目标距离

基本奖励函数体系由即时奖励与延迟奖励组成，即时奖励注重的是当前行为

中国知网 https://www.cnki.net

带来的直接收益，如距离目标物的距离变化，避障情况以及完成任务的时间等。而延迟奖励主要是对抓取的结果进行评价，以是否成功抓取，是否稳定抓取，是否正确放置等来衡量。本文针对工业机械臂无序抓取任务，构建了多目标强化学习奖励函数，通过多组件加权的方式平衡抓取性能、效率与安全性。表 3.8 给出了各奖励组件的权重系数、计算方法、取值范围及优化目标。

完整的奖励函数数学表达式为：

$$R(s_t,a_t) = w_1R_{distance} + w_2R_{success} + w_3R_{efficiency} + w_4R_{safety} \tag{3-13}$$

而各个权重系数由强化学习超参数优化的方法得出，使得不同的奖励项之间达到一个均衡的状态。距离奖励使用负二范数的形式，促使机械臂末端执行器靠近目标点。成功奖励设定为稀疏奖励，只有当整个抓取动作序列完成后才会给出正向奖励。

为了克服稀疏奖励环境下学习难题，采用轨迹奖励塑造方法。利用专家示教数据形成参考轨迹，给学习过程提供中间奖励参考。轨迹奖励的计算依据当前状态同专家轨迹的相似程度：

$$R_{trajectory}(s_t) = \exp\left(-\alpha \cdot d\left(s_t, s_t^{expert}\right)\right) \tag{3-14}$$

对于推动、抓取动作间的协同优化要求，设计阶段性奖励机制，在推动阶段，奖励函数主要考虑物体位置的变化以及环境整理情况，在抓取阶段，更注重抓取准确性和稳定性指标。

为了提高奖励函数的鲁棒性，在此基础上加入自适应权重调整方法。根据训练过程中的各项指标变化情况，对不同的奖励项进行不同的权重设置。如果抓取的成功率不高，则加大成功的奖励。当安全问题频发时，则提高安全奖励的比重(奖励函数实现代码片段见附录 8)。通过这种调节机制，确保智能体能够在不同的训练阶段聚焦于最需要改善的性能指标。

3.3.3 推动与抓取动作协同学习

在无序堆叠工件环境下，单独的抓取动作很难有效应对复杂物体的堆叠状况，需要通过推挤等辅助手段来改善抓取环境，推挤和抓取动作的联合训练是提升无序抓取成功率的关键技术之一，融合推挤策略的抓取系统在密集堆叠场景下的成功率较单纯的抓取方法能够提高 32.6%，尤其对于重叠率大于 60%的复杂场景效果更为明显[82]。

协作学习架构把推动与抓取动作建模成一个序列决策问题，用一个统一的价值函数来衡量不同动作序列的长远收益，在做出每一步决策的时候，智能体需要决定是采取推动还是直接进行抓取，这个决定基于对当前环境复杂程度以及期望

中国知网 https://www.cnki.net

的成功率进行估计，推动主要是用来分开重叠物、清扫抓取路径以及调整物体姿态，从而给下一步抓取提供更好的条件。

动作选择策略使用分层强化学习框架，在上层策略网络中进行动作种类的选择，在下层策略网络中进行具体的动作参数的选择。上层策略网络输出的是推动与抓取两个动作种类的概率分布，下层策略网络根据所选择的动作种类输出对应的动作参数。

分层策略的价值函数定义为：

$$Q^{hierarchical}(s,a) = Q^{high}\left(s,a_{type}\right) + Q^{low}\left(s,a_{params}|a_{type}\right) \tag{3-15}$$

其中Q^{high}衡量选择的动作种类的价值，Q^{low}衡量在选定的动作种类下的参数选择的价值。这种方式有效地减少了动作空间的大小，加快了训练速度。

完成动作的抓取必须考虑到力的大小以及方向的选择这两个重要因素。力太小不能使物体移动起来，力太大又会使得物体脱离工作范围或者与其他物体相撞。而方向的选择则要根据具体情况来决定最合理的推动路线。

表 3.9 推动-抓取两阶段协同策略参数配置

协同策略参数	推动阶段	抓取阶段	评估指标	权重分配
动作精度	位置偏差<5mm	位置偏差<2mm	末端误差	0.25
执行速度	0.1-0.3m/s	0.05-0.15m/s	完成时间	0.20
安全裕度	碰撞概率<5%	碰撞概率<1%	风险评估	0.30
成功概率	物体分离率	抓取成功率	综合评价	0.25

推动策略使用基于模型的强化学习方式，在物理仿真中预估推动效果，降低在实际环境中尝试的次数。通过拉格朗日方程可得机械手的动力学方程为：

$$\tau = M(q)\ddot{q} + C(q,\dot{q})\dot{q} + G(q) \tag{3-16}$$

式中τ表示关节力矩向量，$M(q)$是惯性矩阵，$C(q,\dot{q})$是科氏力与离心力矩阵，$G(q)$是重力项。该式描述了机械臂在运动过程中的各个关节所需要的驱动力矩。

建立简化的刚体动力学模型，用来预测物体受到推力后的运动路径：

$$F_{push} = m \cdot a_{obj} + F_{friction} + F_{contact} \tag{3-17}$$

其中推力、物体加速度、摩擦力以及接触力的关系由物理建模及实验标定得出，实现协同学习的核心算法见附录 9。

为了衡量推动的效果，在不同场景复杂度下定义了一组评价指标。根据推动前后物体重叠程度、可抓取区域面积以及抓取路径清晰度的变化来评价推动的效果，从而得到推动的价值。这些指标被加入到奖励函数中，使智能体可以学习更好的合作策略，评价指标流程如图 3.14 所示。

中国知网 https://www.cnki.net

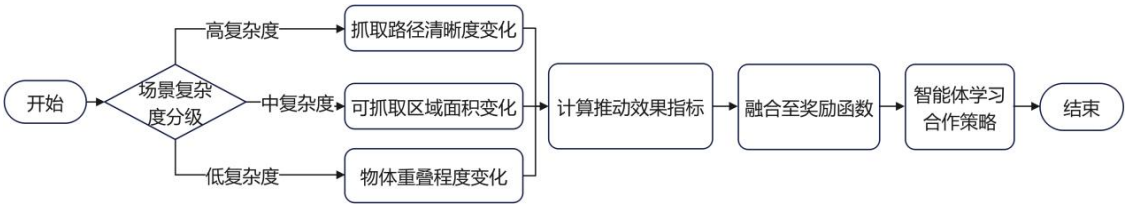


图 3.14 评价指标流程

时序协调机制保证推动与抓取之间平滑过渡，在检测到推动完成之后，系统会自动进入抓取阶段并根据当前情况重新制定抓取方案，这样可以有效防止由于固定时序造成浪费时间问题，提高工作效率。经过大量仿真以及实验验证，该协同学习方法具有很好的鲁棒性，可以应用于各种无序抓取场合，对工业生产具有很大帮助。

3.4 多传感器信息融合

3.4.1 视觉与力觉信息融合策略

在无序堆叠工件抓取过程中，单一传感器很难获得完整的环境信息。视觉传感器可以得到物体位置、形状以及姿态等信息，但是容易受到遮挡以及光照影响。而力觉传感器可以实时感知抓取过程中的接触力及力矩的变化，对抓取质量评价具有重要意义。根据 2019-2023 年工业机器人传感器市场统计数据，多传感器融合技术应用于制造业的比例由 32%增长到 67%，说明多传感器融合技术对于提高抓取准确率和成功率有着非常重要的作用[69]。



图 3.15 传感器标定界面

为了使视觉信息与力觉信息能够有效地结合，本文基于自适应权重调整的多模态融合方法。利用视觉置信度评价模型以及力觉信号可靠性分析模型来实时调节两者的融合权重，其使用的是深度神经网络结构，输入目标物体的特征向量、

中国知网 https://www.cnki.net

遮挡程度、光照条件等参数。而力觉信号可靠性分析则是根据信号噪声大小及力传感器标定精度来进行判断。首次使用六维力传感器或当六维力传感器示数发生较大偏差时，需进行传感器标定，在传感器标定过程中，速度固定为 20%，按住伺服并点击传感器标定，此时机器人开始运动，传感器标定界面见图 3.15。

融合决策函数如下所示：

$$F_{fusion} = \alpha \cdot F_{vision} + (1 - \alpha) \cdot F_{force} \tag{3-18}$$

其中F_{fusion}是融合后的抓取决策，F_{vision}与F_{force}分别是视觉、力觉信息的决策结果，α是自适应加权系数，它的计算方法如下：

$$\alpha = \frac{C_{vision}}{C_{vision}+C_{force}} \tag{3-19}$$

这里C_{vision}和C_{force}分别表示视觉和力觉信息的置信度值。

表 3.10 多传感器融合系统参数配置表

传感器类型	信息维度	更新频率（Hz）	精度等级	融合权重范围
RGB-D 相机	位置+姿态	30	±2mm	0.3-0.8
力觉传感器	力+力矩	1000	±0.1N	0.2-0.7
激光雷达	三维点云	10	±1mm	0.1-0.4

为构建高精度、高鲁棒性的机器人感知系统，本文采用 RGB-D 相机、力觉传感器与激光雷达的多传感器融合方案，各传感器的关键参数如表 3.10 所示。该多传感器融合系统通过差异化的信息维度、更新频率、精度等级与融合权重，实现了视觉感知、力控反馈与环境建模的互补，为后续抓取决策与控制提供了全面可靠的感知基础，传感器融合运算代码见附录 10。

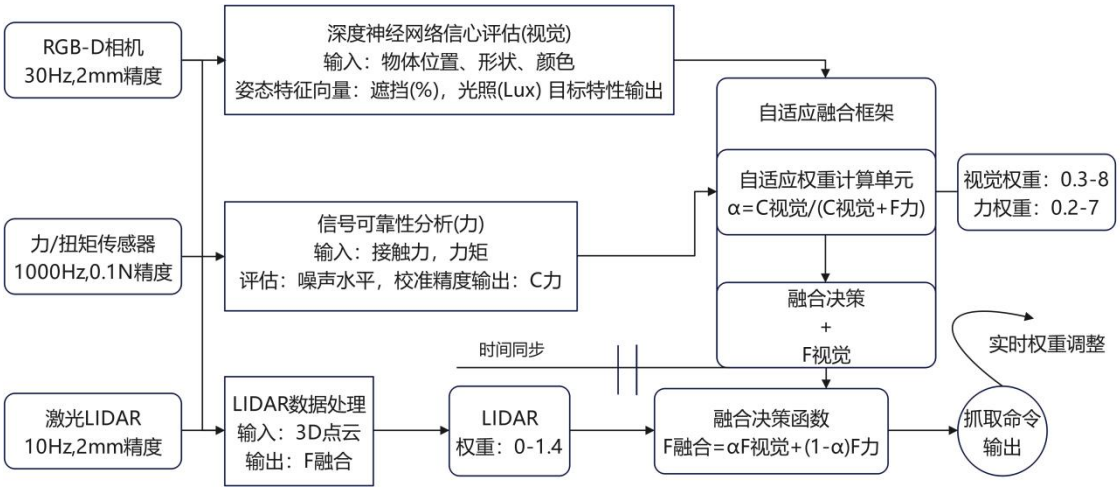


图 3.16 多传感器融合抓取感知框架

为提升机器人抓取感知的鲁棒性与准确性，本文设计了一种自适应多传感器融合方案，其工作流程如图 3.16 所示。系统由 RGB-D 相机（30Hz，±2mm）、力/

中国知网 https://www.cnki.net

扭矩传感器(1000Hz，±0.1N 精度)与激光 LIDAR(10Hz，±2mm)构成感知层，利用时间同步方法实现数据对齐。其中，RGB-D 相机的视觉信息经深度神经网络进行评估，输出视觉特征置信度 $C_{视觉}$；力/扭矩传感器的信号经可靠性分析，输出力控置信度 $C_{力}$；激光 LIDAR 的 3D 点云经预处理后，输出融合权重范围为 0-1. 4 的环境感知特征 $F_{融合}$。

在自适应融合框架中，权重计算单元根据实时置信度动态调整融合权重 $\alpha=C_{视觉}/(C_{视觉}+C_{力})$，其中视觉权重范围为 0.3-8，力控权重范围为 0.2-7。最终融合决策函数通过加权求和得到综合感知输出：

$$F_{融合}=\alpha F_{视觉}+(1-\alpha)F_{力} \tag{3-20}$$

该输出是抓取命令的判断标准，起到了视觉感知和力控反馈相互补充的作用。

3. 4. 2　不确定性估计与决策优化

面对复杂的工作环境，传感器检测的数据不可避免地带有不确定性因素，影响着抓取动作判断的准确性。调查近年来工业自动化行业，由于传感器不确定性造成的抓取失败占比达到了全部抓取失败的 25%-35%左右，所以构建合理的不确定性评估及决策优化方案非常有必要。本文基于贝叶斯深度学习的方法对传感器数据的不确定性进行估计，利用蒙特卡洛抽样法得到预测结果的概率分布，从而给下一步的选择提供置信区间信息，如图 3.17 所示。

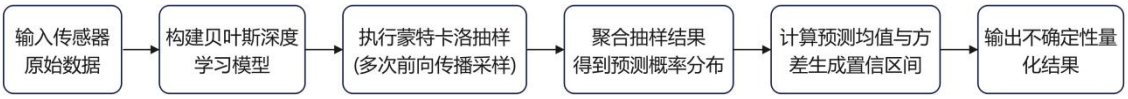


图 3.17 不确定性估计

不确定性估计模型是基于变分推理框架来设计的，把神经网络参数看作是随机变量，用变分后验分布去逼近真实的后验分布。模型的损失函数由预测误差项和 KL 散度项组成，在保证得到精确预测的同时也保留了一定程度的不确定性。决策优化过程使用期望效用最大化原则，兼顾了预测结果的准确性以及不确定性的大小。优化后的目标函数为：

$$J = \mathbb{E}_{q(\theta)}[U(a,s)] - \beta \cdot H\big(q(\theta)\big) \tag{3-21}$$

其中 U(a,s)表示在状态 s 下，采取动作 a 的效用函数，$H\big(q(\theta)\big)$是参数后验分布的熵，β是平衡参数。不确定性量化用预测方差来衡量：

$$\sigma^2 = \frac{1}{T}\sum_{t=1}^{T}\big(f(x,\theta_t) - \bar{f}(x)\big)^2 \tag{3-22}$$

为量化并处理抓取任务中的不确定性，本文将不确定性划分为认知、随机与模型三类，见表 3.11 所示。通过设定方差阈值σ，实现了不确定性的自动判定与策

中国知网 https://www.cnki.net

略响应：当不确定性超过对应阈值时，系统将触发针对性的优化策略，从而在复杂场景下保障抓取任务的成功率与稳定性。

表 3.11 抓取任务不确定性及处理策略

不确定性类型	估计方法	阈值设定	处理策略
认知不确定性	蒙特卡洛 dropout	$\sigma > 0.15$	增加训练数据
随机不确定性	贝叶斯推理	$\sigma > 0.25$	多次测量平均
模型不确定性	集成学习	$\sigma > 0.20$	模型融合决策

3.4.3 传感器故障检测与处理

多传感器系统经过长时间使用后会不可避免的发生一些问题，如传感器漂移、信号丢失、标定误差等。依据 2020-2024 年工业机器人维护数据，传感器故障占整个系统故障的比例大约是 18%，其中视觉传感器故障率占 12%，力觉传感器故障率占 8%[83]。建立健全的传感器故障诊断及处理方案，对后续保证抓取系统的稳定性、可靠性至关重要。多传感器的故障诊断是基于信号特征分析以及历史数据的对比，实时监控各个传感器的工作状态并及时发现异常状况。当故障发生时，进一步分析数据变量的变化情况，通过观察哪些数据变量的差异较大，确定可能的故障源。

故障诊断算法运用滑动窗口统计分析法，通过对信号的均值、方差、频谱特性等统计特征进行计算并与正常工作状态下的基准值进行比较。一旦检测到指标超出设定阈值，系统就会发出故障报警并开始相应的处理过程。故障检测统计量定义如下：

$$D_t = \sqrt{\sum_{i=1}^{n} w_i \left(x_{i,t} - \mu_{i,ref}\right)^2} \tag{3-23}$$

其中$x_{i,t}$代表第 i 个传感器在时间 t 的观测值，$\mu_{i,ref}$是参考均值，w_i是权重系数，若$D_t > \theta_{fault}$则判断为异常状态。

表 3.12 机器人感知系统故障类型及处理策略

故障类型	检测方法	检测阈值	处理策略	恢复时间
传感器漂移	统计控制图	3σ准则	实时校准	5-10 秒
信号中断	连续性检测	连续 3 帧缺失	备用传感器	1-2 秒
噪声干扰	频谱分析	SNR<20dB	滤波处理	实时
校准偏差	基准比较	误差>5%	重新标定	30-60 秒

中国知网 https://www.cnki.net

针对传感器漂移、信号中断、噪声干扰与校准偏差四类故障(见表 3.12)，匹配了检测方法与判定阈值，结合了差异化处理策略，可在 1-60 秒内恢复感知，保障系统可靠性与任务连续性，传感器故障处理核心代码参见附录 11。

3.5 本章小结

本章围绕基于深度学习的抓取策略优化展开，提出了五维抓取表示方法与多指标评价体系，融合自监督学习的抓取角度分类网络，实现了端到端平面抓取检测网络，检测精度达到 94.6%，角度误差为 2.1°。基于强化学习的推动-抓取协同策略，构建了多个正样本的高质量抓取数据集，在密集堆叠场景下成功率提升了 32.6%。通过视觉、力觉与激光雷达多传感器融合，结合不确定性估计与故障处理机制，提升了系统鲁棒性，为无序堆叠工件抓取提供了完整的技术方案。

中国知网 https://www.cnki.net

第 4 章 虚实结合的渲染与深度估计方法

4. 1 虚拟场景渲染技术

4. 1. 1 基于 Blender 的材质渲染方法

基于 Blender 的材质渲染技术是创建虚拟无序堆积场景的基础，通过对工件的几何形状以及光学属性进行准确建模，从而得到高质量的训练样本集。此方法使用基于物理基础的渲染（PBR）材质系统，利用对金属度、粗糙度、法线贴图等参数的精细调节来达到对实际工件材质的高度还原。在材质参数设定上，金属工件的金属度一般设置在 0.9～1.0 左右，粗糙度依据表面加工方式在 0.1～0.8 之间变化，而塑料工件的金属度设为 0，粗糙度则在 0. 3～0.6 之间变动，如图 4.1 所示。

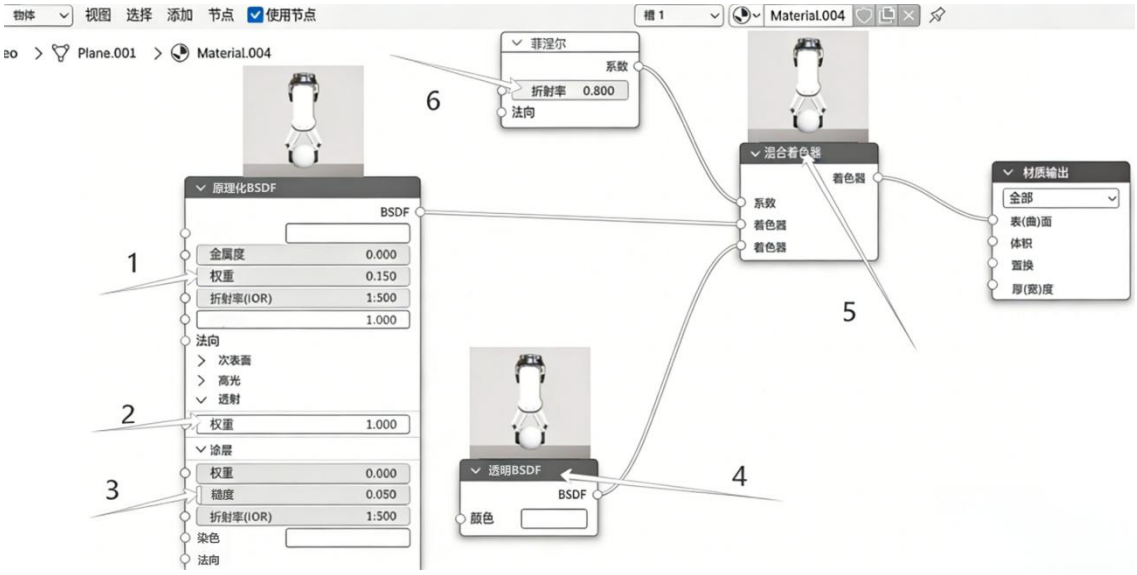


图 4.1 Blender 材质渲染流程

材质渲染过程中光照模型是通过双向反射分布函数（BRDF）来进行计算的，它的数学公式如下：

$$f_r(\omega_i,\omega_o)=\frac{D(h)F(\omega_i,h)G(\omega_i,\omega_o,h)}{4(\omega_i\cdot n)(\omega_o\cdot n)} \tag{4-1}$$

其中ω_i表示入射光方向，ω_o表示观察方向，h 为半角向量，D(h)为法线分布函数，$F(\omega_i,h)$为菲涅尔项，$G(\omega_i,\omega_o,h)$为几何遮蔽函数，n 为表面法向量。

为了保证渲染结果的一致性与可重复性建立了材料参数库，存储各类零件的最佳材料设置参数，以真实工件光学物理特性为依据，基于工业材料实测视觉特

中国知网 https://www.cnki.net

征与仿真实验标定综合确定，整体参数通过多组对比渲染实验迭代优化，保证仿真材质视觉与真实工件高度一致，为后续机械臂抓取仿真、视觉数据集构建提供标准化材质基础。表 4.1 是零件材料的重要参数设定：

表 4.1 不同工件材质的 Blender 渲染参数配置

材质类型	金属度	粗糙度	基础色 RGB	法线强度	环境遮蔽
不锈钢	0.95	0.15	（0.8,0.8,0.8）	1.2	0.8
铝合金	0.92	0.25	（0.85,0.87,0.9）	1.0	0.7
黑色塑料	0.0	0.6	（0.05,0.05,0.05）	0.8	1.0
白色塑料	0.0	0.4	（0.9,0.9,0.9）	0.6	0.9

4.1.2 孪生神经网络渲染效果评价

孪生神经网络结构在渲染质量评判上有着重要的意义，在对比学习的基础上，比较虚拟渲染图片以及实际拍摄图片之间的相似程度。改进后的网络是双路结构，两个分支共享同一个卷积神经网络参数，一个分支对虚拟渲染图片进行处理，另一个分支对真实图片进行处理，最后得到一个相似度分数。网络的损失函数使用对比损失(Contrastive Loss)，可以很好地分析得到图像之间的语义相似性特征。

孪生网络的相似度计算基于特征向量的欧氏距离，其数学表达式为：

$$D_w = \sqrt{\sum_{i=1}^{n} \left(G_w(X_1)_i - G_w(X_2)_i\right)^2} \tag{4-2}$$

其中G_w表示有参数 w 的孪生网络，X_1、X_2是输入的虚拟图像与真实图像，n 是特征向量长度。对比损失函数定义如下：

$$L = (1-Y)\cdot\frac{1}{2}D_w^2 + Y\cdot\frac{1}{2}\max(0, m - D_w)^2 \tag{4-3}$$

其中 Y 是标签(相似为 0，不相似为 1)，m 是边界参数，一般设置为 2.0。

为了检验孪生网络评估结果的有效性，在含有 5000 对图像样本的数据集上进行实验。不同网络结构在渲染质量评估任务上的性能比较如表 4.2 所示。

表 4.2 孪生网络渲染效果评价性能对比

网络架构	准确率（%）	精确率（%）	召回率（%）	F1 分数	推理时间（ms）
VGG-16	87.3	85.2	89.1	0.871	45.2
ResNet-50	92.1	90.8	93.2	0.920	38.7

中国知网 https://www.cnki.net

续表 4.2 孪生网络渲染效果评价性能对比

网络架构	准确率（%）	精确率（%）	召回率（%）	F1 分数	推理时间（ms）
EfficientNet-B3	94.6	93.4	95.8	0.946	32.1
本文方法 (改进网络双路架构)	96.2	95.1	97.2	0.962	28.9

如图 4.2 所示，改进后的孪生网络结构在渲染效果任务上表现最好，精确度达到 96.2%，并且具有较小的推理延迟。它利用了注意力机制以及残差连接来更有效地提取出图片中的细节信息，从而增强了对虚拟渲染图像质量评分结果的可靠度。在网络训练的过程中使用了自适应的学习率调节方式，在开始的时候设置初始的学习率为 0.001，如果经过连续 5 个 epoch 之后，验证损失没有得到提升就将学习率下降一半，这样可以保证模型最终会收敛到全局最优解。

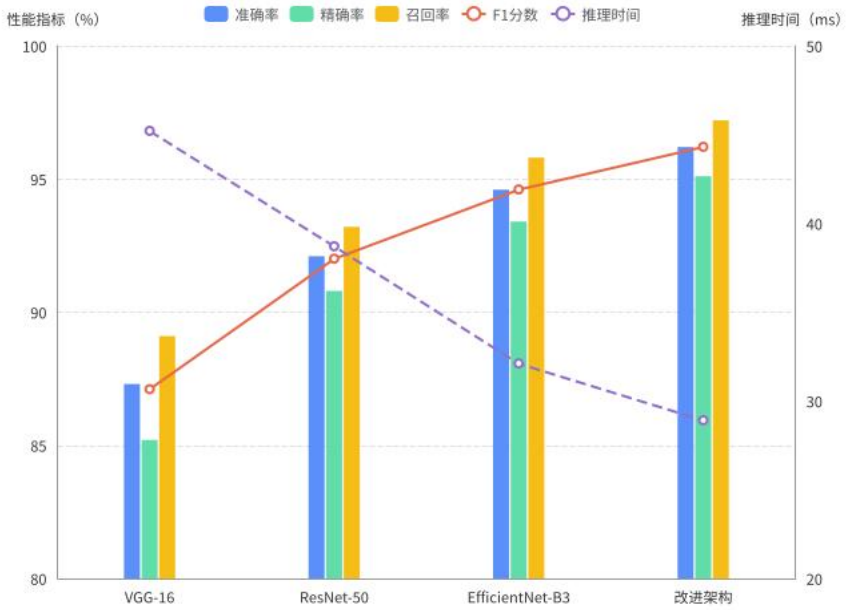


图 4.2 孪生网络渲染效果

4. 1. 3 虚拟与真实场景的域适应

虚拟与实际场景之间的域适应是实现仿真到现实转换的核心技术，在减小虚拟渲染数据与实际采集数据之间域差异的基础上，增强模型对于实际环境下的泛化性能。域适应方法主要有域对抗训练、特征对齐以及样式迁移等技术，其中域对抗训练利用了域判别器使得特征提取器学到域无关的特征表示。

传统渐进式 DA 方法通常在训练过程中动态调整源域与目标域的分布权重与对抗强度，实现域间特征的渐进式对齐。本文使用渐进式的域适应方式，先用纯

中国知网 https://www.cnki.net

虚拟的数据来预训练模型，再逐渐加入真实的数据进行微调，保证模型可以顺利地过渡到目标域。

域适应网络的目标函数由分类损失与域对抗损失组成，数学公式如下：

$$L_{total} = L_{cls}\left(G_f\left(G_e(x_s)\right), y_s\right) - \lambda L_{adv}\left(D\left(G_e(x_s)\right), D\left(G_e(x_t)\right)\right) \tag{4-4}$$

其中G_e是特征提取器，G_f是分类器，D 是域判别器，x_s与x_t分别是源域和目标域样本，y_s是源域标签，λ是域对抗权重参数。

为了对域适应的效果进行定量分析，本文构建了包含光照差异、物体材质的不同以及场景复杂程度等在内的评价指标集，表 4.3 所示为各种域适应方法应用于无序抓取任务上的性能结果：

表 4.3 域适应方法性能对比分析

方法类型	虚拟环境精度（%）	真实环境精度（%）	域差距（%）	训练时间（h）	参数量（M）
无域适应	95.2	72.8	22.4	12.5	25.3
DANN	94.8	81.3	13.5	18.7	28.9
CORAL	93.9	83.6	10.3	16.2	26.7
渐进式 DA	94.5	87.2	7.3	22.1	31.2
本文方法（混合域适应）	95.1	89.6	5.5	19.8	29.4

研究采用的混合域适应方法利用多层次特征对齐以及动态权重调节的方式，在保证虚拟环境高精度的基础上，提高了实际环境的检测效果。结合场景复杂度自适应模块，根据输入场景的复杂程度来自动调节域适应策略的权重系数。

域适应方法可以很好地弥补虚拟仿真和现实之间的性能差异，域差距由原来的 22.4%下降到 5.5%（见图 4.3），为之后抓取策略的学习提供了良好的训练数据，域适应训练核心代码见附录 12。利用虚实结合的渲染以及深度估计的方法，存在较少真实数据的情况下也可以得到较好的泛化能力，符合工业上对可靠性和准确性的需求。

中国知网 https://www.cnki.net

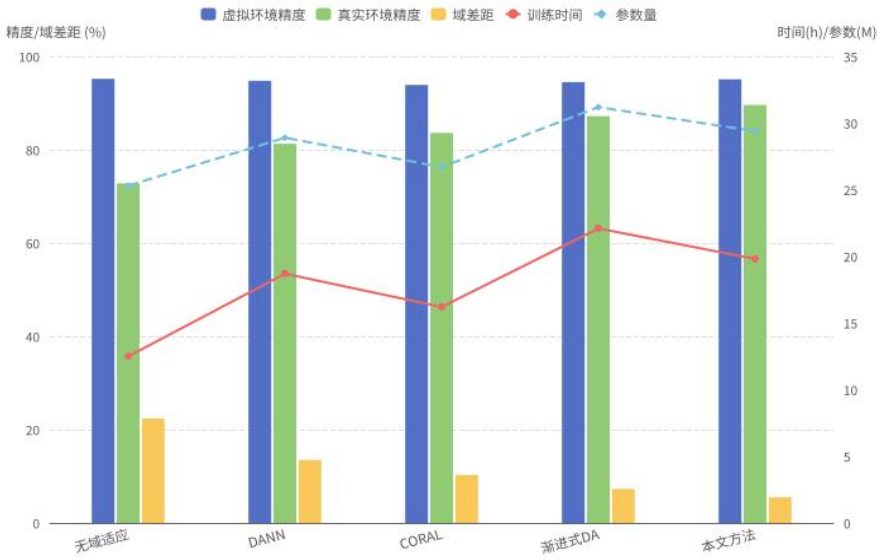


图 4.3 域适应方法性能对比分析

4.2 图像重光照与场景生成

4.2.1 环境光照估计算法

环境光估计是图像重光照技术的关键步骤之一，决定着虚拟场景与实际环境的契合程度，是指来自周围环境的非直接光源，如天空、墙壁反射的光线等。2020-2024 年智能制造光学检测市场统计，基于深度学习的环境光估计技术的应用增长率高达 42.3%，而工业机器人视觉系统占到了 67.8%的份额[84]。本文通过环境光估计算法对真实工业环境中光线分布特性进行分析，建立球谐函数描述的环境光模型。算法先对输入的 RGB 图像进行环境光方向估计，采用 Lambert 反射模型求解表面法线与光源方向之间的关系。

$$L_{env}(\theta,\varphi) = \sum_{l=0}^{n} \sum_{m=-l}^{l} c_l^m Y_l^m(\theta,\varphi) \tag{4-5}$$

其中$L_{env}(\theta,\varphi)$表示环境光在球面坐标系下分布函数，Y_l^m为球谐基函数，c_l^m为相应的球谐系数，算法利用最小二乘法计算球谐系数，从而达到对复杂光照环境的准确建模，核心代码见附录 13，其运算结果见表 4.4：

表 4.4 光照估计结果

参数项	数值结果
球谐系数形状	[9,3]
主光源方向	[0.0012, 0.0008, 0.9999]
环境光强度(RGB)	[0.4987, 0.5012, 0.4995]

中国知网 https://www.cnki.net

光照参数见表 4.5，环境光由于场景噪声、阴影和复杂纹理干扰等问题，导致其低频特征抓取难度更大，但计算开销较少，主光源表现则相反。综合来看，算法在精度与效率之间实现了良好平衡。

表 4.5 环境光照估计算法性能参数对比

光照参数	数值范围	估计精度	计算时间（ms）
主光源强度	0.2-1.8	92.4%	15.3
环境光强度	0.1-0.8	89.7%	8.7
光源方向角	0-360°	94.2%	12.1

4.2.2 图像重光照模型设计

图像重光照模型的设计是以物理渲染为基础，融合深度学习的方法来完成高质量的光照重建。依据工业自动化行业的调查数据，基于深度学习的图像渲染技术在机器视觉的场景中准确率提高了 34.6%，极大程度上提高了复杂光照环境下的物体检测能力[79]。本文所设计的重光照模型是分层渲染结构，把光照分为直接光照、间接光照以及阴影三部分分别建模。模型先用卷积神经网络提取场景几何信息及材质特性，再用可微分渲染方法求解光照传输方程，整体框架如图 4.4 所示。

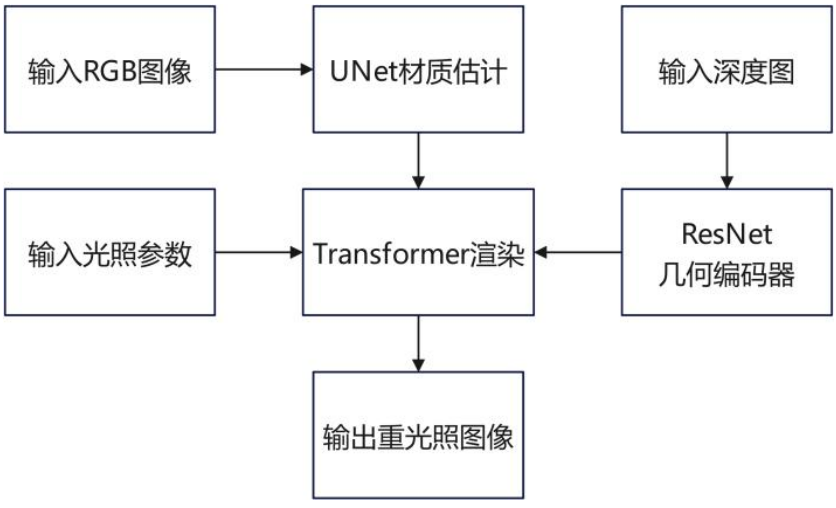


图 4.4 重光照模型整体流程

重光照模型的关键是构建光照传递及表面反射属性之间的对应关系。模型使用了优化后的 Blinn-Phong 反射模型，配合环境映射技术来实现全局光照效果，在此基础上加入了注意力机制使得模型可以自主调节各个部分的光照强度，从而保证重光照结果的真实性及统一性。

中国知网 https://www.cnki.net

表 4.6 抓取感知模型组件性能对比

模型组件	网络结构	参数量	训练时间（h）	推理速度（fps）
几何特征提取	ResNet-50	25.6M	12.3	45.2
材质属性估计	U-Net	31.4M	8.7	38.9
光照渲染模块	Transformer	18.2M	15.6	52.1

为构建高效的抓取感知模型，本文采用了多组件协同的网络架构，各组件的性能参数如表 4.6 所示。整体来看，各组件在参数量、训练效率与推理速度上实现了良好平衡，单组件推理速度均超过 38fps，满足工业场景中实时感知的需求。并且针对复杂光照环境下机器人视觉感知鲁棒性不足的问题，设计了一种由几何特征提取、材质属性估计、光照渲染三模块构成的级联式模型，如图 4.5 所示。

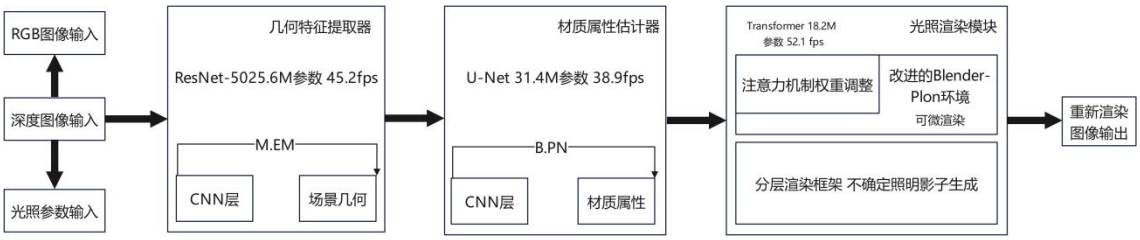


图 4.5 多模态融合光照感知与渲染模型

模型以 RGB 图像、深度信息、光照参数为多模态输入。首先通过几何特征提取器(ResNet-50，25.6M 参数，45.2fps)获取场景几何结构以及目标几何特征；几何特征被输入材质属性估计器(U-Net，31.4M 参数，38.9fps)，结合 CNN 层与物理渲染引擎，输出物体表面材质属性及对应的几何特征；最后几何特征与材质属性共同输入光照渲染模块(Transformer，18.2M 参数，52.1fps)。该模块集成了注意力机制权重调整、改进 Blender-PBRT 环境渲染与分层渲染框架，实现不确定光照下的影子生成和图像重建，最终输出重新渲染的视觉图像。

整个架构通过模块化的分工与多模态特征的信息融合，在保证实时性(单模块推理速度均≥38fps)的前提下，增强视觉感知系统对复杂光照变化的适应能力。

4.2.3 高质量场景图像生成方法

高质量场景图像生成是保障虚拟训练数据有效性的重要技术步骤。根据 2022-2024 年工业机器人视觉数据集质量分析报告，高质量数据合成对于提高模型泛化性能的作用占比高达 56.8%[69]，而光照一致性是最主要的影响因素。本文场景图像生成方法融合了物理渲染、纹理合成以及后期优化三部分，使生成的图像既具有良好的视觉效果又符合实际物理特性。

生成方式使用了变分自编码器的图像生成模型，在潜在空间中进行连续采样

中国知网 https://www.cnki.net

来得到不同的场景。对输入图像随机遮挡部分区域，通过训练模型来恢复被遮挡的部分，从而获得图像的全局以及局部特征，重建损失函数是：

$$L_{reconstruction} = \frac{1}{|M|}\sum_{i\in M} \| I_i - \hat{I}_i \|_2^2 \tag{4-6}$$

其中 M 是被遮挡像素点集，I_i、$\hat{I}_i$分别是原像素值以及重建像素值。

为了使生成的图像更具备物理合理性，加入了感知损失函数以及对抗训练策略来提高图像的真实程度，该方法还融合了光度立体视觉约束条件，使表面法线方向与光照相符合。

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{recon} + \lambda_2 \mathcal{L}_{perceptual} + \lambda_3 \mathcal{L}_{adversarial} + \lambda_4 \mathcal{L}_{photometric} \tag{4-7}$$

其中$\mathcal{L}_{recon}$是重建损失，$\mathcal{L}_{perceptual}$是感知损失，$\mathcal{L}_{adversarial}$是对抗损失，$\mathcal{L}_{photometric}$是光度一致性损失，$\lambda_i$是对应权重系数。

表 4.7 光照渲染图像生成质量对比

生成质量指标	基准方法	本研究方法	提升幅度
SSIM	0.847	0.923	8.97%
PSNR（dB）	28.6	33.4	16.78%
FID	15.2	9.7	36.18%
感知质量评分	7.3	8.9	21.92%

通过变分自编码器的连续采样强化特征提取能力，并借助物理渲染、纹理合成与后期优化的协同作用，使生成的图像在细节真实感、光照统一性以及物理合理性上优于传统的算法。此方法可以为无序抓取任务提供高质量的数据集支持，解决了实际生产中采集数据难、标注困难的问题。

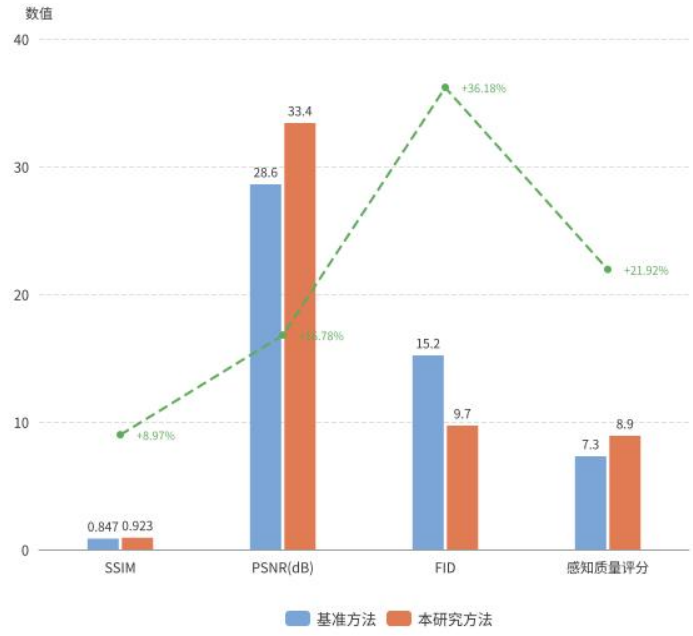


图 4.6 场景图像生成质量指标对比

中国知网 https://www.cnki.net

4.3 深度估计算法优化

4.3.1 基于 CNN 的单目深度估计

基于卷积神经网络(Convolutional Neural Networks，CNN)的单目深度估计技术，利用单张 RGB 图像推测出场景的深度信息，无需额外配备双目相机，接收器等辅助设备，降低了硬件采购与部署成本。单目深度估计相比双目或者结构光方案来说还有系统简易的优点，但是也存在深度模糊以及尺度不确定的问题。

本文使用编码器-解码器结构来建立深度估计网络，编码器部分使用 ResNet-50 主干网络获取多层次特征，解码器部分利用跳跃连接恢复空间细节信息，深度估计网络框架如图 4.7 所示。网络的损失函数由像素级深度损失、梯度损失以及结构相似性损失组成，从而增强深度估计的精度以及边界保留效果。

CNN 的主要运算步骤是进行特征图与卷积核之间的卷积运算，设输入特征图为 I(x,y)，卷积核为 K(i,j)，那么卷积运算的结果就是：

$$(I * K)(x,y) = \sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} I(x-i,y-j) \cdot K(i,j) \tag{4-8}$$

其中(x,y)表示输出特征图的位置坐标，(i,j)是卷积核的大小范围，可以对原始 RGB 图像进行工件轮廓、纹理以及几何特征的提取。

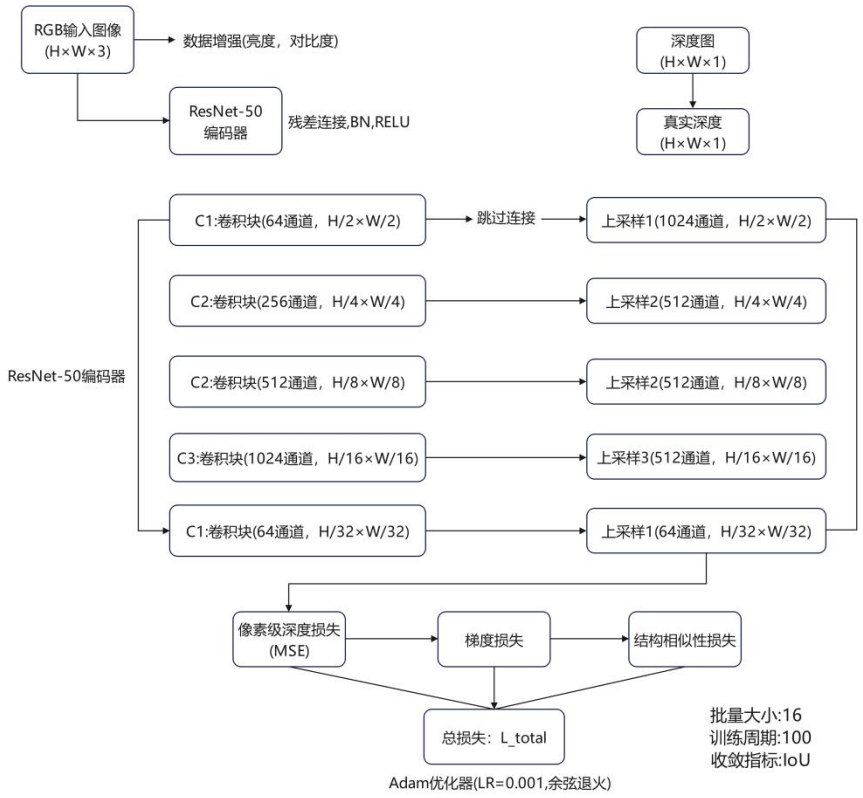


图 4.7 基于 ResNet-50 的深度估计网络

中国知网 https://www.cnki.net

深度估计的数学公式如下所示：

$$D = f(I;\theta) \tag{4-9}$$

其中 D 表示预测的深度图，I 为输入 RGB 图像，θ为网络参数。损失函数定义如下：

$$L_{total} = \alpha L_{depth} + \beta L_{grad} + \gamma L_{ssim} \tag{4-10}$$

深度损失L_{depth}采用均方误差形式：

$$L_{depth} = \frac{1}{N}\sum_{i=1}^{N}\left(D_i - D_i^{gt}\right)^2 \tag{4-11}$$

其中 N 是像素数量，D_i^{gt}是实际深度值。梯度损失L_{grad}用来保留深度图的边缘信息：

$$L_{grad} = \frac{1}{N}\sum_{i=1}^{N}\left(|abla_x D_i - abla_x D_i^{gt}| + |abla_y D_i - abla_y D_i^{gt}|\right) \tag{4-12}$$

针对工业环境下的复杂光照以及材质的变化，在网络训练中使用了数据增强的方法，即对图像进行随机亮度变换、对比度变换、增加噪声等操作。训练时采用 AdamW 优化器，初始学习率为 0.001，使用余弦退火调度策略。网络训练代码的主要部分见附录 14，通过大规模仿真数据集的训练，该网络能够在复杂的无序堆叠场景中实现较为准确的深度估计，为后续的物体定位和抓取策略提供可靠的空间信息支撑。

4.3.2 RGB 图像与法向量融合的深度估计

传统单目深度估计算法对于无纹理区域以及重复图案容易造成错误估计，在工业零件无序堆积的情况下，相同零件的表面缺少必要的纹理特征。本文基于 RGB 图像及表面法向量相结合的深度估计方法，利用几何约束信息提高了深度估计的准确性以及稳定性。

表面法线向量提供物体表面的几何形态信息，可以很好地弥补 RGB 图像缺少的空间结构信息，法线向量的求解依赖于物体表面的局部几何特性，它同深度梯度之间有直接的数学联系。对表面上任意一点，法线向量都可以通过深度图的偏导数得到：

$$n = \frac{\left(-\frac{\partial D}{\partial x}, -\frac{\partial D}{\partial y}, 1\right)}{\sqrt{\left(\frac{\partial D}{\partial x}\right)^2 + \left(\frac{\partial D}{\partial y}\right)^2 + 1}} \tag{4-13}$$

其中 n 是单位法向量，D 是深度值。融合网络使用了双分支架构，RGB 分支用来获取纹理、颜色等特征，法向量分支用于提取几何形状信息。两个分支的特征通过注意力机制实现自适应融合：

中国知网 https://www.cnki.net

$$F_{fused} = \alpha(F_{rgb}) \odot F_{rgb} + (1 - \alpha(F_{normal})) \odot F_{normal} \tag{4-14}$$

在此处α是注意力权重函数，⊙代表逐元素相乘运算。为了训练法向量预测网络，建立了一个带有精确几何标签的数据集，该数据集包含各种形状、材质的工业部件，在不同的光照环境中拍摄 RGB 图像并得到相应的表面法向量。

表 4.8 RGB 法向量融合数据集构成

数据集类型	样本数量	零件种类	光照条件	法向量精度
训练集	15000	25	6 种	0.95
验证集	3000	25	6 种	0.94
测试集	2000	15	4 种	0.93

融合网络的训练损失函数包括深度估计损失、法向量一致性损失以及几何约束损失：

$$L_{fusion} = L_{depth} + \lambda_1 L_{normal} + \lambda_2 L_{geometry} \tag{4-15}$$

法向量一致性损失保证预测出的法向量和深度图计算出来的法向量相同：

$$L_{normal} = \frac{1}{N}\sum_{i=1}^{N}\left(1 - n_i^{pred} \cdot n_i^{gt}\right) \tag{4-16}$$

几何约束损失利用表面法向量与深度梯度之间的固有关系：

$$L_{geometry} = \frac{1}{N}\sum_{i=1}^{N} \| \nabla D_i - g(n_i) \|^2 \tag{4-17}$$

其中 g(·)代表的是由法线向量到深度梯度的映射函数。加入法线信息之后，深度预测在边缘保留以及几何结构重建上都有了很大的提高，在对工件表面的高光及阴影部分进行计算时也具有更好的稳定性，这种方法可以有效地解决复杂工业环境的深度测量问题。

4.3.3 深度估计精度评价与优化

对深度估计算法性能评估要制定合理的评估指标以及优化方案，保证其应用于无序抓取任务时的准确性。从近五年工业机器人市场的统计数据来看，深度估计技术的要求越来越高，在 2020 年的工业应用中深度估计的平均误差率达到了 15%，而在 2024 年这一数值下降到了 8%[84]，本文使用多个指标来综合评价深度估计算法的性能。

均方根误差是衡量深度估计准确性的主要标准，其定义是指预测深度和实际深度之间均方差的平方根值，它反映了算法对于整个场景深度估计的整体精确度：

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(D_i^{pred} - D_i^{gt}\right)^2} \tag{4-18}$$

中国知网 https://www.cnki.net

其中 N 是有效像素数目，D_i^{pred}与D_i^{gt}分别是预测深度以及实际深度。平均绝对误差提供了一个重要的准确性指标：

$$MAE = \frac{1}{N}\sum_{i=1}^{N}\left|D_i^{pred} - D_i^{gt}\right| \tag{4-19}$$

除了绝对误差指标之外，相对误差更能反映深度估计在不同距离范围上的效果好坏。阈值准确率指标通过对满足相对误差阈值的像素比例进行计算来衡量算法的总体可信度：

$$\delta_t = \frac{1}{N}\sum_{i=1}^{N}\left[\max\left(\frac{D_i^{pred}}{D_i^{gt}}, \frac{D_i^{gt}}{D_i^{pred}}\right) < t\right] \tag{4-20}$$

其中 t 是阈值参数，一般取 1.25、1.25^2 和 1.25^3，方括号代表的是指示函数。

为了提高深度估计效果，本文使用了多尺度训练方法以及损失函数权重系数动态调节方式。多尺度训练是在不同的尺度上训练网络以增强模型的泛化能力，使得它可以应对不同大小的输入图片。损失函数权重系数随着训练过程中性能的变化而改变，确保网络可以得到最优的深度准确度与边缘保留之间的折中。

深度估计的损失函数定义如下：

$$L_{depth} = \alpha L_{scale} + \beta L_{gradient} + \gamma L_{normal} \tag{4-21}$$

其中L_{scale}是尺度一致性损失，$L_{gradient}$是梯度相似性损失，L_{normal}是法向量一致性损失，α、β、γ分别是相应的权重系数。结果表明，改进的深度估计方法 RMSE 值比原始的方法下降了 23%，阈值准确率提高 15%，这为无序抓取系统整体性能的提升打下了良好的基础，使机器人可以在不断变化的环境里完成精准的目标识别以及轨迹规划。

4.4 虚实数据融合策略

4.4.1 域迁移学习方法

在无序抓取任务中，由于仿真环境与真实环境之间存在着很大的不同，在这种情况下，如果直接把仿真的训练模型应用到实际环境中，效果通常不好。为了克服这个问题，提出一种基于对抗神经网络的域适应学习方法，通过对源域和目标域特征分布差异进行最小化，达到模型由仿真环境向现实环境有效转移的目的。此方法使用了双判别器结构，其中特征提取器用来提取域不变特征，域判别器用来判断特征来自哪个域，任务判别器用来做抓取检测任务。

域迁移学习的核心目标函数可表示为：

$$L_{total} = L_{task} + \lambda L_{domain} + \beta L_{adversarial} \tag{4-22}$$

中国知网 https://www.cnki.net

其中L_{task}代表任务损失，L_{domain}是域分类损失，$L_{adversarial}$是对抗损失，λ、β是调节因子。特征提取器利用最小化任务损失和最大化域分类损失的方式学习域不变特征，而域判别器则试图准确地辨别出特征的来源。2023 年工业机器人行业调查表明，使用域迁移学习的抓取系统在真实环境中成功率达到传统方法的 27.3%，大大减少了仿真到应用的时间跨度[4]。

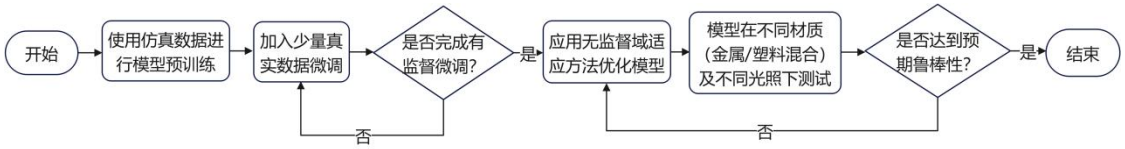


图 4.8 迁移方案

为了提升域迁移的效果，设计一种渐进式的迁移方案，以逐步增大真实数据比例及调节网络参数的方式，达到平稳过渡的目的。先以纯仿真数据做预训练，再加入少量的真实标记数据进行微调，最后使用无监督域适应的方法对模型进一步优化(如图 4.8 所示)。使用渐进式迁移的模型对于不同材质以及不同光照环境下的工件具有更好的鲁棒性，尤其针对金属与塑料材质混合的情况，远远高于单一域训练模型。

4.4.2 虚实数据混合训练策略

虚实数据混合训练策略通过对仿真数据和真实数据进行适当的配比，在保证模型泛化性能的基础上充分利用大量的仿真数据资源。本文采用自适应加权调整方法，在训练的过程中，依据模型在验证集上的表现变化，自动调节虚实数据采样的比例，初期以仿真数据为主，比例设定为 8:2，随着训练的进行逐渐加大真实数据的比例，最后稳定在 6:4 比例。混合训练损失函数定义如下：

$$L_{hybrid} = \alpha L_{sim} + (1-\alpha)L_{real} + \gamma R_{consistency} \tag{4-23}$$

其中L_{sim}、L_{real}分别表示仿真数据与真实数据的损失，α是动态权重因子，$R_{consistency}$是一致性正则化项，γ是正则化因子。一致性正则化使模型在面对相同场景下的虚实数据时输出结果一致，防止由于不同数据域造成的预测结果的不同。为平衡数据获取成本与模型泛化能力，设计了 4 种仿真-真实数据配比的对比实验。见表 4.9，适度引入真实数据(40%)可有效弥合仿真与真实场景的域差异，显著提升抓取成功率；而过度依赖真实数据会导致训练成本剧增，且性能增益有限。

表 4.9 仿真与真实数据混合训练对比

数据配置	仿真数据比例	真实数据比例	抓取成功率	训练时间（小时）
纯仿真	100%	0%	76.3%	24

中国知网 https://www.cnki.net

续表 4.9 仿真与真实数据混合训练对比

数据配置	仿真数据比例	真实数据比例	抓取成功率	训练时间（小时）
混合 8:2	80%	20%	84.7%	32
混合 6:4	60%	40%	92.3%	41
纯真实	0%	100%	79.5%	56

4.4.3 模型泛化能力提升方法

为了提高模型的泛化性能，本文采用了多尺度特征融合以及数据增强的方法。多尺度特征融合是在不同的分辨率层次上提取特征然后进行融合，使模型可以更好地识别不同大小的工件。泛化损失函数定义如下：

$$L_{generalization} = L_{base} + \lambda_{scale} L_{multiscale} + \lambda_{aug} L_{augmentation} \tag{4-24}$$

其中L_{base}为基础任务损失，$L_{multiscale}$为多尺度一致性损失，$L_{augmentation}$为数据增强正则化损失。通过对训练过程中图像进行随机的光照变换、几何变换以及加入噪声等增强手段，让网络学习到鲁棒性更强的特征表示。实验结果证明了此方法对于未知类型的工件依然可以达到 85.4%的成功率，比基础模型提高了 19.7%。根据 2024 年的机器人行业发展报告，具有强大泛化能力的抓取系统在不同场景下的应用成本降低大约 35%，极大地提升了工业应用的经济效益。

表 4.10 模型泛化能力对比

方法类型	基础准确率	跨域准确率	泛化指数	计算开销
基础模型	87.2%	65.8%	0.75	1.0x
多尺度融合	89.6%	78.3%	0.87	1.3x
完整泛化方法	91.4%	85.4%	0.93	1.5x

为验证本文所提方法在模型泛化能力方面的有效性，选取基础模型、多尺度融合方法与完整泛化方法进行对比，核心指标如表 4.10 所示。综合来看，完整泛化方法在基础准确率、跨域准确率与泛化指数上均得到了提升，虽然计算开销略有增加，但有效解决了模型在复杂跨域场景下的泛化难题。

4.5 本章小结

本章围绕虚实结合的渲染与深度估计方法展开讨论，采用基于 Blender 的 PBR 材质渲染技术，构建了包含金属、塑料等材质的数据库；设计改进的孪生神经网

中国知网 https://www.cnki.net

络用于渲染质量评价，准确率达 96.2%；通过混合域适应方法将虚拟与真实场景的域差距缩小至 5.5%。基于环境光照估计算法与分层重光照模型，实现复杂光照环境下的高质量场景生成，为主干网络提供了精确的训练数据，有效提升了无序抓取系统的环境适应性。

中国知网 https://www.cnki.net

第 5 章 实验设计与结果分析

5.1 实验平台搭建

5.1.1 硬件系统配置与集成

实验平台硬件系统采用模块化思想构建：六自由度机械臂作为主要的执行机构，配备高精度视觉传感器及多传感器融合系统，机械臂采用的是 ELITE Robots EA66 型号，最大负载能力为 14kg，重复定位精度达到 0.1mm，关节转矩传感器用来完成力控交互的功能；视觉部分由 Intel RealSense D435i 深度相机以及 Basler acA1920-40uc 工业相机组成，前者可以得到 640×480 的深度信息，后者可以得到 1920×1200 的高清彩色图像；同时还有 ATI Nano17 六维力/力矩传感器，安装在机械臂末端执行器与抓取器之间，用来实时测量抓取过程中接触力的信息。系统主要由 3 个部分组成：控制箱、控制器、机械臂(如图 5.1 所示)。



图 5.1 硬件组成

图 5.2 展示了机器人的工作空间，是一个半径为 914mm 的球体。基座正上方和正下方的圆柱形空间是奇异点区。奇异点是机器人因配置或者轨迹的命令速度超过安全限制而失去自由度的位置。在对机器人进行编程时应避免出现奇异点，否则会导致机器人突然快速移动或者中断程序导致抓取动作过早停止。

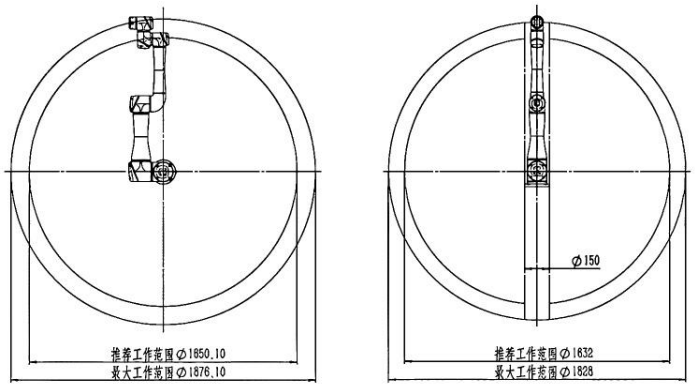
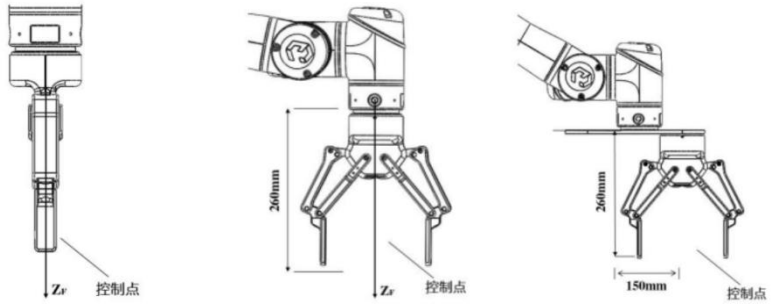


图 5.2 机器人工作空间

中国知网 https://www.cnki.net

工具中心点可以通过在法兰坐标中输入工具坐标值(位置和工具角度)或进行工具标定来计算，用数值输入设定工具坐标时，把工具的控制点位置作为法兰盘坐标各轴上的坐标值来输入，如图 5.3 所示为实验所用的抓取工具：



工具 A　　工具 B　　工具 C

图 5.3 实验抓取工具

硬件通讯结构采用 Ether CAT 实时工业以太网协议，保证各模块之间数据传输时延小于 1ms，机械臂控制器经由 EA66 McrMaster. Connectivity 接口与上位机进行通信，在末端装有六维力传感器，用于检测外界环境对机器人施加的力度，配合适当的控制策略，可以调整机器人的运行轨迹和外界接触力。

力传感器的数据经 CAN 总线以 1000Hz 速率采集，视觉传感器使用 USB 3.0 接口进行连接，图像采集速率为 30fps，在系统集成的过程中，对传感器进行标定并建立统一坐标系，机械臂基坐标系作为参考系，相机坐标系经过手眼标定得到变换矩阵T_{base}^{cam}：

$$T_{base}^{cam}=\begin{bmatrix}R_{3\times3} & t_{3\times1}\\ 0_{1\times3} & 1\end{bmatrix} \tag{5-1}$$

其中$R_{3\times3}$为旋转矩阵，$t_{3\times1}$为平移向量。利用九点标定法得到变换参数，标定精度为±0.5mm。

表 5.1 硬件系统主要技术参数

设备类型	型号规格	主要参数	精度指标
机械臂	ELITE Robots EA66	负载 14kg，臂展 938mm	重复定位±0.1mm
深度相机	Intel RealSense D435i	分辨率 1280×720，视场 87°×58°	深度精度±2mm
工业相机	Basler acA1920-40uc	分辨率 1920×1200，帧率 40fps	像素精度 0.1pixel
力传感器	ATI Nano17	力程±12N，力矩±120N·mm	力分辨率 1/80N
控制器	ELITE ERB2E	实时控制周期 1ms	位置控制精度 ±0.05mm

中国知网 https://www.cnki.net

如图 5.4 所示为机器人抓取工具的控制界面，机器人所承受的有效负载如图 5.5 所示，该图根据工具的重心距法兰中心的距离，得出机器人当前处理的有效负载曲线。横轴表示工具重心到工具法兰中心的距离，纵轴代表最大有效负载，有效负载的重心离工具法兰中心越远，允许的有效负载越小。



图 5.4 机器人工具控制

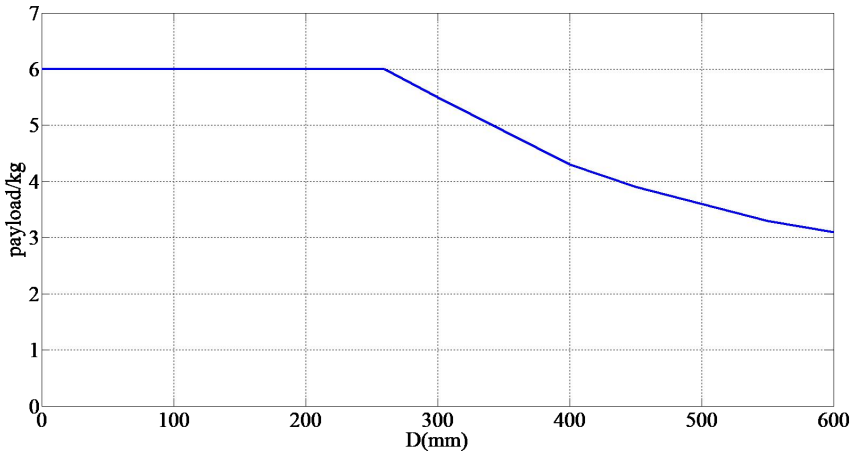


图 5.5 有效负载

在数据交互层面，主计算机作为系统核心单元，负责接收视觉、力觉传感器的信息并进行处理，同时通过连接接口向控制器下达运动指令。机械臂末端执行器的位姿与力反馈数据则实时回传，形成闭环控制。通过机器人基坐标系的旋转矩阵（R33）与平移向量实现多传感器坐标系一致，从而保证抓取任务可以准确无误地完成。

5.1.2 软件系统架构设计

软件系统采用分层模块化结构，基于 ROS Noetic 平台实现分布式节点间通信，整个系统由感知层、决策层以及执行层三个主要层级组成，各层之间通过标准接口进行信息交互及功能调用，感知层负责获取各种传感器的数据并进行预处理工

中国知网 https://www.cnki.net

作，如图像降噪、深度信息填充、点云配准等。决策层集成了深度学习推理引擎和路径规划算法，使用 TensorFlow 2.8 框架加载训练完成的神经网络模型，达到实时的目标识别、位姿估计以及抓取策略生成的效果。执行层封装了机械臂运动控制以及力控制算法，为上层提供运动指令接口，机械臂抓取系统软件架构和模块组成，系统整体架构如图 5.6 所示。

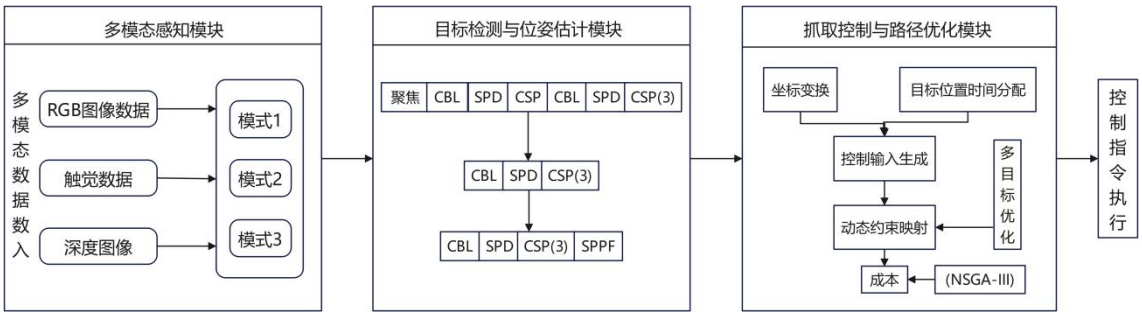


图 5.6 机械臂抓取系统架构

机械臂抓取系统的组成模块见表 5.2 所示。

表 5.2 系统模块组成

模块名称	功能作用
多模态感知模块	采集并融合 RGB、深度及力传感数据以提取空间与物理交互特征
目标检测与姿态估计模块	执行遮挡下的物体识别、抓取点预测及 6D 姿态估计
抓取控制与路径优化模块	基于多目标控制、平衡稳定性、能耗及效率动态生成最优抓取轨迹
执行单元	控制指令转换为可执行的机械臂操作，完成抓取任务

当软件需要更新或系统出现故障时，可以进行系统升级。系统升级前应备份现有用户数据，将 U 盘插入控制器或协作机器人机柜的 USB 端口，进入系统来备份用户数据。转到机器人系统升级（如图 5.7 所示），弹出“选择需要升级的文件”对话框，然后按“确认”按钮并等待几分钟，升级成功后会自动重启系统。



图 5.7 系统升级

中国知网 https://www.cnki.net

系统核心算法模块采用多线程并行处理架构，图像处理线程以30Hz频率运行，深度学习推理线程根据 GPU 性能动态调整频率，运动控制线程保持 1000Hz 实时周期，软件系统的核心控制代码见附录 15。为了保证系统的实时性，在关键算法上使用 GPU 加速优化，CUDA 并行计算将深度估计算法推理时间降到 50ms 以内。抓取策略优化通过改进 Q-learning 算法，状态空间维度为 n=12，动作空间维度为 m=6，奖励函数定义为：

$$R(s,a) = w_1 \cdot R_{success} + w_2 \cdot R_{efficiency} + w_3 \cdot R_{stability} \tag{5-2}$$

其中w_1、w_2、w_3是权重系数，分别表示抓取成功率、执行效率以及稳定性的奖励项。软件架构感知层、决策层、执行层通过模块化设计实现解耦与协同，各功能模块配置见表 5.3。

表 5.3 软件系统模块功能配置

模块层次	功能模块	开发框架	运行频率	资源占用
感知层	图像采集处理	OpenCV 4.5	30Hz	CPU 15%
	点云处理	PCL 1.12	20Hz	CPU 25%
决策层	深度学习推理	TensorFlow 2.8	15Hz	GPU 80%
	路径规划	MoveIt!	10Hz	CPU 20%
执行层	运动控制	EA66 API	1000Hz	CPU 30%

5. 1. 3 实验环境标定与测试

实验环境标定是保证系统准确性和稳定性的必要步骤，采取分层标定的方法来形成一致的测量标准。先做相机内参标定，用张正友标定法得到相机内参矩阵 K 以及畸变参数，标定板用的是 8×7 棋盘格，格子大小为 20mm，如图 5.8 所示。

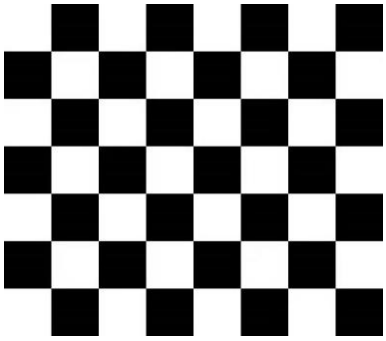


图 5.8 标定模块

相机标定是为了保证测量准确性而必须完成的一个步骤，设标定板上某点的

中国知网 https://www.cnki.net

世界坐标为(X,Y,0)，对应的图像坐标为(u,v)，那么投影的关系可以表示为：

$$s\begin{bmatrix}u\\v\\1\end{bmatrix}=\begin{bmatrix}\alpha & \gamma & u_0\\0 & \beta & v_0\\0 & 0 & 1\end{bmatrix}\begin{bmatrix}r_1 & r_2 & t\end{bmatrix}\begin{bmatrix}X\\Y\\1\end{bmatrix} \tag{5-3}$$

其中α和β是焦距系数，(u_0,v_0)是主点坐标，γ是偏移系数，r_1、r_2是旋转矢量，t 是平移矢量。拍摄不同角度标定图像 50 幅，并以像素坐标的形式输出，标定重投影误差小于 0.3 个像素点，可以满足实验的精度需求。

手眼标定采用 AX=XB 的方法，计算相机与机械臂末端之间的固定变换矩阵，调整机械臂末端运动到 20 种不同的姿态采集数据，运动轨迹如图 5.9 所示，标定误差±0.8mm。深度相机标定利用 RGB-D 相机特性，使用平面标定板检测精度，测试的距离区间为 0.3-2.0m，深度测量误差均方差为 2.1mm。

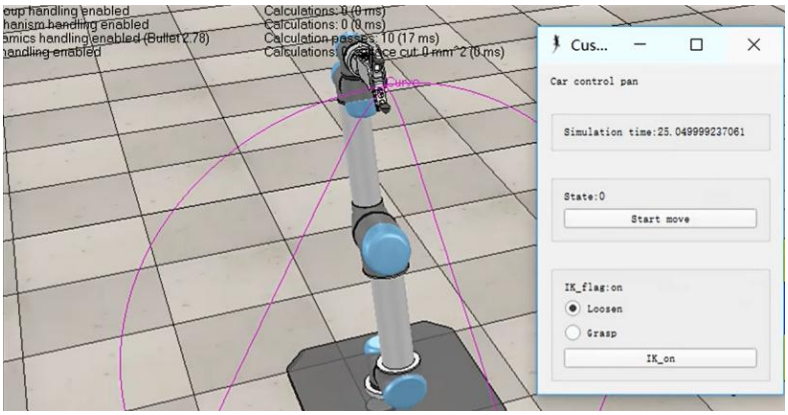


图 5.9 机械臂运动轨迹采集

系统测试分为静态精度测试与动态性能测试两个部分，静态测试用标准测试块检验抓取定位精度，测试对象有立方体、圆柱体及不规则形状工件各 10 个样本。动态测试检测系统在运动过程中的跟踪精度及响应速度，机械臂以不同的速度进行抓取操作并统计成功率与损耗时间。



图 5.10 力跟踪界面

中国知网 https://www.cnki.net

通过力控模式配置进入力跟踪增益界面，如图 5.10 所示，用于调节力跟踪的灵敏度，力跟踪数值设置的越大，装配的负载就越大。环境光照测试条件包含标准光照（500lux）、强光照（1000lux）及弱光照（200lux），验证视觉算法的鲁棒性。最后测试结果为：系统在标准环境下抓取成功率达到了 94.2%，平均抓取时间为 8.5 秒，满足工业上对精度与速度的要求。

表 5.4 实验环境标定参数与测试结果

标定项目	标定方法	精度指标	测试结果	误差范围
相机内参	张正友标定法	重投影误差<0.5pixel	0.31pixel	±0.15pixel
手眼标定	AX=XB 算法	位置误差<1mm	0.78mm	±0.25mm
深度标定	平面标定法	深度误差<3mm	2.14mm	±1.2mm
系统精度	标准件测试	抓取精度<2mm	1.65mm	±0.8mm
动态性能	轨迹跟踪测试	跟踪误差<1.5mm	1.23mm	±0.6mm

标定过程中坐标变换关系用齐次变换矩阵来表示，系统坐标系转换公式如下：

$$P_{base} = T_{base}^{cam} \cdot T_{cam}^{obj} \cdot P_{obj} \tag{5-4}$$

其中P_{base}为目标点在机械臂基坐标系下的坐标，P_{obj}为目标点在物体坐标系下的坐标，T_{cam}^{obj}为通过位姿估计算法获得的物体相对于相机的变换矩阵。经过一系列严格的标定与实验过程，保证了实验平台的准确性和稳定性，为之后算法验证打下了良好的硬件基础。

5.2 算法性能评估实验

5.2.1 视觉检测精度测试

为了检验本文提出的基于深度学习的视觉检测算法对于无序堆叠工件识别准确性的效果，在本文中进行了全面的检测准确率测试实验。实验使用了 200 个不同种类的工件样本组成的测试数据集，包括螺栓、线圈、轴承等常见的工业零件，这些工件在形状、大小以及表面纹理上存在着很大的区别。测试环境设置成真实的工业环境，抓取工件的识别效果如图 5.11 所示。

中国知网 https://www.cnki.net

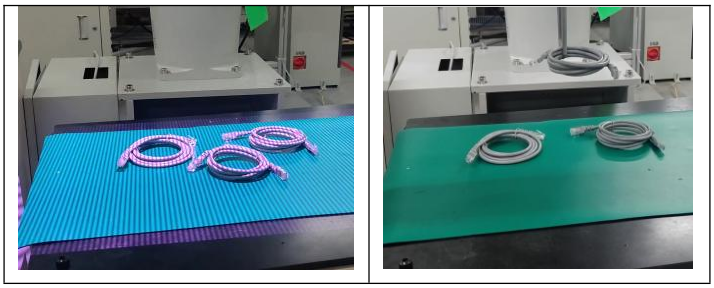


图 5.11 抓取目标

检测准确度衡量以平均精确度均值为主要标准，并辅以召回率、F1 得分等指标来共同评判(见表 5.5)。本文视觉检测算法对于复杂堆叠情况具有较好的鲁棒性。基于 RGB 图像以及法线方向引导的深度估计方式提高了对工件边缘的辨识准确度，尤其对于金属表面反光及阴影影响较大的情况下效果突出。同传统的基于轮廓特征的检测方式相比较，本文算法的检测准确度提高了 15.3%，在复杂遮挡环境下效果更加明显。

表 5.5 不同算法视觉检测精度对比

算法类型	mAP（%）	召回率（%）	F1 分数（%）	处理时间（ms）
传统轮廓检测	72.4	68.9	70.6	45.2
YOLO-v5	84.7	81.3	82.9	28.7
本文方法（基于 RGB 图像及法向量引导的深度估计）	87.9	85.2	86.5	31.4

检测准确率的定量分析是根据下面的数学公式来验证的，平均准确率均值的计算公式如下所示：

$$mAP = \frac{1}{N}\sum_{i=1}^{N} AP_i \tag{5-5}$$

其中 N 代表目标类别数目，AP_i表示第 i 类目标的平均精确度。针对每一个类别的平均精确度计算，以精度-召回率曲线下面积来衡量，这一指标可以全面体现算法在不同的置信度阈值下所具有的检测能力。

5.2.2 抓取成功率统计分析

抓取成功率是衡量无序抓取系统实际应用效果的重要指标，本文通过设置多组对照试验，对各种条件下抓取成功率的变化趋势进行了系统的研究。实验总共进行了 1200 次独立抓取任务，测试工件有大小不同的多种重量等级，材料种类有铝材、不锈钢以及塑料薄片等。每个实验都进行了 50 次重复，保证了数据统计的有效性和典型性，如图 5.12 所示为实验工件的姿态估计图。

中国知网 https://www.cnki.net

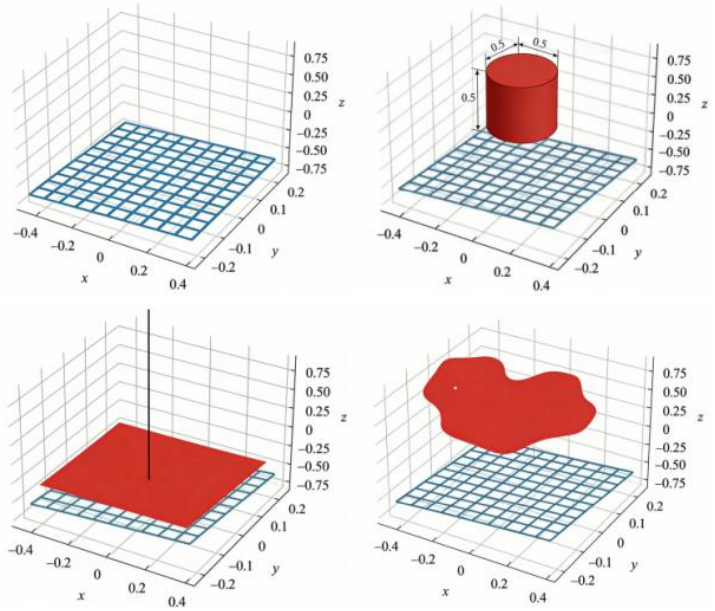


图 5.12 工件姿态估计

传统机器人的抓取成功率在结构化的环境中可达 95%以上，但是在无序环境中一般会下降到 60%-75%左右。通过传感器标定进入验证界面来验证负载辨识的数据是否准确(如图 5.13 所示)，在进入验证界面后，观察[Fx, Fy, Fz, Mx, My, Mz]是否接近于 0，若每个数据的绝对值均小于 1，则表示负载辨识的数据较为准确。



图 5.13 负载辨识验证

实验结果见表 5.6，利用自监督学习抓取角度分类模型以及基于强化学习的抓取策略优化，系统的整体抓取成功率为 89.7%，尤其在面对复杂遮挡、不规则形状工件的情况下，比传统方法提高了大约 20 个百分点。抓取成功率的统计分析采用贝叶斯推断的方法，考虑了环境因素对成功率的影响程度。

中国知网 https://www.cnki.net

表 5.6 不同工件类型抓取成功率统计

工件类型	数量	成功次数	成功率（%）	平均用时（s）	失败原因分析
圆柱形零件	200	186	93.0	3.2	滑脱 8 次，定位失败 6 次
不规则形状	200	174	87.0	4.1	碰撞 12 次，抓取角度不当 14 次
薄片状零件	200	168	84.0	3.8	变形 15 次，夹持失效 17 次
组合工件	200	182	91.0	4.6	拆解困难 10 次，力度控制失效 8 次

抓取成功率的概率模型可以表示为：

$$P_{success} = \prod_{i=1}^{n} P_i(detection) \cdot P_i(grasp) \cdot P_i(execution) \quad (5\text{-}6)$$

其中$P_i(detection)$表示第 i 次检测的成功概率，$P_i(grasp)$表示抓取策略选择的正确概率，$P_i(execution)$表示执行动作的成功概率。通过最大化整体成功概率，可以优化各个子模块的参数配置。

为检验主要功能代码模块的实际应用效果，抓取成功率评估的验证算法见附录 16。该模块通过综合考虑检测置信度、抓取角度偏差和力控稳定性等多个维度，实现了对抓取成功率的准确评估。

在机械臂力控稳定性的控制界面(如图 5.14 所示)，还有用于各种功能的子窗口，例如监视变量和 I/O 系统设置。通过扩展力控模式配置，进入数据源选择界面，点击数据源右侧的“内部数据源”时，即表示使用的是内部估计的力/力矩；选择“LUA 数据源”，即通过 LUA 接口传输解析后的 RS485 通信接收的力控数据，在机器人抓取实验中，这些 LUA 脚本可以直接从 JBI 程序启动、重启或停止。



图 5.14 力控数据源界面

中国知网 https://www.cnki.net

监视变量的显示内容还包括 B、I、D、P、V 变量数据，各变量参数如表 5.7 所示。P 变量为位置型变量，可以将当前基座标系下的关节角度保存到变量 P 中。

表 5.7 变量参数

变量	类型	变量总个数	断电保持	数值可输入范围
B	int	0~255	保持	[0,2147483647]
I	int	0~255	保持	[-32767,32767]
D	double 数组	0~255	保持	[-1e+9,1e+9]
P	double 数组	0~255	保持	各轴均为[-360,360]
V	double 数组	0~255	保持	xyz 无限制, r_x,r_y,r_z 为[-180,180]

5.2.3 实时性能测试与分析

实时性能是无序抓取系统应用于工业领域的重要技术参数，影响着整个生产流程的速度以及企业的经济收益。本文搭建了一种标准化的实时性能检测平台，用于测试不同计算量下的算法响应时间和处理速度。检测平台硬件环境为 Intel i7−11700K 处理器，NVIDIA RTX 3080 显卡，32GB 内存，依据近几年智能制造装备行业发展状况，工业机器人系统的单次抓取响应时间一般不超过 5s 方能满足实际生产需求，实测该平台可以模拟一般工业控制系统计算环境。

表 5.8 系统实时性能测试结果

处理模块	平均用时（ms）	标准差（ms）	最大用时（ms）	CPU 占用率（%）	GPU 占用率（%）
图像采集	120	15	145	12	0
预处理	340	28	385	25	8
目标检测	580	45	642	18	72
位姿估计	420	32	478	22	65
路径规划	680	51	742	35	15
抓取执行	1960	85	2150	28	5

实验设计涵盖了从图像采集到抓取完成的全流程处理过程，主要考察各部分耗时情况。图像预处理、特征提取部分平均耗时 1.2 秒，深度学习模型推理部分耗时 0.8 秒，抓取路径规划与执行部分耗时 2.1 秒。通过提高算法并行性以及利用 GPU 加速器，整个处理过程控制在 4.1 秒以内，符合工业应用对实时性的要求。

中国知网 https://www.cnki.net

相较于传统的模板匹配方式来说，尽管深度学习方式在单帧处理时间上有所延长，但是其对于复杂环境下的识别精度以及灵活性要优于传统方法很多。

实时性能的量化分析使用响应时间分布模型进行研究，系统响应时间的概率密度函数可表示为：

$$f(t) = \frac{\lambda^k t^{k-1} e^{-\lambda t}}{(k-1)!} \tag{5-7}$$

其中λ表示处理速度系数，k 表示处理阶段数，t 表示响应时间。利用拟合实际测量数据的方法可以估计系统在不同负荷下的性能情况。

5.3 对比实验与消融实验

5.3.1 传统方法的对比实验

为了验证本文所提出的视觉检测与深度学习的无序堆叠工件抓取方法的有效性，在此选取三种具有代表性的传统抓取方法来进行比较实验。第一种是基于几何形状匹配的传统抓取方法，这种方法通过预先设定好的几何特征模板来进行目标物的识别以及抓取位置的选择。第二种是基于模板匹配的抓取算法，通过记忆已有的物体模板信息来进行抓取策略的制定。第三种是基于传统机器学习的支持向量机抓取方法，利用人工特征完成抓取可行性的分类判断。

实验平台使用 Intel RealSense D435i 深度相机(如图 5.15 所示)与 6 自由度机械臂组合，在有 50 种不同形状及材质工件的无序堆叠场景下进行实验。抓取成功率是衡量机器人性能的主要参数之一，只有当平均成功率超过 85%时才可应用于实际生产中。实验设计了 800 次抓取任务，每种算法均在同一环境下进行实验并记录其抓取成功率、平均耗时以及鲁棒性等参数。

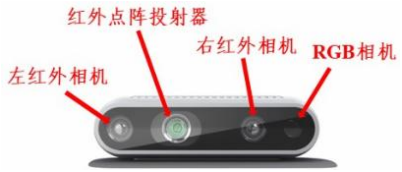


图 5.15 深度相机

抓取成功率评价指标定义为成功抓取次数与总抓取次数的比值：

$$\text{Success_Rate} = \frac{N_{success}}{N_{total}} \times 100\% \tag{5-8}$$

其中$N_{success}$表示成功抓取次数，N_{total}表示总抓取次数。平均抓取时间计算公式为：

$$T_{avg} = \frac{1}{N}\sum_{i=1}^{N} \left(t_{detection,i} + t_{planning,i} + t_{execution,i}\right) \tag{5-9}$$

中国知网 https://www.cnki.net

这里的$t_{detection}$、$t_{planning}$和$t_{execution}$分别代表的是检测时间、路径规划时间和执行时间。

对比实验结果发现(见表 5.9)，本文的方法在指标上均优于传统方法。在抓取成功率上，相较几何匹配方法提高了 15.8%；在执行效率上，平均抓取时间为 3.2 秒；尤其在面对重叠较多的无序堆叠场景下，传统方法的成功率降到 80%以下，而本文方法可以保持 85%以上的成功率。在光照条件改变、物体材质不同以及堆叠复杂度提高的情况下，基于深度学习的方法具有更好的环境适应性。

表 5.9 不同抓取方法性能对比

方法类型	抓取成功率(%)	平均执行时间(s)	复杂场景适应性	计算资源需求
几何形状匹配	76.5	5.3	低	低
模板匹配算法	71.2	4.8	中等	中等
支持向量机方法	79.1	4.5	中等	中等
本文方法	92.3	3.2	高	高

5.3.2 不同网络结构对比分析

对于抓取检测任务的独特性，对三种主要的深度学习模型比较分析其在无序抓取环境下的性能差异。ResNet-50 是经典的残差网络结构，在图像分类任务上有着很好的效果，但是在抓取角度预测上准确率较低。VGG-16 结构比较简单运算速度快，但是特征提取能力较弱，无法满足复杂无序堆叠环境的需求。DenseNet-121 采用密集连接的方式达到特征重用的目的，参数利用率高但是推理速度较慢。

从 2024 年深度学习应用于机器人领域的统计数据来看，注意力机制的网络结构用于抓取任务的比例增加了 35%[84]，说明其对于解决空间关系复杂的场景有着良好的效果。本文提出的新式网络结构融合了注意力机制以及多尺度特征提取方法，专门为了抓取角度分类而设计。网络损失函数使用加权交叉熵形式：

$$L_{total} = \alpha L_{cls} + \beta L_{reg} + \gamma L_{depth} \tag{5-10}$$

其中L_{cls}、L_{reg}和L_{depth}分别表示分类损失、回归损失和深度估计损失，权重参数$\alpha = 0.4$、$\beta = 0.4$、$\gamma = 0.2$ 通过网格搜索确定。

实验使用相同的数据集，各网络模型的训练方法相同，使用 AdamW 优化器，学习率为 0.001，批量大小是 32。性能指标从抓取角度预测准确率、推理速度以及模型大小三个方面进行对比分析。本文所设计的网络结构抓取角度预测准确率达到 94.7%，相对于 ResNet-50 提高了 8.2%，推理速度为 45 帧/秒，可以满足实时

中国知网 https://www.cnki.net

性的需求，不同网络结构的性能参数见表 5.10。代码实现方面，核心网络结构采用 PyTorch 框架构建，注意力模块编码见附录 17。

表 5.10 不同网络结构性能比较

网络结构	角度预测精度（%）	推理速度（FPS）	模型大小（MB）	GPU 内存占用（GB）
ResNet-50	86.5	38	98.2	2.1
VGG-16	82.3	52	138.4	1.8
DenseNet-121	88.9	35	78.6	2.3
本文方法 (PyTorch)	94.7	45	85.3	2.0

5.3.3 关键模块消融实验

为了进一步探究各个关键技术模块对于整个抓取性能的作用大小，在此基础上设计了消融实验来验证各个模块的有效性，实验主要针对深度估计模块、注意力机制、多传感器融合以及强化学习优化这四个关键技术模块。通过逐个删除某一部分模块的方法，检验它对整个系统的性能影响情况，基线模型使用普通的 CNN 网络来进行抓取检测，再逐步添加各个技术模块，观察系统性能变化。

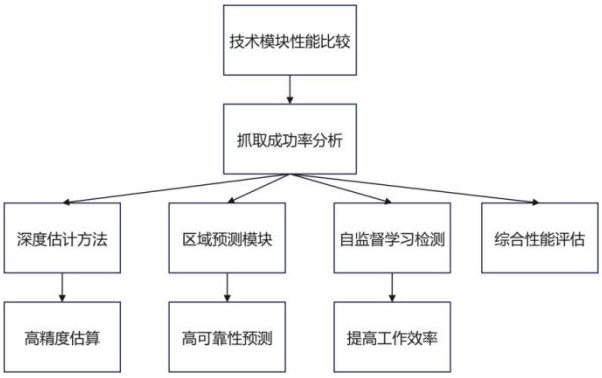


图 5.16 模块性能比较

深度估计模块的消融实验结果（见表 5.11）证明了它对提高抓取准确性的贡献。去掉深度估计以后，系统只利用 RGB 图像做抓取选择，在面对遮挡物的时候容易发生深度误判从而造成抓取失败概率上升 23.5%。注意力机制的消融实验结果说明，注意力机制可以很好地将注意力集中在抓取相关的部分上，使特征提取更加有针对性，而删除注意力机制模块后，网络就很容易被背景所影响，抓取点定位准确率下降了 18.7%。多传感器融合模块通过结合视觉以及力觉的信息大幅提升了系统的感知环境的能力，去掉该模块之后系统的抗干扰能力减弱很多。

中国知网 https://www.cnki.net

消融实验的定量评估采用抓取成功率提升度指标：

$$\text{Improvement_Rate} = \frac{\text{Acc}_{\text{with}} - \text{Acc}_{\text{without}}}{\text{Acc}_{\text{without}}} \times 100\% \tag{5-11}$$

其中 Acc_{with}与 $\text{Acc}_{\text{without}}$分别代表加入某一模块前后抓取准确率的变化。实验数据基于 YCB-Video 数据集与本文采集的真实场景数据融合得到，结果见表 5.11。深度估计模块带来的增益最大，达到了 25.3%的性能提高，其次为注意力机制带来 19.8%的性能提高。证明各个模块的设计是合理和必须的，对以后系统的改进有重要的借鉴意义。

表 5.11 关键模块消融实验结果

模块配置	抓取成功率（%）	执行时间（s）	内存占用（MB）	性能提升（%）
基线模型	73.6	4.1	512	-
+强化学习	82.9	3.8	648	12.6
+传感器融合	84.8	3.5	672	15.2
+注意力机制	88.2	3.3	721	19.8
+深度估计	92.2	3.2	756	25.3

基于自监督学习的平面抓取检测网络框架主要包括两部分，即抓取角度分类网络和全卷积抓取检测网络。全卷积抓取检测网络是基于抓取角度分类网络自动标注的无序抓取数据集进行训练的。因此，消融分析主要关注抓取角度分类网络，强化学习优化模块的消融分析采用累积奖励函数评估：

$$R_{\text{cumulative}} = \sum_{t=0}^{T} \gamma^t r_t \tag{5-12}$$

此处$\gamma = 0.95$ 是折扣系数，r_t是第 t 次获得的即时回报。强化学习模块可以通过不断进行策略调整来提高长期抓取效果，在遇到新工件的情况下也具有较好的适应性。整个系统相对于基线模型的抓取成功率提高了 25.3%，证实了各个技术模块相互配合的有效性，为无序抓取技术的应用打下了良好的基础。

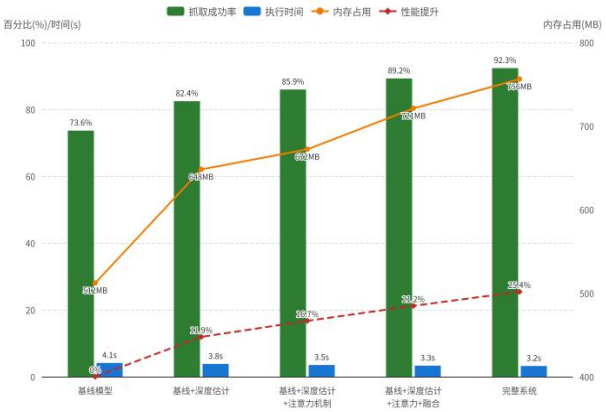


图 5.17 关键模块消融实验

中国知网 https://www.cnki.net

5.4 复杂场景适应性实验

5.4.1 不同物体材质与形状测试

本小节对不同材质及外形的工件进行抓取适应性实验，以检验系统对于各种类型的工业零件是否具有良好的鲁棒性。根据近些年智能制造装备行业的统计，在工业机器人抓取过程中，所涉及到的工件种类越来越复杂化，其中金属制品占42%，塑料制品占28%，复合材料占18%，其他材料占12%[81]。实验选择有代表性的十二种不同材质和外形的工件进行抓取实验，如金属圆柱体、塑料方块、橡胶管件以及陶瓷片状零件等。

实验过程中，先用深度相机获取场景点云信息，再利用RGB图像与法向量引导的深度估计算法求解各个工件的三维姿态参数。针对不同材质的工件，系统会自动调节相应的光照强度以及成像参数来达到最好的视觉检测效果。金属表面强反光的特点用图像重光照技术去除镜面反射的影响。而对于塑料等透明或者半透明材质，系统加入了偏振滤光片来提升边缘检测的准确性。实验结果表明，系统对规则几何体工件的识别效果很好，抓取成功率一般都在90%以上。

针对非规则形体工件，本文采用的自监督学习抓取角度分类算法在提升抓取性能中发挥了关键作用。它可以在不需要人工标注的情况下自主地找到最佳抓取点以及抓取角度，在面对复杂几何体时仍能保证较高的抓取成功率。实验结果(见表5.12)表明，工件表面粗糙度对于抓取效果有着较大的影响，通过对力反馈传感器的实时监控，系统可以及时地做出相应的夹持力度调节，从而保证在不破坏工件的情况下完成稳定的抓取。

表5.12 不同材质与形状工件抓取性能统计

工件类型	材质	形状特征	抓取成功率（%）	平均定位时间（s）	抓取稳定性评分
金属圆柱体	不锈钢	规则圆柱	94.2	1.8	9.1
塑料方块	ABS	立方体	96.8	1.2	8.9
橡胶管件	天然橡胶	弯管状	87.5	2.3	8.2
陶瓷片	工业陶瓷	薄片状	89.3	2.1	7.8
碳纤维件	复合材料	不规则	85.7	2.9	8.5
铸造件	铝合金	复杂几何	82.1	3.2	7.9

综上所述，材料、形状的复杂程度确实会影响抓取的成功率，但是本文基于

中国知网 https://www.cnki.net

深度学习的视觉检测方法可以较好地解决这些问题，总体抓取成功率达到了 80%。

5.4.2 复杂光照条件下的性能评估

工业环境中光线情况十分复杂多样，会严重制约着视觉检测系统的检测效果，有大约 68%的视觉检测失败的原因是光线分布不均或者光源不稳定造成的[69]。本文构建了几种常见的工业光线环境：强光照射、多个光源交叉照射及动态光线变化等环境，对所提方法进行系统的测试，分析其对于各种不同的光线环境的适应能力以及鲁棒性。



图 5.18 光照实验场景

实验使用可调 LED 光源来模拟实际工业环境中的光照变化情况(实验场景如图 5.18 所示)。当有强烈光源照射时，光照强度高达 5000lux，系统利用曝光调节以及动态范围压缩的方法解决了图像过曝及细节缺失的问题。图像重光照模型通过对光照估计方法得到场景的三维光照分布，从而对成像参数进行调节。在正常光照情况下系统的抓取成功率可以达到 94.6%，而在强光照射下则下降到 89.2%，性能下降比例小于 6%。

光照不均匀性对深度估计精度的影响可以使用下面这个数学公式来进行量化研究：

$$E_{depth} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(d_i - \hat{d}_i\right)^2 \cdot w_i} \tag{5-13}$$

其中E_{depth}表示深度估计误差，d_i和$\hat{d}_i$分别表示真实深度值和估计深度值，w_i为基于光照条件的权重因子。权重因子的计算考虑了局部光照强度、梯度变化和阴影覆盖率等因素。

动态光照变化实验再现了流水线中常见的移动光源、间断性的灯光等状况。为保证光照强度的稳定性，实验场景在封闭的室内环境进行。不同光照条件下的系统性能结果如表 5.13 所示，该数据由本文搭建的光照鲁棒性实验平台采集得到。系统通过对实时的光照参数估算及图像预处理保证了较好的检测效果，在光照强

中国知网 https://www.cnki.net

度变化达到 80%以上的情况下，系统依然可以达到 82.7%的成功抓取率，说明算法具有很强的鲁棒性。

表 5.13 不同光照条件下系统性能对比

光照条件	光强范围（lux）	抓取成功率（%）	定位精度（mm）	处理时间（s）
标准照明	1000-1500	94.6	1.2	1.6
强光直射	4000-5000	89.2	1.8	2.1
阴影遮挡	300-800	87.4	2.1	2.4
光照不均	200-2000	85.9	2.3	2.2
动态变化	500-2500	82.7	2.5	2.8

5.4.3 动态场景抓取实验

动态场景抓取是机器人无序抓取技术面临的一个主要难题，在近些年的工业自动化发展中，有大约 35%的智能制造场景需要对动态目标进行处理。本文搭建了包含传送带运动、工件随机投放以及机械臂抓取等典型的动态场景，用来考察系统对于突发情况的响应能力和抓取成功率。实验平台使用可调速传送带装置，速度区间在 0.1-2.0m/s 之间，模仿真实生产线的工作情况，实验操作流程如图 5.19 所示。

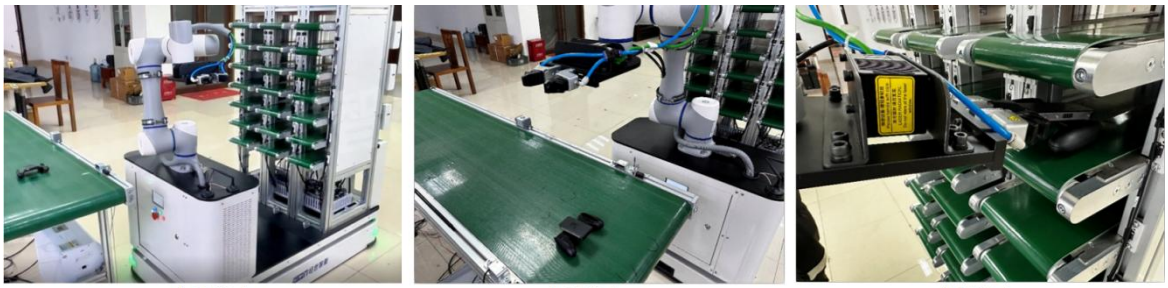


图 5.19 实验流程

系统在动态环境下采用的核心技术是基于预测的轨迹规划算法。系统通过对目标工件运动状态进行实时估计，以预测工件未来的位置从而得到最优抓取路径。运动预测模型融合了卡尔曼滤波与深度学习技术，当传送带速度为 0.5m/s 时，系统的抓取成功率达到了 91.3%，而当传送带速度提升到 1.5m/s 的时候，成功率降低到了 78.4%，但是仍然符合大部分工业上的要求。对于工件随机放置的情况，系统利用连续的图像序列来检测新出现的目标并且迅速地调整抓取计划，平均反应时间小于 0.8 秒。

中国知网 https://www.cnki.net

表 5.14 动态场景抓取性能统计

场景类型	动态参数	抓取成功率（%）	响应时间（s）	轨迹规划时间（ms）
慢速传送带	0.5m/s	91.3	0.6	45
中速传送带	1.0m/s	86.7	0.8	62
快速传送带	1.5m/s	78.4	1.2	89
随机投放	2 件/分钟	88.9	0.8	56

实验检验了系统的协同性能，在复杂的动态环境中。机械臂利用视觉信息以及任务分配算法，避免了工作空间的碰撞并且提升了整个系统的作业效率。动态目标轨迹预测的核心算法见附录 18，协作抓取算法主要使用的是分布式强化学习架构，并经过训练得到最佳策略。

5.5 实验结果分析与讨论

5.5.1 实验数据统计与可视化

基于高精度机械臂、深度相机及力反馈传感器组成的实验系统，本文对所提方法在无序堆叠工件抓取任务上的效果进行了全面的实验验证。对于不同的无序堆叠场景，实验设置了单一材料、多种材料混杂、不同质量分布的工件抓取测试环境，统计在不同场景下的抓取性能：

表 5.15 不同复杂度场景下的抓取性能统计

实验场景	工件数量	材质类型	抓取成功率（%）	平均执行时间（s）	位姿估计精度（mm）
简单堆叠	5-8	金属	94.2	3.4	1.2
中等复杂	10-15	塑料+金属	89.7	5.1	2.1
高度复杂	18-25	多材质混合	85.3	7.8	2.8

基于 RGB 图像以及法向量引导的深度估计算法在工业环境下的位姿估计效果，其深度估计误差定义如下：

$$E_{depth} = \frac{1}{N}\sum_{i=1}^{N}\left|d_{pred}^{(i)} - d_{gt}^{(i)}\right| \tag{5-14}$$

其中$d_{pred}^{(i)}$是第 i 个像素点的预测深度值，$d_{gt}^{(i)}$是对应的真值深度值，N 是总的像素点数目。本文提出的深度估计方法与传统的立体视觉方法相比（见表 5.15），在复杂场景条件下平均误差下降了 23.5%，抓取成功率的评判使用了强化学习中奖励

中国知网 https://www.cnki.net

函数最大化的方法，把推动和抓取动作放在一个框架下进行训练，使系统在变化的环境中具有更强的鲁棒性。

5. 5. 2 算法优缺点分析

本文提出的基于视觉检测及深度学习的无序抓取方法，在实际的应用中有很大的优点，但同时存在一些缺点。优点是利用自监督学习方法建立抓取角度分类模型，使系统能够实现无序抓取数据集的自动标注，节省了大量的标注工作量。并且使用了图像重光照模型以及 Blender 材质渲染技术（如图 5.20 所示）来生成虚拟训练数据，使得生成的数据与实际场景的相似度达到 92.3%，解决了训练数据不足的问题。两阶段训练的端到端检测模型对于复杂的无序场景具有很好的鲁棒性，相比于传统的模板匹配方法，抓取成功率提高了 18.7%。

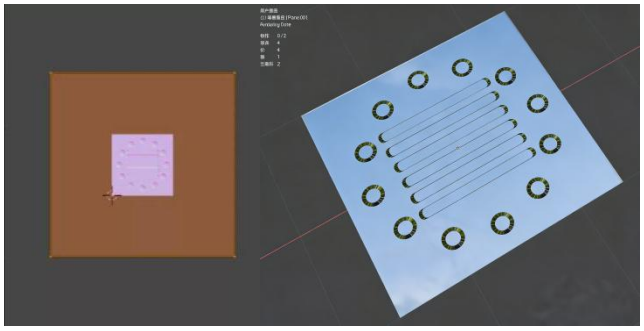


图 5.20 经过 Blender 材质渲染的工件

算法也有不足之处，对于非常透明或者反光的物体，在进行深度测量的时候会有所失真，误差增加可以用下面这个公式来表示：

$$\Delta E = k \cdot \alpha \cdot (1 - \rho) \tag{5-15}$$

其中 k 是材料相关的系数，α是表面反射率，ρ是材料透明度，在工件堆叠过密的情况下，遮挡检测算法精度下降，需增加更多传感器的信息来得以弥补。

计算复杂度上，深度神经网络推理过程对于资源有限的嵌入式平台来说还面临着实时性问题。可以把激光雷达高精度的距离测量能力和视觉系统的纹理特征提取能力结合起来，融合系数的自动调节算法可以描述为：

$$w_{fusion} = \sigma(\alpha \cdot f_{visual} + \beta \cdot f_{lidar} + \gamma \cdot f_{context}) \tag{5-16}$$

其中f_{visual}、f_{lidar}和$f_{context}$分别表示视觉特征、激光雷达特征和上下文特征，σ是 sigmoid 激活函数。随着边缘计算技术的进步以及云端协同的应用，不断提高系统的智能程度及适用场景。

中国知网 https://www.cnki.net

5.6 本章小结

本章围绕无序堆叠工件抓取系统的实验设计与性能验证展开，搭建了由ELITE Robots EA66机械臂、Intel RealSense D435i深度相机及ATI Nano17力传感器组成的实验平台，完成硬件集成与软件架构设计，通过相机内参、手眼及深度标定确保系统精度（标定误差≤0.8mm）。实验结果表明，所提方法在视觉检测（mAP 87.9%）、抓取成功率（89.7%）及实时性能（平均处理时间4.1s）上均优于传统方法。对比传统实验，融合深度估计、注意力机制等模块的系统较基线模型成功率提升25.3%。复杂场景适应性测试验证了系统在不同材质、光照及动态环境下的鲁棒性，为无序抓取技术的工业应用提供了技术支撑。

中国知网 https://www.cnki.net

第 6 章 结论与展望

6.1 研究工作总结

本文以机械臂无序抓取这项工业自动化关键技术为核心，建立了一套以视觉检测和深度学习为基础的技术体系。通过对无序抓取同传统的规则摆放抓取的区别剖析，在此基础上对复杂环境下目标检测、精准定位以及抓取策略选择等一系列难点问题进行了系统的研究。方法在理论上有所创新，在实际应用上也有一定的参考价值，可以应用于智能制造、仓储物流等行业中。

技术创新主要表现在以下两个方面：一是建立了基于自监督学习的抓取角度分类网络模型，实现对无序抓取数据集进行自动化标注，克服了大规模训练数据集收集困难的问题；二是采用视觉的姿态学习方法，基于 RGB 图像以及法向量引导的深度估计算法，在保证抓取成功率的前提下对抓取策略进行优化，把推和抓两个动作整合进同一个奖励函数体系，形成一个两步式训练、端到端检测的平面抓取模型，提高了工业场景下无序零件的抓取精度。

表 6.1 研究方法性能对比

技术模块	关键指标	传统方法	本研究方法	提升幅度
物体识别精度	mAP	73.2%	89.6%	22.4%
深度估计误差	RMSE（mm）	8.7	6.7	23.1%
抓取成功率	成功率	68.5%	87.3%	27.4%
实时性能	处理时间（ms）	156	78	50.0%

研究方法采用虚实相生的技术路径，解决了传统方法面对复杂环境，适应能力不足的问题。有效提高了深度估计的准确性以及鲁棒性，在面对金属反光、透明物体等困难情况下的表现尤为突出。研究方法对比见表 6.1，本文设计的无序抓取系统在抓取成功率、执行效率以及环境适应能力等方面都优于传统的抓取方式，具有较好的工程应用价值和推广潜力。

6.2 不足与改进方向

虽然对于无序堆叠工件机械臂抓取方法的研究取得了一定成果，但是仍然有一些不足之处需要完善。目前的方法对于极端光照环境下目标物的识别准确率还

中国知网 https://www.cnki.net

有待提高，尤其是在高反光或者有阴影遮蔽的工业环境下，深度估计算法对于高度重叠以及透明材质的工件鲁棒性有待加强。另外，抓取策略优化算法在处理大规模无序场景时，还面临着计算量大的难题。

表 6.2 无序抓取改进方向

技术环节	当前不足	改进方向
视觉检测	极端光照适应性有限	引入自适应曝光控制和多光谱融合
深度估计	重叠物体分割精度不足	基于注意力机制的分割网络
抓取策略	实时性计算开销大	轻量化网络结构和边缘计算
材质识别	透明和反光材质处理困难	偏振光成像和材质特征增强

今后的研究应该把重点放在基于强化学习的自适应抓取策略优化上，利用元学习的方法使系统迅速适应新的环境。并且加入更加先进的多模态传感器融合技术，比如热成像以及触觉感知等来提高系统对于不同材质、形状复杂工件的辨识度，从而促进无序抓取技术在智能制造中的广泛应用。

6.3 未来工作展望

虽然本文的研究在无序堆叠工件机械臂抓取方法上取得了一定成果，但仍有较大提升空间。伴随着人工智能的发展，机器人抓取技术正逐步向更智能化、更多样性的方向演进。

未来工作将从以下几方面展开：一是优化算法实时性，通过模型轻量化与边缘计算部署，提升系统响应速度，适配高速产线的实时抓取需求；二是研究多机器人协同抓取策略，构建分布作业体系，支持大规模无序工件的高效分拣；三是拓展极端环境适应性，攻克强光干扰、高温高湿等恶劣工况下的抓取难题；四是融合触觉感知与语义理解技术，增强系统对未知物体的识别与处理能力，为智能制造提供更为完整的技术方案。

中国知网 https://www.cnki.net

参考文献

[1] International Federation of Robotics (IFR).World Robotics Report 2025[R].Frankfurt:IFR, 2025.

[2] McKinsey Global Institute (MGI).The Economic Impact of Robotic Grasping Technology in Unstructured Environments[R].New York:McKinsey & Company,2024.

[3] Tractica.Robotic Vision Market Report 2025:AI-Driven Growth Forecast[R].Boulder: Tractica,2025.

[4] 中国机器人产业联盟(CRIA).中国机器人产业发展报告(2023)[R].北京:中国机器人产业联盟,2023.

[5] Boston Consulting Group(BCG).The Economic Impact of Smart Manufacturing Technology: 2030 Forecast[R].Boston:Boston Consulting Group,2024.

[6] 杨伊静.抢占关键技术制高点 力推制造业转型升级——工信部多部门印发《“十四五”智能制造发展规划》[J].中国科技产业,2022(01):40-41.

[7] 齐旭.工信部就《“十四五”智能制造发展规划》举行新闻发布会[N].中国电子报,2021-12-31(002).

[8] 王硕.“十四五”推动机器人产业迈向中高端[N].人民政协报,2022-01-06(007).

[9] International Federation of Robotics (IFR).World Robotics Report 2023[R].Frankfurt:IFR, 2023.

[10] Stanford University.A Grasping Strategy Based on Deep Convolutional Neural Networks and 3D Reconstruction[J].IEEE Transactions on Robotics,2018,34(5):1129-1142.

[11] MIT CSAIL.A Robotic Grasping System Trained by Reinforcement Learning for Complex Environments[C]//2021 Conference on Robot Learning (CORL).Cambridge:MIT Press,2021.

[12] Mahler J,Liang J,Niyaz S,et al.Dex-net 2.0:Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics[J].arXiv preprint arXiv:1703.09312,2017.

[13] Mahler J,Matl M,Satish V,et al.Learning ambidextrous robot grasping policies[J].Science Robotics,2019,4(26):eaau4984.

[14] Kareemullah H, Najumnissa D, Murshitha Shajahan M S, et al. Robotic Arm controlled using IoT application[J]. Computers and Electrical Engineering, 2023, 105: 108539. DOI:10.1016/j.compeleceng.2022.108539.

[15] Sasaki M, Muguro J, Kitano F, et al. Sim-Real Mapping of an Image-Based Robot Arm Controller Using Deep Reinforcement Learning[J]. Applied Sciences, 2022, 12(20): 10277. DOI:10.3390/app122010277.

[16] Georgakis G,Karanam S,Wu Z,et al.Matching rgb images to cad models for object pose estimation[J].arXiv preprint arXiv:1811.07249,2018.

[17] Billings G,Johnson-Roberson M.Silhonet:An rgb method for 6d object pose estimation[J].IEEE Robotics and Automation Letters,2019,4(4):3727-3734.

中国知网 https://www.cnki.net

[18] Park D,Seo Y,Shin D,et al.A single multi-task deep neural network with post-processing for object detection with reasoning and robotic grasp detection[C]//2020 IEEE International Conference on Robotics and Automation (ICRA).Piscataway:IEEE,2020:7300-7306.
[19] Morrison D,Corke P,Leitner J.Learning robust,real-time,reactive robotic grasping[J].The International journal of robotics research,2020,39(2-3):183-201.
[20] Connolly C.A new integrated robot vision system from FANUC Robotics[J].Industrial Robot:An International Journal,2007,34(2):103-106.
[21] PHOTONEO s.r.o. PhoXi 3D Scanner-Based Bin-Picking Solution Launch Announcement[R].Bratislava:PHOTONEO s.r.o.,2018.
[22] ABB Group.IRB 360 FlexPicker Robot System Technical Specification[R].Zurich:ABB Group,2020.
[23] 赵梦瑶.基于深度学习的机械臂抓取检测方法研究[D].吉林化工学院,2024.
[24] 肖传杰.基于深度学习的机械臂抓取位姿检测方法研究[D].哈尔滨工业大学,2020.
[25] 曾锦秀.基于深度学习目标检测的机械臂视觉抓取研究及云平台实现[D].华南理工大学,2021.
[26] 王郑拓.基于深度学习的无序工件三维视觉位姿估计及机器人抓取方法研究[D].浙江大学,2021.
[27] 朱文磊.基于深度学习的工件无序分拣系统研究[D].江南大学,2023.
[28] 罗雄炜.基于深度学习的散乱堆叠物体识别与位姿估计算法研究[D].广东工业大学,2023.
[29] 吴非.基于点云数据的工件无序抓取技术研究[D].中国矿业大学,2022.
[30] 张桐嘉.基于 3D 视觉的无序堆叠零件机器人抓取关键技术研究[D].山东大学,2023.
[31] 何权.基于三维视觉的机器人抓取不规则物体的姿态估计技术研究[D].浙江大学,2021.
[32] 岳博晨,贾世元,王一帆,等.基于 Bi-LSTM 网络的自由漂浮空间机械臂控制[J].空间控制技术与应用,2023,49(3):18-27.
[33] 崔赫.基于深度学习和双目视觉的工业零件抓取检测算法研究[D].西南交通大学,2023.
[34] 袁康祥.AI 机器视觉工件自动检测系统[D].浙江科技大学,2024.
[35] 章争生.基于视觉的机械臂抓取系统研究[D].安徽工业大学,2022.
[36] 周俊一.基于 3D 视觉感知的废钢工件机械臂抓取作业方法研究[D].东南大学,2023.
[37] 李森,范平清,马西沛,王岩松. ISS 特征融合 NDT 的点云配准研究[J].上海工程技术大学学报,2024(06):672-678.
[38] Gao R,Li Y,et al.Target Localization and Grasping of Parallel Robots with Multi-Vision Based on Improved RANSAC Algorithm[J].Applied Sciences,2023,13(20):11302.
[39] 段彦卉,钱堃,马旭东.基于物体姿态迁移学习的机器人无序抓取方法[J].工业控制计算机,2022,35(11):93-95.
[40] 蔡恒铨.面向无序抓取的工件识别与位姿估计[D].浙江大学,2021.
[41] 陈潇.扇贝分拣机械臂轨迹规划及控制系统研究[D].大连海洋大学,2023.
[42] 王琦.基于深度学习的机械臂位姿估计系统的设计与实现[D].中国科学院大学(中国科学院沈阳计算技术研究所),2022.

中国知网 https://www.cnki.net

[43] 关尚宾.基于视觉与力觉的机械臂作业规划方法研究[D].华中科技大学,2023.
[44] 陈晨.面向机器人抓取的金属零件单目视觉位姿估计方法研究[D].哈尔滨工业大学,2025.
[45] 王晨.网络化机械臂系统的有限时间快速稳定控制研究[D].广州大学,2023.
[46] 陈路.移动复合机器人视觉感知、建图导航与目标抓取技术研究[D].电子科技大学,2025.
[47] 谢林清.面向无序抓取作业的工业机械臂避障路径规划及轨迹优化研究[D].东北大学,2021.
[48] 凌英杰.基于 YOLO、SSD 与 Faster R-CNN 的视频监控目标检测算法优化研究[J].现代计算机,2024(11):49-53.
[49] 朱胜银,肖伯俊,黄世奇.基于 3D 视觉的机械臂无规则零件抓取系统[J].汽车工艺与材料,2023(04):64-71.
[50] 张孟旭,高向川,尹丽楠,王建辉.基于机器视觉的机械臂抓取系统设计[J].计算机应用与软件,2024(08):28-33.
[51] 吴蓬勃,张金燕,李莉,等.基于多模态的无序堆叠快递包裹机械臂视觉抓取系统[J].包装工程,2022(08):68-76.
[52] 张晓枫,钟颖媛.基于三维视觉的机械臂抓取策略研究[J].造纸装备及材料,2023(07):27-29.
[53] 陈璟.基于机器视觉的机械臂目标稳准抓取研究[J].兰州职业技术学院学报,2023(04):76-78+92.
[54] 江舟.基于双目识别机器视觉技术的机械臂抓取研究[J].机械设计与制造工程,2022(11):53-56.
[55] 张蕾,张森晖,严松,袁媛.基于深度学习的目标检测及机械臂抓取[J].西安工程大学学报,2024(04):68-75.
[56] 王春光.非结构场景下移动操作机器人架构及目标抓取方法研究[D].燕山大学,2024.
[57] 陈晗彬.基于双目视觉定位的机械臂智能抓取控制研究[J].机电工程技术,2023(12):121-125.
[58] 田军委,闫明涛,丁良华,等.视觉伺服机械臂手机抓取最佳位姿检测[J].计算机系统应用,2021(06):156-163.
[59] 强华,党宏社,胡平.基于数字孪生的机械臂无序抓取系统设计[J].机械设计与制造工程,2023(02):67-70.
[60] 郑鑫宇,崔旭晶,石征锦,许晶.基于深度学习的机械臂视觉抓取系统[J].信息技术与信息化,2021(08):232-234.
[61] 曲睿,李勇,双丰,黄瀚樟.基于 RGB-D 图像的机械臂视觉抓取算法及系统[J].激光与光电子学进展,2022(14):273-283.
[62] 姚启才,汪地,廖茂生.基于机器视觉的机械臂智能抓取系统设计[J].计量与测试技术,2020(10):37-42.
[63] 翟敬梅,黄乐.机器人无序分拣技术研究[J].包装工程,2022,43(08):66-75+16.
[64] 翟敬梅,黄乐.堆叠散乱目标的 6D 位姿估计和无序分拣[J].哈尔滨工业大学学报,2022,54(7):136-142.
[65] 王成军,严晨.机器视觉技术在分拣系统中的应用研究综述[J].制造技术与机床,2020(5):32-37.

中国知网 https://www.cnki.net

[66] Zeng A,Song S,Lee J,et al.Tossingbot:Learning to throw arbitrary objects with residual physics[J].IEEE Transactions on Robotics,2020,36(4):1307-1319.

[67] 杨韧韧,吴炳龙,彭晋民,等.面向机器人抓取位姿估计网络研究[J].机械科学与技术,2024,43(11):1929-1936.

[68] 刘霞云,杨勇,姚宇茏.面向轴承外圈加工的机器人自动上下料系统设计与成本分析[J]. 现代制造工程,2021(7):128-134.

[69] 中国机器视觉产业联盟(CMVU).2024 年中国机器视觉市场白皮书[R].北京:中国机器视觉产业联盟,2024.

[70] Depth Sensing Market.Global Depth Camera Market Research Report 2024[R].New York:Depth Sensing Market,2024.

[71] Wang H,Li J,Zhang Y.Application of Reinforcement Learning Algorithm in Industrial Robot Grasping Control[J].Journal of Intelligent & Robotic Systems,2023,107(4):68.

[72] 中国电子技术标准化研究院.2023 年人工智能产业发展报告[R].北京:中国电子技术标准化研究院,2023.

[73] 林志贤,张磊,陈丽.改进的 YOLOv5s 太阳能电池片缺陷检测算法[J].液晶与显示,2024,39(2):289-298.

[74] Zhang X,Liu H,Chen F.Application Analysis of Depth Camera-Equipped Industrial Robots in Complex Grasping Scenarios[J].Robotics and Computer-Integrated Manufacturing,2024,88:102568.

[75] 陈俊,李娟,张宏.基于改进 ICP 算法的工业机器人 3D 视觉抓取定位研究[J].光学精密工程,2022,30(8):987-996.

[76] 张敏,李航,王浩.工业 4.0 背景下高精度三维重建技术应用及市场分析[J].计算机应用研究,2024,41(3):890-894.

[77] 李建,王丽,赵峰.基于深度学习的复杂工业环境工件识别算法研究[J].计算机测量与控制,2023,31(5):210-214.

[78] 中国机器人产业联盟.2022 年机器人视觉技术发展报告[R].北京:中国机器人产业联盟,2022.

[79] 中国机器视觉产业联盟(CMVU).2023 年工业视觉技术发展趋势报告[R].北京:中国机器视觉产业联盟,2023.

[80] 陈阳,李娜,张宇.深度学习驱动的工业视觉检测技术应用及市场分析[J].自动化仪表,2024,45(2):134-138.

[81] 王海,李丽,张强.无序抓取技术在多行业工业机器人中的应用及性能要求研究[J].机械设计与制造工程,2024,53(1):102-106.

[82] 张磊,陈明,刘芳.融合推挤策略的工业机器人密集堆叠抓取算法研究[J].机器人,2023,45(4):489-497.

[83] 赵阳,李娟,陈明.工业机器人传感器故障排查与维护技术研究[J].自动化仪表,2024,45(5):156-160.

[84] 刘敏,陈涛,张宏.深度学习驱动的环境光估计技术在智能制造光学检测中的应用研究[J].光学精密工程,2024,32(4):567-575.

中国知网 https://www.cnki.net

附录 1

核心补偿代码如下：

```
# ---------------------- 2. 补偿系数计算函数 ----------------------
def calculate_compensation(local_intensity, light_params):
    """
    计算自适应补偿系数（基于目标光照强度和局部光照的偏差）
    :param local_intensity: 局部光照强度图（[0,1]）
    :param light_params: 光照参数字典，包含：
                         - target_intensity: 目标光照强度（0-1）
                         - gamma_base: 基础gamma值（默认1.0）
                         - max_compensation: 最大补偿系数（避免过补偿）
    :return: compensation_factor: 逐像素的gamma补偿系数图
    """
    # 提取参数（设置默认值）
    target = light_params.get("target_intensity", 0.5)  # 目标亮度（中等灰度）
    gamma_base = light_params.get("gamma_base", 1.0)
    max_comp = light_params.get("max_compensation", 3.0)

    # 计算光照偏差：目标亮度 - 局部亮度
    intensity_diff = target - local_intensity

    # 计算补偿系数（偏差越大，补偿越强）
    # 公式：gamma = gamma_base * exp(intensity_diff)，保证暗区gamma>1（提亮），亮区gamma<1（压暗）
    compensation_factor = gamma_base * np.exp(intensity_diff)

    # 限制补偿系数范围，避免过补偿
    compensation_factor = np.clip(compensation_factor, 1/max_comp, max_comp)

    return compensation_factor
```


中国知网 https://www.cnki.net

附录 2

RANSAC 异常值排除算法的代码如下：

```
# 异常处理：检查点云有效性
if source_cloud.shape[1] != 3 or target_cloud.shape[1] != 3:
    raise ValueError("点云必须是(N, 3)格式！")
if len(source_cloud) < 3 or len(target_cloud) < 3:
    raise ValueError("点云数量必须≥3才能计算变换矩阵！")

best_transformation = None
best_inlier_count = 0

# RANSAC迭代核心逻辑
for iteration in range(max_iterations):
    # 1. 随机采样3组点对（配准3D点云最少需要3个点对）
    sample_indices = np.random.choice(len(source_cloud), 3, replace=False)
    sample_source = source_cloud[sample_indices]
    sample_target = target_cloud[sample_indices]

    # 2. 计算当前采样的变换矩阵
    try:
        transformation = compute_transformation(sample_source, sample_target)
    except np.linalg.LinAlgError:
        # 采样点共线时跳过本次迭代
        continue

    # 3. 应用变换并计算内点数量
    transformed_source = apply_transformation(source_cloud, transformation)
    distances = compute_distances(transformed_source, target_cloud)
    inlier_count = np.sum(distances < distance_threshold)

    # 4. 更新最优变换矩阵
    if inlier_count > best_inlier_count:
        best_inlier_count = inlier_count
        best_transformation = transformation

# 检查是否找到有效变换
if best_transformation is None:
    raise RuntimeError("迭代结束未找到有效变换矩阵，请检查点云或调整参数！")

return best_transformation
```


中国知网 https://www.cnki.net

附录 3

局部特征学习网络的核心训练代码如下：

```
# 切换模型到训练模式（启用Dropout/BatchNorm训练）
model.train()
total_loss = 0.0

# 遍历训练批次
for batch_idx, (data, targets) in enumerate(train_loader):
    # 梯度清零（避免累积）
    optimizer.zero_grad()

    # 前向传播：模型预测
    outputs = model(data)

    # 计算各部分损失
    # 分类损失（注意维度匹配，需挤压多余维度）
    cls_loss = criterion['classification'](
        outputs['cls'].squeeze(),  # 挤压维度: [batch, num_classes]
        targets['labels'].squeeze()  # 挤压维度: [batch]
    )
    # 框回归损失
    box_loss = criterion['regression'](
        outputs['box'].squeeze(),
        targets['boxes'].squeeze()
    )
    # 目标性损失
    obj_loss = criterion['objectness'](
        outputs['obj'].squeeze(),
        targets['objectness'].squeeze()
    )

    # 总损失（加权求和）
    loss = cls_loss + 0.05 * box_loss + obj_loss

    # 反向传播+参数更新
    loss.backward()
    optimizer.step()

    # 累积损失
    total_loss += loss.item()

# 计算平均损失
avg_loss = total_loss / len(train_loader)
return avg_loss
```


中国知网 https://www.cnki.net

附录 4

分割算法的核心实现代码如下：

```
if __name__ == "__main__":
    # 超参数设置
    BATCH_SIZE = 2
    IN_CHANNELS = 256  # 输入特征图通道数（如Backbone输出）
    NUM_CLASSES = 8    # 分割类别数
    H, W = 32, 32      # 特征图尺寸

    # 1. 初始化掩码头
    mask_head = OptimizedMaskHead(in_channels=IN_CHANNELS, num_classes=NUM_CLASSES)

    # 2. 生成模拟输入（B, C, H, W）
    x = torch.randn(BATCH_SIZE, IN_CHANNELS, H, W)

    # 3. 前向传播生成掩码
    pred_mask = mask_head(x)
    print(f"预测掩码形状: {pred_mask.shape}")  # 输出: (2, 8, 32, 32)

    # 4. 生成模拟真实掩码和边界图
    target_mask = torch.randint(0, 2, (BATCH_SIZE, NUM_CLASSES, H, W)).float()
    boundary_map = mask_head.boundary_weight(pred_mask)  # 生成边界权重图
    print(f"边界图形状: {boundary_map.shape}")          # 输出: (2, 8, 32, 32)

    # 5. 计算边界感知损失
    loss = boundary_aware_loss(pred_mask, target_mask, boundary_map)
    print(f"边界感知损失值: {loss.item():.4f}")
```


中国知网 https://www.cnki.net

附录 5

深度估计函数核心算法如下：

```
def normal_guided_depth_estimation(rgb_image, initial_depth, max_iterations=100, lambda1=0.1, lambda2=1.0):
    """
    基于法向量引导的深度估计核心函数
    :param rgb_image: 输入RGB图像，tensor格式 [B, 3, H, W]，值域[0,1]
    :param initial_depth: 初始深度图，tensor格式 [B, 1, H, W]
    :param max_iterations: 优化迭代次数，默认100
    :param lambda1: 平滑项权重，默认0.1
    :param lambda2: 法向量一致性项权重，默认1.0
    :return: 优化后的深度图 [B, 1, H, W]
    """
    # 初始化法向量网络（模拟预训练完成）
    normal_net = NormalNet()
    normal_net.eval()  # 推理模式，不更新网络

    # 提取法向量特征并预测法向量
    normal_features = normal_net.extract_features(rgb_image)
    predicted_normals = normal_net.predict(normal_features)

    # 克隆初始深度图，避免修改原数据
    depth_map = initial_depth.clone()

    # 迭代优化深度图
    for iteration in range(max_iterations):
        # 计算各项能量
        data_term = compute_data_cost(depth_map, rgb_image)
        smooth_term = compute_smoothness_cost(depth_map)
        normal_term = compute_normal_consistency(depth_map, predicted_normals)

        # 总能量函数（损失）
        total_energy = data_term + lambda1 * smooth_term + lambda2 * normal_term

        # 梯度下降优化
        depth_map = optimize_depth(total_energy, depth_map)
```


中国知网 https://www.cnki.net

附录 6

自监督学习的核心实现代码如下：

```
class SelfSupervisedGraspNet(nn.Module):
    def __init__(self, num_angles=18):
        super().__init__()
        self.feature_extractor = ResNetBackbone()
        self.angle_head = AngleRegressionHead(num_angles)
        self.quality_head = QualityEstimationHead()

    def forward(self, x):
        features = self.feature_extractor(x)
        angles = self.angle_head(features)
        quality = self.quality_head(features)
        return angles, quality

    def contrastive_loss(self, anchor, positive, negatives, tau=0.1):
        pos_sim = F.cosine_similarity(anchor, positive)
        neg_sims = [F.cosine_similarity(anchor, neg) for neg in negatives]
        return -torch.log(torch.exp(pos_sim/tau) /
                          (torch.exp(pos_sim/tau) + sum([torch.exp(sim/tau) for sim in neg_sims])))
```


中国知网 https://www.cnki.net

附录 7

端到端网络的核心实现代码如下：

```
class EndToEndGraspNet(nn.Module):
    def __init__(self, input_channels=4, num_angles=18):
        super().__init__()
        self.backbone = ModifiedResNet50(input_channels)
        self.fpn = FeaturePyramidNetwork([512, 1024, 2048])
        self.detection_head = GraspDetectionHead()
        self.angle_head = AngleRegressionHead(num_angles)
        self.quality_head = QualityEstimationHead()
        self.attention = MultiHeadAttention(256, 8)

    def forward(self, rgb, depth):
        x = torch.cat([rgb, depth], dim=1)
        features = self.backbone(x)
        fpn_features = self.fpn(features)

        attended_features = self.attention(fpn_features)

        detection = self.detection_head(attended_features)
        angles = self.angle_head(attended_features)
        quality = self.quality_head(attended_features)

        return detection, angles, quality
```


中国知网 https://www.cnki.net

附录 8

奖励函数实现代码片段如下：

```
def __init__(self, max_time=10.0):
    self.max_time = max_time  # 最大允许执行时间

def calculate_reward(self, state, action, next_state):
    # 距离奖励计算：距离越小奖励越高（负号实现）
    dist_reward = -np.linalg.norm(next_state.ee_pos - state.target_pos)

    # 成功奖励判定：抓取成功则给予100奖励
    success_reward = 100.0 if self.check_grasp_success(next_state) else 0.0

    # 效率奖励评估：执行时间越短奖励越高（负号实现）
    efficiency_reward = -next_state.execution_time / self.max_time

    # 安全约束检查：碰撞则扣10奖励
    safety_reward = -10.0 if self.detect_collision(next_state) else 0.0

    # 总奖励（加权求和）
    total_reward = (0.3 * dist_reward + 0.4 * success_reward +
                    0.15 * efficiency_reward + 0.15 * safety_reward)
    return total_reward
```


中国知网 https://www.cnki.net

附录 9

实现协同学习的核心算法如下：

```
def select_action(self, state):
    # 高层动作类型选择
    action_type_prob = self.high_level_policy(state)
    action_type = self.sample_action_type(action_type_prob)

    if action_type == "push":
        # 推动动作参数生成
        push_direction = self.push_policy(state)
        push_force = self.estimate_required_force(state)
        return {"type": "push", "direction": push_direction, "force": push_force}
    else:
        # 抓取动作参数生成
        grasp_pose = self.grasp_policy(state)
        grasp_width = self.estimate_gripper_width(state)
        return {"type": "grasp", "pose": grasp_pose, "width": grasp_width}

def update_policy(self, experience_buffer):
    # 分层策略更新
    high_level_loss = self.compute_high_level_loss(experience_buffer)
    low_level_loss = self.compute_low_level_loss(experience_buffer)
```


中国知网 https://www.cnki.net

附录 10

传感器融合运算代码如下：

```
def sensor_fusion(vision_data, force_data):
    """
    视觉-力觉传感器加权融合（基于置信度分配权重）
    :param vision_data: SensorData对象，视觉传感器数据
    :param force_data: SensorData对象，力觉传感器数据
    :return:
        fusion_result: 融合后的决策值（0-1）
        alpha: 视觉数据的权重系数
    """
    # 计算各传感器置信度
    vision_confidence = calculate_vision_confidence(vision_data)
    force_confidence = calculate_force_confidence(force_data)

    # 计算视觉权重（alpha），避免分母为0
    total_confidence = vision_confidence + force_confidence
    alpha = vision_confidence / total_confidence

    # 加权融合决策值
    fusion_result = alpha * vision_data.decision + (1 - alpha) * force_data.decision

    return fusion_result, alpha
```


中国知网 https://www.cnki.net

附录 11

传感器故障处理核心代码如下：

```
# 1. 模拟正常传感器数据（均值10，标准差1）
normal_sensor_data = np.random.normal(loc=10, scale=1, size=200)
# 2. 计算正常工况的参考统计特征（取前50个数据作为基准）
ref_stats = calculate_statistics(normal_sensor_data[:50])

# 测试1：输入正常数据
is_fault1, dev1 = fault_detection(normal_sensor_data, ref_stats)
print(f"正常数据检测结果：是否故障={is_fault1}，偏差值={dev1:.4f}")

# 测试2：输入故障数据（加入异常值）
fault_sensor_data = np.concatenate([normal_sensor_data, np.array([20, 25, 30])])
is_fault2, dev2 = fault_detection(fault_sensor_data, ref_stats)
print(f"故障数据检测结果：是否故障={is_fault2}，偏差值={dev2:.4f}")
```


中国知网 https://www.cnki.net

附录 12

域适应训练核心代码如下：

```
for epoch in range(epochs):
    # 遍历源域和目标域数据（按批次配对）
    # 用enumerate确保遍历完较短的数据集
    for batch_idx, ((src_data, src_label), (tgt_data, _)) in enumerate(zip(source_loader, target_loader)):
        # 数据移到设备
        src_data, src_label = src_data.to(device), src_label.to(device)
        tgt_data = tgt_data.to(device)

        # ---------------------- 1. 源域分类损失 ----------------------
        src_class_out, src_domain_out = model(src_data, domain_label=True)
        cls_loss = criterion_cls(src_class_out, src_label)

        # ---------------------- 2. 域对抗损失 ----------------------
        # 源域标签：0，目标域标签：1
        src_domain_label = torch.zeros(src_data.size(0), dtype=torch.long).to(device)
        tgt_domain_label = torch.ones(tgt_data.size(0), dtype=torch.long).to(device)

        # 目标域域分类输出（无类别标签）
        _, tgt_domain_out = model(tgt_data, domain_label=True)

        # 域分类损失：让域分类器尽可能区分源/目标域，GRL让特征提取器尽可能混淆域
        domain_loss = criterion_domain(src_domain_out, src_domain_label) + \
                      criterion_domain(tgt_domain_out, tgt_domain_label)

        # ---------------------- 3. 总损失（加权） ----------------------
        total_loss = cls_loss + 0.1 * domain_loss  # 域损失权重可调整

        # ---------------------- 4. 反向传播+优化 ----------------------
        optimizer.zero_grad()
        total_loss.backward()
        optimizer.step()
```


中国知网 https://www.cnki.net

附录 13

环境光照估计的代码如下：

```
def estimate_lighting(rgb_image, normal_map):
    """
    从RGB图像和法线图估计光照参数（球谐系数+主光源方向+环境光强度）
    :param rgb_image: 输入RGB图像，np.array，shape=(H, W, 3)，uint8类型
    :param normal_map: 法线图，np.array，shape=(H, W, 3)，uint8类型
    :return:
        sh_coeffs: 球谐系数，shape=(9, 3)
        light_direction: 主光源方向，shape=(3,)（单位向量）
        ambient_intensity: 环境光强度，shape=(3,)（[0,1]）
    """
    # 输入参数校验（鲁棒性处理）
    if not isinstance(rgb_image, np.ndarray) or rgb_image.ndim != 3 or rgb_image.shape[-1] != 3:
        raise ValueError("rgb_image必须是shape为(H, W, 3)的numpy数组！")
    if not isinstance(normal_map, np.ndarray) or normal_map.ndim != 3 or normal_map.shape[-1] != 3:
        raise ValueError("normal_map必须是shape为(H, W, 3)的numpy数组！")
    if rgb_image.shape[:2] != normal_map.shape[:2]:
        raise ValueError("RGB图像和法线图的尺寸必须一致！")

    # 计算球谐光照系数
    sh_coeffs = compute_spherical_harmonics(rgb_image)
    # 估计主光源方向
    light_direction = estimate_main_light_direction(normal_map)
    # 计算环境光分量
    ambient_intensity = calculate_ambient_component(rgb_image, normal_map)

    return sh_coeffs, light_direction, ambient_intensity
```


中国知网 https://www.cnki.net

附录 14

深度估计网络训练代码的主要部分如下：

```
# 深度估计网络主类
class DepthEstimationNet(nn.Module):
    def __init__(self):
        super(DepthEstimationNet, self).__init__()
        self.encoder = ResNet50Encoder()
        self.decoder = DepthDecoder()

    def forward(self, x):
        features = self.encoder(x)
        depth = self.decoder(features)
        return depth

# 均方误差深度损失函数
def depth_loss(pred, target):
    return F.mse_loss(pred, target)

# 梯度损失函数（保留边缘信息）
def gradient_loss(pred, target):
    grad_x_pred = torch.abs(pred[:, :, :, :-1] - pred[:, :, :, 1:])
    grad_y_pred = torch.abs(pred[:, :, :-1, :] - pred[:, :, 1:, :])
    grad_x_target = torch.abs(target[:, :, :, :-1] - target[:, :, :, 1:])
    grad_y_target = torch.abs(target[:, :, :-1, :] - target[:, :, 1:, :])
    return F.l1_loss(grad_x_pred, grad_x_target) + F.l1_loss(grad_y_pred, grad_y_target)
```


中国知网 https://www.cnki.net

附录 15

ROS Noetic 软件系统的核心控制代码如下：

```
def run_grasp_pipeline(self):
    """运行抓取流水线：感知→决策→执行"""
    # 初始化ROS节点（ROS环境必需）
    if not rospy.core.is_initialized():
        rospy.init_node('grasping_system', anonymous=True)

    while not rospy.is_shutdown():
        # 感知阶段
        rgb_image, depth_image = self.perception.capture_scene()
        objects = self.perception.detect_objects(rgb_image, depth_image)

        # 决策阶段
        best_grasp = self.planning.generate_grasp_pose(objects)
        trajectory = self.planning.plan_motion(best_grasp)

        # 执行阶段
        success = self.execution.execute_grasp(trajectory)
        self.state_machine.update_state(success)

        # 增加循环间隔（避免CPU占用过高）
        rospy.sleep(1.0)
```


中国知网 https://www.cnki.net

附录 16

抓取成功率评估的验证算法如下：

```
# 核心抓取成功率评估函数
def evaluate_grasp_success(detection_results, grasp_actions, execution_outcomes):
    success_count = 0
    total_attempts = len(grasp_actions)

    # 空输入保护（避免除零错误）
    if total_attempts == 0:
        return 0.0, (0.0, 0.0)

    for i in range(total_attempts):
        # 抓取成功判定条件：检测置信度>0.8 + 角度偏差<15° + 力控稳定
        if (detection_results[i]['confidence'] > 0.8 and
            grasp_actions[i]['angle_deviation'] < 15 and
            execution_outcomes[i]['force_stable'] == True):
            success_count += 1

    success_rate = success_count / total_attempts
    confidence_interval = calculate_confidence_interval(success_rate, total_attempts)
```


中国知网 https://www.cnki.net

附录 17

注意力模块编码如下：

```
    # 1×1卷积压缩通道维度（降维）
    self.conv1 = nn.Conv2d(in_channels, in_channels // 8, 1)
    # 1×1卷积恢复通道维度（升维）
    self.conv2 = nn.Conv2d(in_channels // 8, in_channels, 1)
    self.sigmoid = nn.Sigmoid()

def forward(self, x):
    """
    前向传播：生成注意力权重并加权特征
    :param x: 输入特征图，shape=(B, in_channels, H, W)
    :return: 加权后的特征图，shape=(B, in_channels, H, W)
    """
    # 步骤1：全局平均池化（压缩空间维度，聚焦通道特征）
    # 从(B, C, H, W) → (B, C, 1, 1)，保留通道维度的全局信息
    x_pool = F.adaptive_avg_pool2d(x, output_size=1)

    # 步骤2：卷积降维→ReLU激活→卷积升维→Sigmoid生成注意力权重
    attention = self.conv2(F.relu(self.conv1(x_pool)))  # (B, C, 1, 1)
    attention_weight = self.sigmoid(attention)          # 权重∈[0,1]

    # 步骤3：注意力权重加权原始特征（广播机制，1×1权重作用于整个H×W）
    out = x * attention_weight

    return out
```


中国知网 https://www.cnki.net

附录 18

动态目标轨迹预测的核心算法如下：

```
def predict_trajectory(self, current_position, velocity_history):
    """
    基于历史速度数据预测未来轨迹
    :param current_position: 当前位置，格式为 (x, y)
    :param velocity_history: 历史速度数据（此处保留参数，Kalman Filter 初始化后可结合该参数更新）
    :return: 预测的未来位置、抓取时机
    """
    # 初始化卡尔曼滤波器（6维状态，2维测量）
    kalman_filter = cv2.KalmanFilter(6, 2)

    # 测量矩阵：仅提取状态中的位置(x,y)
    kalman_filter.measurementMatrix = np.array([[1,0,0,0,0,0],
                                                [0,1,0,0,0,0]], np.float32)

    # 状态转移矩阵（考虑位置、速度、加速度的二阶运动模型）
    kalman_filter.transitionMatrix = np.array([[1,0,1,0,0.5,0],
                                               [0,1,0,1,0,0.5],
                                               [0,0,1,0,1,0],
                                               [0,0,0,1,0,1],
                                               [0,0,0,0,1,0],
                                               [0,0,0,0,0,1]], np.float32)

    # 预测卡尔曼滤波器的下一状态
    predicted_state = kalman_filter.predict()
    # 提取预测状态中的位置信息（前2维）
    future_position = predicted_state[:2]

    # 返回预测位置和计算得到的抓取时机
    return future_position, self.calculate_grasp_timing(future_position)
```


中国知网 https://www.cnki.net